

Resumen clase 1_Semana_AI_20260219_2

Ángel Eduardo Jiménez Valverde

February 23, 2026

1 Introduction

Al inicio de la clase se nos pidió llenar el formulario para confirmar que sí recibimos los documentos de las áreas de emergencia y del curso. Además, también se nos dio la opción de dar pseudónimos para facilitar la calificación que sea más discreta. **Se deben de enviar dichos pseudónimos por whatsapp directo al profesor de ser el caso que no se hizo en la clase.**

2 En la lección

2.1 ¿Qué es inteligencia artificial?

Iniciamos la clase viendo los distintos estereotipos y los puntos de vista distintos que las personas suelen tener acerca de la Inteligencia Artificial, y que al final... la realidad es que sí se usan distintas técnicas y bastante matemática en el área de trabajo, pero en realidad en algunos casos puede que no tengamos que hacer mucho, ya que ya existe una herramienta para trabajar el caso.

Al final, definir la inteligencia es algo complicado, e incluso algo que puede ser psicológico, filosófico, o propio de la naturaleza.

También es importante definir los siguientes significados:

- **Autonomía:** No requiere que se le proporcione instrucciones.
- **Adaptativo:** Puede cambiar el comportamiento si el ambiente o el espacio del problema cambia.

En conclusión, podemos definir en la inteligencia artificial como:

- Un sistema que posee alguno de estos 2 atributos, principalmente adaptativo, o un comportamiento "inteligente".
- Ser capaz de exhibir inteligencia o capacidad de resolver distintas situaciones complejas y nos proporcione un resultado.
- En algunos casos éstas incluso pueden llegar a simular la visión, escucha o sentidos naturales.
- Se espera que también pueda aprender de forma autónoma mediante sus propios datos y nuevos datos agregados.
- Principalmente, se espera que la inteligencia artificial sea capaz de resolver problemas complejos.

El corazón de la IA al final resultan ser los datos con los que se alimenta a una inteligencia artificial, los datos con los que se entrena, pues en base a dicha información se puede crear una IA correcta, los algoritmos si son de importancia... pero al final lo importante para un resultado son esos datos.

2.2 Datos

El rendimiento de los algoritmos es malo, si al final los datos son incorrectos, *ya sea porque se escogieron datos incorrectos, o que no hay suficientes datos.*

Éstos datos pueden llegar a ser:

- **Cuantitativos:** Valores numéricos, flotantes, que pueden representar una ubicación en el mapa, un nivel de temperatura, etc.
- **Cualitativos:** Suelen ser más complicados de conseguir, pueden llegar a ser datos más específicos o cualitativos.

2.3 Distintos avances de la Inteligencia Artificial

- **1950:** Se crea el término de "inteligencia artificial", y se crea el modelo de Perceptron y el concepto de una **Red Neuronal**.
- **1960** Se crean los modelos de ML (Machine Learning), el modelo de Perceptron no suele ser suficiente.
- **1970** Se crean lenguajes como Prolog, que serán de utilidad para la Inteligencia Artificial
- **1980** Se crean algoritmos tipo colmena, así como máquinas LISP.
- **1990** Hay un avance en la robótica, e incluso se consigue un algoritmo capaz de ganar en el Chess. Además, se consigue salvar el algoritmo de Perceptron y resurgir la Inteligencia Artificial.
- **2000** Se crean dispositivos como el Kinect, la Wii, dispositivos capaces de controlar el movimiento, objetos capaces de obtener reconocimiento facial. La creación de asistentes inteligentes.
- **2010** Se crea una inteligencia artificial que utiliza una técnica más potente con más capas, que sería el inicio de la Inteligencia Artificial como la conocemos, ésta conocida como el Deep Learning.

2.4 Concepto de Machine Learning

Este concepto fue creado por Arthur Samuel, con la idea de crear un algoritmo para jugar "checkers", y que dicho algoritmo sería creado para demostrar que la computadora es capaz de jugar esto.

El Machine Learning cuenta como 2 aristas que forman un vector, dichos aristas serían: **Ciencia** y la **Ingeniería**, con la idea de "construir máquinas que pueda hacer tareas sin ser explícitamente programadas, solamente infiriendo los datos".

Se siguen enfoques estadísticos para entrenar a los modelos para que aprendan de los datos, y crear un algoritmo para aproximar las funciones... de nuevo, es una aproximación, no es perfecta... por eso suele darse múltiples cantidades de datos correctos para entrenar a la máquina y reducir el margen de error.

A mayor cantidad de datos (mientras estén correctos y que cumplan la situación), es mejor, ya que hacen el modelo más robusto.

2.5 Tipos de aprendizaje

- **Supervisado:** Se supervisan la información en base a los conjuntos objetivos, y en base a los datos conseguidos, usualmente mediante prácticas estadísticas. Tenemos un vector que incluye características y objetivo.
- **No supervisado:** Este tipo de aprendizaje es distinto, solamente tenemos el vector de características, no tenemos el valor de objetivo, en base a las características recolectadas, buscamos que existan patrones en los datos, que permitan describir la situación en una manera. Estos tipos de algoritmos son conocidos como "algoritmo de Clustering".

- **Semi-supervisado:** En este se tiene una enorme cantidad de datos, con una ligera mayoría que son supervisados (con muestra y etiqueta), y en el resto de los datos no tenemos el valor objetivo.
- **Auto-supervisado:** Utilizamos nuestra mismo valor de muestra, o en este caso tenemos nuestra arista o vector "x", y vamos a usar ese mismo valor como si estuviéramos usando el método supervisado.
- **Refuerzo:** Es el tipo de supervisado en el que tenemos un modelo, con un sistema de **Rewards (Premios)** y un sistema de **Failures (Castigos)**, en un modo en el que si consigue una ganancia si tiene avances.
- **Few-shot:** Se termina de entrenar el modelo de lenguaje... si se le dan varios ejemplos para que la IA entienda el cómo resolver los errores, en éste caso es Few Shot Learning.
- **One-shot:** Se termina de entrenar el modelo de lenguaje... si de primeras logra resolver las tareas donde se le da un ejemplo de cómo resolver la tarea, en dicho caso, es el caso de One-shot Learning.
- **Zero-shot:** Se termina de entrenar el modelo de lenguaje... si de primeras logra resolver las tareas sin ningún entrenamiento o ejemplo brindado en ningún prompt, es Zero Shot.

2.6 Machine Learning en el área científico:

- Se busca generar conocimiento, nuevas técnicas, nuevas ideas.
- Se basa mucho en las Métricas, y en búsqueda de superar las métricas de otros modelos.
- Se escribe un documento oficial, con evidencia bien planteada.
- Se construyen modelos con datos nuevos, el Data Scientist.

2.7 Machine Learning en el área de ingeniería:

- Se pone en producción el modelo previamente planteado, se hace deploy del posible modelo y se alimenta de la información.
- Después se toca transformar el modelo, en base al modelo creado en un lenguaje, quizás se requiera pasar a otros lenguajes con mejor rendimiento, entonces se transforma el modelo a otro lenguaje.
- Se usan herramientas como Onnix, que permite hacer un refactor de modelos; por ejemplo, hecho en Python, para convertirlo en otros más ligeros o más fáciles de simplificar, como C++ o Rust.
- MLOps: Se hace uso de las herramientas o prácticas para convertir los modelos creados para que sean prácticos en **producción**.

El área científico y el área de ingeniería son bastante distintas, de modo que uno puede optar por un área o división de éstas, según la preferencia, y poder trabajar de ésta en el futuro.

3 Datos de importancia al final de la lección

- Se seleccionaron 2 estudiantes para que hicieran los apuntes de la clase.
- Hay 2 lecturas obligatorias para TEC Digital, es de importancia leerlas para prepararse para el futuro quiz.