

Apuntes Inteligencia Artificial

Santiago Chaves Garbanzo
2023047710

Escuela de Ingeniería en Computación
Tecnológico de Costa Rica

Profesor: Steven Pacheco Portuquez
Curso: IC6200 Inteligencia Artificial
Fecha: 24 de febrero de 2026

Resumen—En esta clase se comentó principalmente sobre los distintos tipos de Machine Learning (ML), y cuáles son sus características principales. Además, se introdujo conceptos fundamentales como que tipos de problemas resuelven los algoritmos de ML, y que proceso se suele utilizar para implementarlos en ambientes de producción

I. REPASO CLASE ANTERIOR

Se realizó un repaso sobre los temas abordados en la clase del jueves anterior.

I-A. ¿Qué es Inteligencia?

Se explico nuevamente que no hay consenso absoluto sobre la definición de la inteligencia. Sin embargo, lo más aceptado es que se evidencia en individuos (o máquinas) que son autónomos y adaptativos. Esto implica que deben ser capaces de actuar sin intervención externa y de saber como reaccionar ante distintos estímulos, dependiendo de la situación.

I-B. ¿Qué es Inteligencia Artificial?

Por lo tanto, la inteligencia artificial se refiere a sistemas de computo y robots que logran ser autónomos y adaptativos. También ocurre cuando se imitan los sentidos básicos (Escucha, Habla, Vista, etc.)y se utilizan para realizar tareas complejas; por ejemplo, los carros autónomos.

Por otro lado, se volvió a enfatizar que el corazón de la IA son los datos, todo entrenamiento es gracias a ellos. Son tan importantes que en caso de no ser de calidad, el modelo resultante tampoco lo será.

I-C. ¿Qué es Machine Learning?

El Machine learning (ML) se resume en algoritmos que se entrenan con grandes cantidades de datos, para aprender a reaccionar ante distintos inputs. Dichos algoritmos son programados de manera "declarativa", no tienen un propósito específico, lo cual les permite ser utilizados en una gran cantidad de escenarios. Por ejemplo, un algoritmo de clasificación binaria, sirve para todo tipo de clasificaciones binarias, mientras que si se tomara un enfoque tradicional, el algoritmo resultante sería sumamente complejo y no generalizable.

Un ejemplo de aplicación de Machine Learning a un problema, es el de tener un modelo que permita determinar si un correo electrónico es Spam o no.

Desde un punto de vista técnico, lo que se hace es pasar todos los datos por una función que servirá para dividirlos (Esto en un algoritmo de clasificación). El objetivo es encontrar una

función que se aproxime a dicha división perfecta, para que así el modelo sea capaz de clasificar de manera correcta en la mayor cantidad de casos. La complejidad recae en que en muchas ocasiones las funciones tienden a ser no lineales.

I-D. Tipos de Aprendizaje

Existen distintas maneras de entrenar modelos de ML:

- **Supervisado:** Ocurre cuando el conjunto de datos consiste de pares ordenados (x, y) , en los que x es un vector de características, por ejemplo, datos de una orquídea: tamaño de tallo, tamaño de pétalo, y color; y y es una etiqueta que se busca aproximar, por ejemplo, el consumo de agua o la especie. Al entrenar el modelo se le pasan dichos parámetros, para que retorne valores $\hat{y}$, que sean lo más cercanos posibles a y .
- **No-Supervisado:** En este tipo de aprendizaje se tiene solo vectores de características $x = (x_1, x_2, \dots, x_n)$, sin etiquetas asociadas. A partir de ellos se trata de encontrar patrones, estructuras en los datos. Esto permite encontrar características que agrupen, o permitan disminuir la dimensionalidad de los vectores.
- **Semi-Supervisado:** Utiliza tanto datos etiquetados como no etiquetados, para optimizar los resultados en ciertos escenarios.
- **Auto-Supervisado:** Este tipo de aprendizaje utiliza los mismos datos con los que se entreno para validarse. Un ejemplo sería un modelo que utilice una imagen a color que fue pasada a blanco y negro para poder descubrir como revertir dicho efecto.
- **Refuerzo:** Este tipo de aprendizaje premia al modelo cuando acierta, y lo penaliza al fallar. Un ejemplo puede ser una IA que juegue Mario, por lo que al caer en huecos




Figura 1. Ejemplo de clasificación

se le reste puntos para que sepa que no debe fallar ahí, y se le concedan puntos al eliminar enemigos.

- **Few/One/Zero - Shot:** El zero shot ocurre cuando un modelo es capaz de resolver una tarea para la cuál no fue entrenado, por ejemplo los LLMs son capaces de realizar aritmética indirectamente gracias a su capacidad de predecir la siguiente palabra. El one shot es cuando solo hace falta darle un ejemplo al modelo para que sepa como resolver un problema. Finalmente el few shot es cuando ocupa más de un ejemplo.

I-E. Enfoques

En el área del machine learning se pueden abarcar dos enfoques principales:

- **Ciencia:** Tiene como objetivo generar nuevo conocimiento, nuevos modelos y aplicarlos a áreas innovadoras. Se tiene que estar pendiente al estado del arte, para superar las métricas actuales. El trabajo suele ser más informal y con propósitos de investigación.
- **Ingeniería (MLOps):** Ocurre una vez se tiene el modelo ya listo, se enfoca en ver como ponerlo en producción, cómo hacerlo más eficiente, cómo monitorizarlo, con qué pipeline reentrenarlo, etc.

II. PIPELINE PARA REENTRENO

Existen modelos fundacionales como ChatGPT que no requieren ser reentrenados constantemente debido a su gran magnitud, pero para otros más simples si se requiere determinar un pipeline en producción. Para ello se siguen los siguientes pasos (ver la Fig. 2):

1. **Manejo de datos:** En esta etapa se debe averiguar de donde obtener los datos, que etiquetas usar (si es que hay), y observar las restricciones de negocio que pueden dificultar este proceso.
2. **Entrenamiento:** Depende de los datos se debe entrenar a los modelos de distintas formas. Una manera es separarlos en 80:20, y usar el 80 % de los para entrenar el modelo, y el resto para validar los resultados (este muestreo debe ser aleatorio).
3. **Validación:** Ahora se necesita validar los distintos modelos entrenados, cambiar hiperparámetros y averiguar cual es el que da los mejores resultados.
4. **Puesta en producción:** Finalmente se debe poner en producción el modelo, y recolectar datos de uso para posteriormente usarlos para reentrenarlo y mejorarlo.

III. PARADIGMAS

Existen distintos tipos de problemas para los que se pueden aplicar conocimientos en ML:

- **Búsqueda:** son los que resuelven los algoritmos típicos como BFS, DFS A*, y Dijkstra, que buscan resolver cual es el mejor camino a tomar.
- **Optimización de Funciones:** Es cuando se trata de optimizar el error entre y y $\hat{y}$. Esto llega a ser complicado ya que las funciones suelen ser no lineales, por lo que es




Figura 2. Pipeline de reentrenamiento




Figura 3. Diferencia entre mínimo local y mínimo global.

fácil confundir un error mínimo local con el error mínimo global, como se observa en la Fig. 3.

- **Predicción y Clasificación:** En este tipo de problemas con base en un vector de características x se predice o clasifica. Por ejemplo, si x hace referencia a datos sobre carros, entonces se puede predecir cuanto gasto de gasolina tendrá, o bien se puede clasificar que tipo de automóvil es (sedán, SUV, camión).
- **Agrupamiento:** Con base en métricas de distancia se pueden generar agrupamientos entre los datos.
- **Deterministas:** Este tipo de problemas no aplican para modelos estadísticos, porque siempre para una misma entrada, se tendrá una misma salida. Por ejemplo, a las 12 m.d. siempre hay luz en Costa Rica.
- **Estocásticos:** Son problemas que dan distintas respuestas para una misma entrada dependiendo de las probabilidades en dicho momento. Por ejemplo, a las 12 m.d siempre está *Lluvioso*|*Soleado*|*Nuboso*.

IV. JERARQUÍA EN INTELIGENCIA ARTIFICIAL

El campo de la inteligencia artificial se divide en una jerarquía (ver la Fig. 4):

1. **Inteligencia Artificial:** Se refiere a todo lo que intente hacer mímica a un sistema inteligente, como los algoritmos genéticos, backtracking, o fuerza bruta.
2. **Machine Learning:** Es cuando se usan grandes volúmenes de datos, para que una máquina aprenda a hacer tareas específicas.
3. **Deep Learning:** Es un tipo de ML que consiste de capas muy profundas, por ejemplo redes neuronales de 80, o convolucionales para computer vision. Suelen resolver problemas de funciones no lineales.




Figura 4. Jerarquía en Inteligencia Artificial

4. **IA Generativa:** Es el tipo de DL que ha surgido recientemente, que se usa para generar textos, imágenes o más contenido.

V. USOS DE LA INTELIGENCIA ARTIFICIAL

La inteligencia artificial tiene múltiples posibles aplicaciones en distintas áreas del conocimiento. Se puede usar para optimizar la producción en sistemas agrícolas, al usar computer vision para detectar el estado de plantas y de ahí determinar que tanto riego ocupan. O bien, en el área médica, se pueden usar modelos de detección para imagenología, que permitan detectar tumores cancerígenos en etapas tempranas.

VI. PIPELINE GENERAL

(Posiblemente salga en Quiz) El proceso de crear un modelo de Machine Learning requiere un pipeline ordenado que permita obtener los mejores resultados posibles. Los pasos son los siguientes:

VI-A. Data Acquisition

Se deben seleccionar muestras representativas de la población con la que se desea trabajar. Por ejemplo, si para un modelo de predicción de votadores para elecciones nacionales se selecciona solo hombres mayores a 40 años en San José, el resultado se verá sesgado gracias a la mala selección de la muestra. Por ello la calidad de los datos afecta directamente los resultados, y la generalidad que tendrá el modelo.

VI-B. Data Preparation

Esta etapa se enfoca en cómo hay que darle los datos al modelo. Por ejemplo, hay modelos en los que se ocupa que los datos sigan una distribución normal para que los resultados sean adecuados. O bien, hay otros en los que si los datos numéricos tienen una varianza muy alta ($x_i = 1000000$, $x_j = 0,3$), el producto final sufre overfitting.

Asimismo, en ocasiones se ocupa aplicar normalizaciones, escalamiento o estandarización a los distintos valores. También se suele eliminar duplicados, y averiguar que hacer ante datos faltantes (como aplicarles el valor promedio de dicha característica).

VI-C. Feature Engineering

En esta etapa se crean nuevas características para optimizar el grado de error del modelo. Por ejemplo, si se tiene una característica x_1 del largo de un terreno y otra x_2 del ancho, puede llegar a ser útil crear una nueva x_3 que sea el área total del terreno. Otro caso es cuando los datos siguen una parábola, pero se ocupa aplicarles un modelo lineal, por lo que se puede crear un feature que eleve al cuadrado dichos valores y permita un mejor ajuste.

VI-D. Model Selection

Dependiendo del problema que se abarque, la selección del modelo. Por ejemplo, en caso de ocupar explicabilidad en las respuestas, se puede usar un Decision Tree, que retorna los pasos que siguió para conformar su solución (un caso práctico sería aplicarlo para algoritmo de aprobación de crédito bancario).

VI-E. Model Training

Esta etapa es en la que se entrena al modelo y se mide cuales son las configuraciones más eficientes. Se aplican técnicas como el Grid Search, que permite correr el modelo con distintos hiperparámetros, para ver cuál combinación termina con mejores resultados.

VI-F. Deployment

Finalmente toca averiguar como desplegar el modelo para que pueda ser accedido por el público meta. En esta etapa se debe averiguar si toca hacer migraciones con herramientas como ONNX, ver todo el proceso de MLOps.

VII. TAREA MORAL

La tarea no suma puntos, sin embargo es importante porque en caso de que se haga una curva a final de semestre se tomará en cuenta si fue hecha.

Se debe realizar una mini-investigación de las siguientes personas:

- Yann LeCun
- Yoshua Bengio
- Sam Altman
- Geoffrey Hinton
- Timnit Gebru
- Ian Goodfellow

Además hacer un resumen del funcionamiento de las siguientes herramientas/conceptos:

- ONNX
- MLflow
- Vertex
- LangChain
- HuggingFace
- Ollama
- Chain-of-Thought