

Apuntes Clase 1 Semana 2

Jose Sequeira Chacon
2019380131

Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica

Profesor: Steven Pacheco Portuquez
Curso: IC6200 Inteligencia Artificial
Fecha: 24 de febrero de 2026

Abstract—En esta lección se repasó acerca de los diversos algoritmos de Machine Learning (ML) y cuáles son sus características fundamentales. También, se presentaron conceptos básicos como los tipos de problemas que pueden resolver los diferentes algoritmos de ML y el proceso general de su implementación en producción.

I. REPASO

A. Definición de Inteligencia

Aunque no hay una definición absoluta de inteligencia globalmente reconocida, lo que generalmente se acepta es que es una entidad de funcionamiento autónomo y adaptativa a los cambios en el entorno. Estas entidades deben poder actuar de forma independiente.

B. Definición de Inteligencia Artificial

Basado en la definición anterior, la inteligencia artificial (IA) se define como un sistema computacional que puede funcionar de manera autónoma y que logra adaptarse a cambios en el entorno.

Un claro ejemplo de IA son los autos de conducción autónoma, los cuales funcionan de manera independiente (no hay ningún chofer en el auto) y pueden adaptarse a situaciones inesperadas.

C. Base de la Inteligencia Artificial

Los datos son el corazón de la IA. No importa que tan bueno sea el algoritmo, un modelo será tan bueno como la calidad de los datos de su entrenamiento.

D. Definición de Machine Learning

El Machine Learning (ML) es un campo de la inteligencia artificial que se centra en la creación de sistemas que puedan aprender de los datos, sin estar explícitamente programados para cada tarea en específico.

Un ejemplo sería un clasificador de imágenes, el cual usaría una función matemática para separar los valores. Por lo tanto, no se programa el clasificador, permitiendo que el algoritmo logre clasificar imágenes nuevas, aunque no hayan sido vistas anteriormente.

E. Tipos de Aprendizajes

- Supervisado: se basa en etiquetas o pares ordenados, donde cada entrada x tiene una salida esperada y (etiqueta). La salida del modelo se considera una aproximación y se denota como $\hat{y}$. La sección supervisada es




Fig. 1. Ejemplo de función lineal.

comparar y con $\hat{y}$.

Uso: clasificaciones binarias, cálculos de regresión.

- No supervisado: en este aprendizaje, no existe la etiqueta o salida esperada y . La idea de este tipo de aprendizaje es encontrar patrones, realizar agrupaciones o establecer relaciones por sí solo. Al no haber etiquetas, no hay una salida esperada ni una supervisión que realizar.

Uso: agrupamiento (clustering), reducción de variables, asociaciones.

- Semisupervisado: basado en los tipos de aprendizajes anteriores, en este tipo de aprendizaje se utilizan algunas entradas con etiquetas, por lo tanto, estas entradas si son supervisadas.

La necesidad de este aprendizaje resulta del costo de etiquetar todo el dataset, requiriendo personas experimentadas y ciertas habilidades. Por lo que se reduce el costo operativo al tener datos no etiquetados.

Uso: transducción (generar etiquetas para entradas), inductivo (etiquetar entradas basadas en una lista de etiquetas existentes).

- Autosupervisado: a diferencia del método supervisado, el modelo se encarga de hacer la comparación y con $\hat{y}$. Este aprendizaje también podría generar etiquetas (como lo haría el aprendizaje semisupervisado) como un primer paso. Después, funcionaría como un algoritmo supervisado o no supervisado.

Uso: basado en la función, como aprendizaje supervisado o no supervisado.

- Refuerzo: este aprendizaje es un tipo de aprendizaje

automático centrado en el entrenamiento de agentes para maximizar la recompensa mediante interacciones en entornos dinámicos. A diferencia del aprendizaje supervisado o no supervisado, el AR equilibra la exploración (probar nuevas acciones) y la explotación (utilizar información conocida).

Al comparar el rendimiento del agente con métricas definidas, la diferencia en el desempeño genera la noción de arrepentimiento. Esto resulta en que el agente deba razonar sobre las consecuencias a largo plazo de sus acciones (es decir, maximizar las recompensas futuras), aunque la recompensa inmediata asociada a esto pueda ser negativa.

Uso: problemas de comportamiento (juegos)

- Zero-shot: aprendizaje que implica que el modelo tendrá entradas de clases totalmente desconocidas durante las pruebas. Dicho de otra forma, el modelo no fue entrenado con dichas clases de datos (tareas a resolver).

Uso: clasificación de imágenes, segmentación, procesamiento de lenguaje natural.

- One-shot: basado en el aprendizaje anterior, el modelo es entrenado con un ejemplo de la clase de entrada (tarea a resolver).

Uso: clasificaciones, reconocimiento de objetos, computer vision

- Few-shot: similar a los 2 aprendizajes anteriores, este tipo usa varios ejemplos de la clase de entrada durante el entrenamiento.

Uso: segmentación y clasificación de imágenes, robótica.

F. Énfasis

- Científico: este enfoque es teórico, su finalidad es generar nuevo conocimiento y desarrollar nuevos modelos. Esto implica estar actualizado al estado del arte para sobrepasar las métricas actuales. Este trabajo es realizado generalmente por data scientists.
- Ingeniería: este es un enfoque práctico, que busca como poner en producción al modelo. Esto implica transformación del notebook a una arquitectura real con capacidades y limitaciones, además de una potencial conversión del lenguaje original. El trabajo es realizado por ingenieros Machine Learning Operations (MLOps).

II. DESARROLLO DE UN MODELO

En términos generales, un modelo de machine learning tiene un ciclo de mejora continua con las siguientes etapas:

- 1) Serving: el modelo está puesto en producción y se generan nuevos datos.
- 2) Datos: se colectan los nuevos datos y se divide 80/20. 80% se utiliza para entrenamiento y 20% para pruebas.
- 3) Entrenamiento: se escoge el modelo apropiado para el nuevo dataset. Pueden usarse varios modelos para comparación de resultados.
- 4) Validación: se revisan y comparan resultados entre modelos, se optimizan hiperparámetros y se escoge el mejor modelo.




Fig. 2. Ciclo de mejora continua de un modelo.

III. PARADIGMAS DE PROBLEMAS

Como se ha indicado, existen diferentes tipos de algoritmos y entrenamientos, estos resultan en diferentes problemas que la IA puede solucionar:

- Búsqueda: la solución de este tipo de problema requiere encontrar el camino más óptimo.
- Optimización: al optimizar funciones, se puede confundir un mínimo local con un mínimo global. Por lo tanto, el problema se halla en encontrar el mínimo correcto.
- Predicción: este tipo de problema se centra en identificar patrones y dar una salida de un número real.
- Clasificación: este problema se enfoca en identificar patrones y dar una salida en un conjunto finito de categorías o etiquetas.
- Agrupamiento: este tipo se enfoca en determinar agrupamientos en los datos, basado en métricas y cercanía de los mismos.

IV. TIPOS DE MODELOS

- Determinístico: estos modelos producen el mismo resultado para una entrada determinada siempre. Esto logra alta predictibilidad y simplicidad.
- Estocásticos: estos modelos incorporan aleatoriedad durante el entrenamiento o inferencia para manejar la incertidumbre, lo que resulta en diferentes resultados entre ejecuciones pero una mejor generalización.

V. RELACIÓN DE CONCEPTOS

Existen varios conceptos relacionados que se pueden representar como subconjuntos unos de otros:

- 1) Inteligencia Artificial (IA): hace referencia a la mímica de un comportamiento inteligente, como detección de patrones y resolución de problemas.
- 2) Machine Learning (ML): se puede definir como la IA que utiliza grandes volúmenes de datos con algoritmos estadísticos para detectar patrones. Soluciona problemas lineales.

- 3) Deep Learning (DL): se define como ML de redes neuronales de mucha profundidad de capas. Solución de problemas no lineales.
- 4) Generative AI (GenAI): DL con sets de datos masivos para generar texto, código, imágenes, etc.
- 6) Model deployment: esta fase práctica implica el diseño de la arquitectura, transformación del notebook y ejecutar el modelo. Esto se definió en la sección I-F.




Fig. 3. Ciclo de desarrollo de un modelo.

VI. USOS DE LA INTELIGENCIA ARTIFICIAL

La inteligencia artificial puede tener diversas aplicaciones en varias áreas. Por ejemplo, se puede usar en la agricultura, utilizando computer vision para identificar qué cultivar, requerimientos de agua, fertilizante, etc. También, se pueden utilizar computer vision para la detección de tumores cancerígenos en fases iniciales.

VII. PROCESO DE DESARROLLO

De manera general, el desarrollo de un modelo de Machine Learning tiene los siguientes pasos:

- 1) Data acquisition: es necesario obtener datos de calidad relevantes y representativos del problema que se va a resolver. Por lo tanto, se necesita determinar y delimitar el origen, muestra y forma de obtención del dataset.
- 2) Data preparation: seguidamente, se deben preparar los datos. Esto incluye la limpieza de duplicados, normalizar la distribución, transformación para normalización, escalamiento.
- 3) Feature engineering: creación de features o variables a partir de variables existentes para proporcionar variables más relevantes o apropiados.
Por ejemplo, cálculo de superficie a partir de los datos de ambas dimensiones.
- 4) Model selection: seleccionar modelo en función del problema a resolver. Dado que existen diferentes tipos de algoritmos y aprendizajes, los modelos resultantes van a ser más apropiados en diferentes problemas.
- 5) Model training: selección de hiperparámetros que influyen en la optimización del modelo. Para esto, se utiliza la técnica Grid Search, para probar el modelo con diferentes configuraciones de hiperparámetros.