

Apuntes de Clase: Semana 3 Martes

Jose Miguel Gonzalez Barrantes
Carné: 2023087564
Escuela de Ingenieria en Computación
Instituto Tecnológico de Costa Rica
Profesor: Steven Andrey Pacheco Portugués
Curso: IC6200 Inteligencia Artificial
Fecha: Miércoles 4 de marzo de 2026

Resumen—A continuación se presentan los apuntes de la clase del martes 3 de marzo, correspondiente a la semana 3. La clase inicia con la realización del Quiz #1 y posteriormente se comentan en voz alta las respuestas de las preguntas. Después se continúa con un repaso de conceptos importantes de álgebra lineal que serán de mucha utilidad durante el curso. Finalmente se comienza con el tema de Supervised Learning.

I. PREGUNTAS DEL QUIZ #1

1. Describa los tipos de aprendizaje supervisado, no supervisado y one-shot learning

En el aprendizaje supervisado se cuenta con un vector de características X y además se tiene la etiqueta Y . El modelo aprende la relación entre ambos para poder realizar predicciones.

En el aprendizaje no supervisado no se tienen etiquetas definidas. En este caso el modelo busca patrones o estructuras en los datos, por ejemplo mediante técnicas de agrupamiento.

El *One-Shot Learning* consiste en entrenar el modelo utilizando únicamente un solo ejemplo, buscando que el sistema pueda generalizar a partir de muy poca información.

2. Describa la técnica de Grid Search

La técnica de *Grid Search* es muy utilizada en machine learning para encontrar la mejor configuración de un modelo. Se basa en probar diferentes combinaciones de hiperparámetros que se definen previamente y evaluar cuál funciona mejor.

Con esto se compara el rendimiento de cada combinación y finalmente se selecciona la que obtiene los mejores resultados.

3. ¿Cuál es la diferencia entre la mejor solución local y global en optimización de problemas?

Una solución local es la mejor dentro de una región o dominio específico del problema. En cambio, la solución global es la mejor de todas las posibles soluciones.

Una solución local no siempre será la mejor del problema completo, por lo que no se puede asumir que sea la óptima. Idealmente se busca encontrar la solución global.

4. Describa qué son los problemas de agrupamiento

Los problemas de agrupamiento buscan organizar datos

en grupos o *clusters* según sus similitudes. La idea es que los elementos dentro de un mismo grupo sean más parecidos entre sí que con los de otros grupos.

Este tipo de técnica se utiliza cuando no se tienen etiquetas o categorías previamente definidas.

II. INFORMACIÓN ADICIONAL DE LA CLASE

Durante la clase el profesor mencionó algunos aspectos importantes relacionados con el trabajo práctico del curso. Se habló sobre el uso de *Jupyter Notebooks* como herramienta principal para el desarrollo de los ejercicios y análisis de datos.

Además, el profesor comentó sobre un error que puede aparecer durante la manipulación de datos. Este error no proviene directamente del archivo CSV, sino del proceso de manejo o transformación de los datos dentro del notebook.

También se mencionó un material de repaso de álgebra lineal que contiene información importante sobre matrices, vectores y otros conceptos fundamentales que serán necesarios para comprender mejor los temas del curso.

Finalmente, el profesor aclaró que no habrá revisiones presenciales programadas. Lo importante será enviar el trabajo, revisar cuidadosamente el notebook y asegurarse de que el informe solicitado esté completo. Si en el informe aparece información que no está respaldada en el notebook, esto podría generar una penalización.

III. REPASO DE ÁLGEBRA LINEAL

Durante la clase se realizó un breve repaso de algunos conceptos fundamentales de álgebra lineal que serán importantes a lo largo del curso, especialmente para comprender cómo funcionan muchos algoritmos de machine learning.

III-A. ¿Qué es un vector?

Un vector es un objeto matemático que tiene **dirección** y **magnitud**. Puede interpretarse como una posición dentro de un espacio n -dimensional.

Por ejemplo, el vector

$$x = (1, 5)$$

representa una posición en el plano cartesiano.

En muchos casos se representa un vector como una flecha que inicia en el origen $(0, 0)$ y termina en el punto que definen sus coordenadas.




Figura 1. Representación geométrica de un vector

III-B. Dirección y magnitud

Dirección: indica hacia dónde apunta el vector dentro del espacio.

Magnitud: representa la longitud del vector, es decir, la distancia desde el punto de origen hasta el punto final.

III-C. Vector entre dos puntos

Si se tienen dos puntos en el espacio:

$$A = (a_1, a_2, a_3, \dots, a_n)$$

$$B = (b_1, b_2, b_3, \dots, b_n)$$

entonces el vector que va desde A hasta B se calcula como:

$$\mathbf{u} = B - A$$

$$\mathbf{u} = (b_1 - a_1, b_2 - a_2, \dots, b_n - a_n)$$

donde:

- A es el punto de origen.
- B es el punto final.
- a_i y b_i representan las coordenadas en la dimensión i .
- n representa el número de dimensiones.

III-D. Magnitud de un vector

La magnitud de un vector mide qué tan grande o largo es el vector.

Se denota como:

$$||x||$$

Para un vector

$$x = (x_1, x_2, \dots, x_n)$$

su magnitud se calcula como:

$$||x|| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

donde:

- $x_1, x_2, \dots, x_n$ son las componentes del vector
- n es el número de dimensiones

Geoméricamente esto corresponde a la distancia desde el origen hasta el punto que representa el vector.

III-E. Distancia de Manhattan

La distancia de Manhattan mide la distancia entre dos puntos moviéndose únicamente de forma horizontal y vertical.

Se define como:

$$d(A, B) = \sum_{i=1}^n |a_i - b_i|$$

donde:

- $A = (a_1, a_2, \dots, a_n)$
- $B = (b_1, b_2, \dots, b_n)$
- n es el número de dimensiones

Esta distancia no siempre representa el camino más corto entre dos puntos.

III-F. Distancia Euclidiana

La distancia Euclidiana corresponde a la distancia más corta entre dos puntos en el espacio.

Se calcula mediante:

$$d(A, B) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$

donde:

- $A = (a_1, a_2, \dots, a_n)$
- $B = (b_1, b_2, \dots, b_n)$
- n es el número de dimensiones

Esta es una de las métricas de distancia más utilizadas en machine learning.

III-G. Norma de un vector

Una norma es una función

$$\|\cdot\|$$

que asigna un vector a un número real (escalar). En otras palabras, la norma mide el tamaño o longitud de un vector.

Para que una función sea considerada una norma debe cumplir tres propiedades:

1. Positividad

$$\|x\| \geq 0$$

y

$$\|x\| = 0 \iff x = 0$$

Esto significa que la norma siempre es positiva o cero, y solo es cero cuando el vector es el vector nulo.

2. Homogeneidad

$$\|\alpha x\| = |\alpha| \|x\|$$

donde:

- α es un escalar
- x es un vector

Esto significa que si un vector se escala por un número, su norma también se escala proporcionalmente.

3. Desigualdad triangular

$$\|x + y\| \leq \|x\| + \|y\|$$

donde:

- x y y son vectores

Geoméricamente esto representa que la suma de dos lados de un triángulo siempre es mayor o igual que el tercer lado.

III-H. Vector unitario

Un vector unitario es un vector cuya magnitud es igual a 1.

$$\|u\| = 1$$

Estos vectores son útiles porque representan únicamente una dirección. En algunos algoritmos se utilizan para normalizar datos o comparar direcciones entre vectores.

III-I. Producto punto

El **producto punto** (dot product) es una de las operaciones más importantes entre vectores y aparece constantemente en machine learning.

Si se tienen dos vectores:

$$x = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, y_2, \dots, y_n)$$

el producto punto se define como:

$$x \cdot y = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

o de forma compacta:

$$x \cdot y = \sum_{i=1}^n x_i y_i$$

donde:

- x_i es la componente i del vector x
- y_i es la componente i del vector y
- n es el número de dimensiones

Interpretación geométrica

Geoméricamente, el producto punto representa la proyección de un vector sobre otro. Es decir, puede verse como la "sombra" que un vector proyecta sobre el otro.

También puede expresarse como:

$$x \cdot y = \|x\| \|y\| \cos(\theta)$$

donde:

- $\|x\|$ es la magnitud del vector x
- $\|y\|$ es la magnitud del vector y
- θ es el ángulo entre ambos vectores

Esta operación es fundamental en muchos modelos de inteligencia artificial, incluyendo modelos lineales, redes neuronales y métodos de similitud entre vectores.

III-J. Cálculo del ángulo entre dos vectores

El ángulo entre dos vectores puede calcularse utilizando el producto punto y las magnitudes de los vectores.

Partiendo de la relación geométrica:

$$x \cdot y = \|x\| \|y\| \cos(\theta)$$

se puede despejar el coseno del ángulo:

$$\cos(\theta) = \frac{x \cdot y}{||x|| ||y||}$$

Finalmente el ángulo se obtiene aplicando la función inversa del coseno:

$$\theta = \cos^{-1} \left(\frac{x \cdot y}{||x|| ||y||} \right)$$

Pasos para calcular el ángulo entre dos vectores

1. Calcular el producto punto $x \cdot y$
2. Calcular las normas $||x||$ y $||y||$
3. Sustituir en la fórmula y despejar el coseno

III-K. Vectores codireccionales

Dos vectores son **codireccionales** si tienen la misma dirección aunque sus magnitudes sean diferentes.

En términos matemáticos, dos vectores u y v son codireccionales si existe un escalar $k \neq 0$ tal que:

$$v = ku$$

donde:

- k es un escalar distinto de cero
- u es un vector
- v es el vector resultante al multiplicar u por el escalar

III-L. Ángulo entre vectores codireccionales

Para determinar el ángulo entre dos vectores codireccionales se sigue el mismo procedimiento utilizado para calcular el ángulo entre vectores:

1. Calcular el producto punto
2. Calcular las normas
3. Usar la identidad del coseno

Si el resultado del ángulo es:

$$\theta = 0$$

entonces los vectores son codireccionales.

III-M. Producto punto de un vector consigo mismo

Si se calcula el producto punto de un vector consigo mismo se obtiene:

$$u \cdot u$$

Sabemos que un vector es codireccional consigo mismo, por lo que el ángulo entre ellos es 0 grados.

$$u \cdot u = ||u|| ||u|| \cos(0)$$

Como:

$$\cos(0) = 1$$

entonces:

$$u \cdot u = ||u||^2$$

III-N. Vectores con ángulo de 90 grados

Si dos vectores forman un ángulo de 90° , el coseno de ese ángulo es:

$$\cos(90^\circ) = 0$$

Por lo tanto:

$$u \cdot v = ||u|| ||v|| \cos(90^\circ)$$

$$u \cdot v = 0$$

Esto significa que cuando el producto punto entre dos vectores es cero, los vectores son perpendiculares.

III-Ñ. Ortogonalidad y ortonormalidad

Ortogonalidad

Dos vectores son ortogonales cuando su producto punto es igual a cero:

$$u \cdot v = 0$$

Esto implica que los vectores forman un ángulo de 90° .

Ortonormalidad

Un conjunto de vectores es ortonormal cuando:

- Los vectores son ortogonales entre sí
- La norma de cada vector es igual a 1

$$||u|| = 1$$

$$||v|| = 1$$

IV. SUPERVISED LEARNING: CONCEPTOS Y TEORÍA

El aprendizaje supervisado es una técnica de aprendizaje automático en la cual un modelo aprende a partir de un conjunto de datos previamente etiquetados. Esto significa que cada ejemplo dentro del conjunto de datos contiene características de entrada y un valor objetivo que el modelo debe aprender a predecir.

Durante el entrenamiento, el modelo analiza la relación entre las características y las etiquetas para poder realizar predicciones sobre nuevos datos.

IV-A. Feature

Una *feature* o característica es una propiedad individual de los datos que describe el problema que se desea analizar. Las características representan la información relevante que el modelo utilizará para aprender patrones dentro del conjunto de datos.

Por ejemplo, en un problema relacionado con vehículos, algunas características podrían ser:

- Peso del vehículo
- Año de fabricación
- Tamaño del motor

Cada una de estas características aporta información que ayuda al modelo a comprender mejor el problema.

IV-B. Vector de Características

Un vector de características es una representación numérica de un ejemplo dentro de un conjunto de datos. Este vector contiene todas las características que describen una instancia específica.

Matemáticamente se representa como:

$$\mathbf{x} = (x_1, x_2, x_3, \dots, x_n)$$

donde:

- $x_1, x_2, \dots, x_n$ representan las características del ejemplo.
- n es el número total de características.

Cada fila dentro de un conjunto de datos puede interpretarse como un vector de características que será utilizado como entrada para el modelo.

IV-C. Label

El *label* o etiqueta es el valor objetivo que el modelo intenta predecir. En aprendizaje supervisado, cada ejemplo del conjunto de datos está asociado con un label.

Las etiquetas pueden ser:

- Valores continuos (por ejemplo, precios o temperaturas).
- Valores discretos o categorías (por ejemplo, tipos de vehículos o clasificación de correos electrónicos).

IV-D. Data Set

Un *data set* es un conjunto organizado de datos que contiene múltiples ejemplos utilizados para entrenar o evaluar un modelo de aprendizaje automático.

Generalmente, un dataset puede representarse como una matriz de datos en la que cada fila corresponde a un ejemplo y cada columna corresponde a una característica.




Figura 2. Ejemplo de un dataset donde cada fila representa un ejemplo, cada columna representa una característica y una fila puede interpretarse como un vector de características que se utiliza como entrada para un modelo de aprendizaje automático.

En la figura se puede observar cómo un conjunto de datos contiene múltiples características (features). A partir de una fila del dataset se forma un vector de características que posteriormente es utilizado como entrada para un modelo de aprendizaje automático.

IV-E. Subcategorías del Aprendizaje Supervisado

El aprendizaje supervisado se divide principalmente en dos tipos de problemas: regresión y clasificación.

IV-E1. Regresión: La regresión es una técnica utilizada para predecir valores numéricos continuos. El objetivo es encontrar una función matemática que se ajuste lo mejor posible a los datos observados.

En este tipo de problema se busca aproximar una función:

$$y = f(x)$$

donde:

- x representa las características de entrada.
- y es el valor que se desea predecir.

Un ejemplo común es la regresión lineal:

$$y = wx + b$$

donde:

- w representa la pendiente de la recta.
- b representa el término de sesgo o *bias*.

La regresión se utiliza para analizar tendencias y realizar predicciones numéricas, como estimar precios de viviendas o predecir temperaturas.




Figura 3. Ejemplo de regresión donde una línea o curva se ajusta a un conjunto de puntos para predecir valores continuos.

IV-E2. Clasificación: La clasificación es una técnica de aprendizaje supervisado cuyo objetivo es asignar una categoría o clase a un conjunto de datos de entrada.

El modelo aprende a partir de ejemplos previamente etiquetados y posteriormente puede predecir la clase correspondiente para nuevos datos.

Por ejemplo, utilizando características como el peso del vehículo, el año de fabricación o el tipo de motor, el modelo puede determinar la categoría del vehículo.

Este tipo de técnica se utiliza ampliamente en problemas como:

- Detección de spam
- Reconocimiento de imágenes
- Diagnóstico médico




Figura 4. Ejemplo de clasificación donde los datos se separan en diferentes categorías o clases.

IV-F. Ejercicios

Ejercicio 1

Basado en datos sobre ratas, tenemos una característica de esperanza de vida y una de obesidad. Estamos intentando encontrar una correlación entre estas dos características. ¿Este problema es de regresión o de clasificación?

Respuesta: Regresión. En este caso se explora la relación entre dos variables: la esperanza de vida es la variable dependiente y la obesidad es la variable independiente. El objetivo es estimar un valor numérico continuo.

Ejercicio 2

Basado en datos sobre animales, disponemos del peso de cada ejemplar y de si tiene alas o no. Estamos tratando de determinar cuáles animales son pájaros. ¿Este problema es de regresión o de clasificación?

Respuesta: Clasificación. El objetivo es asignar una categoría a cada ejemplo (pájaro o no pájaro), por lo que el resultado es una clase discreta.

Ejercicio 3

Basado en datos sobre dispositivos informáticos, contamos con el tamaño de pantalla, el peso y el sistema operativo de varios dispositivos. Queremos determinar cuáles dispositivos son tablets, laptops o teléfonos. ¿Este problema es de regresión o de clasificación?

Respuesta: Clasificación. El modelo debe asignar cada dispositivo a una de varias categorías posibles (tablet, laptop o teléfono).

Ejercicio 4

Basado en datos meteorológicos, tenemos la cantidad de precipitación y un valor de humedad. Queremos determinar la humedad en diferentes épocas del año. ¿Este problema es de regresión o de clasificación?

Respuesta: Regresión. La humedad es una variable numérica continua que se desea predecir a partir de otras variables como la precipitación.