

Semana 3 Clase 1

Emmanuel David Rodríguez Rivas
2023146102
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica

Curso: IC6200 Inteligencia Artificial
Profesor: Ing. Steven Pacheco Portuquez
Fecha: 03/03/2026

Resumen—En este documento se presentan los principales conceptos discutidos durante la clase correspondiente a la semana 3 del curso de Inteligencia Artificial. Inicialmente se revisan las respuestas del Quiz #1, relacionadas con conceptos básicos de aprendizaje automático y optimización. Posteriormente se realiza un repaso de fundamentos de álgebra lineal, incluyendo vectores, normas, distancias y relaciones entre vectores como el producto punto y la ortogonalidad. Finalmente, se repasa el concepto de aprendizaje supervisado.

1. Preguntas del Quiz #1

1.1. Tipos de aprendizaje

En el contexto del aprendizaje automático existen distintos paradigmas dependiendo de la forma en que se estructuran los datos.

Aprendizaje supervisado

En el aprendizaje supervisado se cuenta con un conjunto de datos etiquetados. Cada ejemplo contiene un vector de características X y una etiqueta Y . El objetivo es aprender una función que permita predecir correctamente la salida para nuevos datos.

Aprendizaje no supervisado

En este tipo de aprendizaje no se cuenta con etiquetas asociadas a los datos. El modelo busca identificar patrones o estructuras dentro del conjunto de datos. Un ejemplo común es el agrupamiento o *clustering*.

One-shot learning

El *one-shot learning* es un enfoque donde el modelo aprende a reconocer una categoría utilizando únicamente uno o muy pocos ejemplos de entrenamiento.

1.2. Grid Search

La técnica de *Grid Search* es un método utilizado para seleccionar los mejores hiperparámetros de un modelo de aprendizaje automático.

Consiste en definir un conjunto de posibles valores para cada hiperparámetro y evaluar el desempeño del modelo para todas las combinaciones posibles.

1.3. Solución local y Solución global

En problemas de optimización se distinguen dos tipos de soluciones:

- **Solución local:** corresponde a la mejor solución dentro de una región limitada del espacio de búsqueda.
- **Solución global:** corresponde a la mejor solución considerando todas las posibles soluciones del problema.

En algunos algoritmos es posible encontrar un óptimo local que no representa la mejor solución global.

1.4. Problemas de agrupamiento

Los problemas de agrupamiento o *clustering* consisten en dividir un conjunto de datos en grupos de manera que los elementos dentro de un mismo grupo sean más similares entre sí que con los de otros grupos.

Este tipo de técnicas se utilizan comúnmente en aprendizaje no supervisado.

2. Repaso de Álgebra Lineal

Muchos algoritmos de inteligencia artificial utilizan conceptos de álgebra lineal para representar y manipular datos. Por esta razón se realizó un repaso de algunos conceptos fundamentales.

2.1. Vectores

Un vector es un objeto matemático que posee magnitud y dirección. En un espacio n -dimensional, un vector puede representarse como:

$$x = (x_1, x_2, \dots, x_n)$$

Geoméricamente, un vector puede interpretarse como una flecha que parte desde el origen y apunta hacia un punto específico en el espacio.

2.2. Vector entre dos puntos

Si se tienen dos puntos en el espacio:

$$A = (a_1, a_2, \dots, a_n)$$

$$B = (b_1, b_2, \dots, b_n)$$

el vector que va desde A hasta B se calcula como:

$$u = B - A$$

$$u = (b_1 - a_1, b_2 - a_2, \dots, b_n - a_n)$$

2.3. Magnitud de un vector

La magnitud o norma de un vector representa su longitud.

Para un vector

$$x = (x_1, x_2, \dots, x_n)$$

su magnitud se calcula como:

$$||x|| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

2.4. Distancia Manhattan

La distancia Manhattan entre dos puntos A y B se define como:

$$d(A, B) = \sum_{i=1}^n |a_i - b_i|$$

Esta métrica mide la distancia recorriendo únicamente movimientos horizontales y verticales.

2.5. Distancia Euclidiana

La distancia Euclidiana corresponde a la distancia directa entre dos puntos.

$$d(A, B) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$

Esta es una de las métricas más utilizadas en algoritmos de machine learning.

2.6. Norma de un vector

Una norma es una función que asigna un vector a un número real y cumple tres propiedades fundamentales:

- Positividad

$$||x|| \geq 0$$

- Homogeneidad

$$||\alpha x|| = |\alpha| ||x||$$

- Desigualdad triangular

$$||x + y|| \leq ||x|| + ||y||$$

2.7. Vector unitario

Un vector unitario es aquel cuya magnitud es igual a 1. Dado un vector u , su vector unitario se calcula como:

$$\hat{u} = \frac{u}{||u||}$$

3. Relaciones entre vectores

3.1. Producto punto

El producto punto entre dos vectores se define como:

$$x \cdot y = \sum_{i=1}^n x_i y_i$$

El resultado del producto punto es un escalar.

3.2. Interpretación geométrica

Geoméricamente el producto punto puede expresarse como:

$$x \cdot y = ||x|| ||y|| \cos(\theta)$$

donde θ es el ángulo entre los vectores.

3.3. Cálculo del ángulo entre vectores

A partir de la identidad anterior se puede calcular el ángulo entre dos vectores mediante:

$$\theta = \cos^{-1} \left(\frac{x \cdot y}{||x|| ||y||} \right)$$

3.4. Vectores codireccionales

Dos vectores son codireccionales si existe un escalar k tal que:

$$v = ku$$

En este caso ambos vectores tienen la misma dirección.

3.5. Ortogonalidad

Dos vectores son ortogonales cuando su producto punto es igual a cero:

$$u \cdot v = 0$$

Esto implica que el ángulo entre los vectores es de 90° .

4. Aprendizaje Supervisado

El aprendizaje supervisado es una técnica de machine learning en la cual el modelo aprende a partir de datos previamente etiquetados.

Cada ejemplo del conjunto de datos contiene características de entrada y una etiqueta asociada.

4.1. Feature

Una *feature* o característica es una propiedad medible de los datos.

Ejemplos de características pueden ser:

- Peso de un vehículo
- Tamaño de pantalla
- Intensidad de un píxel en una imagen

4.2. Vector de características

Un vector de características representa numéricamente una instancia del conjunto de datos.

$$x = (x_1, x_2, \dots, x_n)$$

Cada componente del vector corresponde a una característica del ejemplo.

4.3. Label

El *label* es el valor objetivo que el modelo intenta predecir.

Las etiquetas pueden ser:

- Valores continuos (regresión)
- Valores discretos (clasificación)

4.4. Dataset

Un dataset es un conjunto organizado de datos utilizado para entrenar o evaluar modelos.

Generalmente se representa como una matriz donde:

- Cada fila representa un ejemplo.
- Cada columna representa una característica.

4.5. Subcategorías del aprendizaje supervisado

Regresión

La regresión se utiliza para predecir valores numéricos continuos. El objetivo es aproximar una función:

$$y = f(x)$$

Un ejemplo es la regresión lineal:

$$y = wx + b$$

donde w representa la pendiente y b el término de sesgo.

Clasificación

La clasificación busca asignar una categoría a un conjunto de datos de entrada.

Ejemplos de aplicaciones incluyen:

- Detección de spam
- Reconocimiento de imágenes
- Clasificación de vehículos