

Apuntes Semana 4

Apuntes del 10 de marzo de 2026

Steven Sequeira Araya - 2022080836

Inteligencia Artificial

stsequeira@estudiantec.cr

Resumen—En este documento, se resume la clase del 10 de marzo del 2026, en la cual se realizó primeramente un repaso de lo visto en clases anteriores y lecturas (Regresión Lineal y K-Nearest Neighbors). De manera general, este documento recopila información sobre los fundamentos de estos modelos estadísticos, el cálculo del error y repaso de algunas derivadas fundamentales.

Index Terms—K-Nearest Neighbors, Regresión Lineal, Funciones Convexas, Descenso de Gradiente.

I. REPASO DE K-NEAREST NEIGHBORS

Este algoritmo utiliza una métrica de distancia (comúnmente la distancia L_2) para localizar los k puntos más cercanos (vecinos) a una nueva entrada. La clase asignada se determina por mayoría de votos entre esos vecinos. En este modelo, k es el hiperparámetro crítico que define la sensibilidad del algoritmo al ruido o a la estructura de los datos.

I-A. Pasos

1. Cuando llega un nuevo dato (punto de consulta), el algoritmo calcula la distancia entre ese nuevo punto y todos los demás puntos que ya existen en el conjunto de entrenamiento.
2. Una vez calculadas todas las distancias, el algoritmo las ordena de menor a mayor y selecciona los k puntos que estén a la menor distancia del nuevo dato.
3. Finalmente, el algoritmo observa las etiquetas o clases de esos k vecinos seleccionados y realiza una votación por mayoría.

I-B. Ventajas y Desventajas

Ventajas:

- Sencillo de implementar.
- No requiere fase de entrenamiento.
- Intuitivo y fácil de entender.

Desventajas:

- Pesado a nivel computacional.
- Poco eficiente con volúmenes de datos grandes.
- Requiere tener los datos cargados en memoria.

II. MODELO ESTADÍSTICO

Busca describir la relación entre variables observadas mediante la siguiente ecuación:

$$y = f(x) + \varepsilon \quad (1)$$

Donde:

- x = variables de entrada.
- y = variable de salida.
- $f(x)$ = parte sistemática del fenómeno.
- ε = error.

III. REGRESIÓN LINEAL

Es un algoritmo de aprendizaje supervisado que modela la relación entre una variable dependiente (etiqueta) y una o más variables independientes. Su objetivo es encontrar la recta de mejor ajuste calculando sus coeficientes (pendiente e intercepto) de manera que se minimice la diferencia entre los valores reales y las predicciones.

IV. IDEA PRINCIPAL

Construir un modelo que siga la siguiente estructura lineal:

$$f_{w,b}(x) = wx + b \quad (2)$$

Donde:

- w es un vector D -dimensional.
- b es un número real (intercepto).
- y es el modelo $f_{w,b}(x)$.

Se busca encontrar los valores de w y b que hagan la predicción más acertada.

V. MIN SQUARE ERROR (MSE)

Para medir qué tan bien se ajusta el modelo, se define la función conocida como *Loss function* (función de pérdida), que es la medida de penalidad que cuantifica el error de cada ejemplo.:

$$L = \frac{1}{N} \sum_{i=1}^N (f_{w,b}(x_i) - y_i)^2 \quad (3)$$

Esta es la misma ecuación utilizada para la *Cost function* (función de costo). Su objetivo es encontrar el promedio de los errores al cuadrado entre las predicciones del modelo y las etiquetas reales.

El objetivo principal es minimizar L para poder ajustar los parámetros w y b , logrando un modelo lo más preciso posible. Si el valor de L es muy grande, el modelo falla al momento de realizar las predicciones.

En la práctica, se prefiere utilizar el MSE en lugar del MAE (Mean Absolute Error), ya que la función MSE es estrictamente convexa y diferenciable en todo su dominio,

mientras que el MAE no es derivable en el punto donde el error es cero.

Las variables independientes son las características de la muestra, mientras que las dependientes son los valores a predecir y es afectada por las variables independientes.

VI. FUNCIONES CONVEXAS Y NO CONVEXAS

Las funciones convexas tienen la propiedad analítica de contar con un único mínimo global. Mientras que las funciones no convexas pueden presentar múltiples mínimos locales además del mínimo global.



Figura 1. Ejemplo de función convexa.




Figura 2. Ejemplo de función no-convexa.

La definición formal de una función convexa establece que si $f(x)$ posee un mínimo local en $x = c$, entonces se cumple que $f(x) \geq f(c)$ para todo x dentro de un entorno de c .

En este contexto, se utiliza la función L con el objetivo de encontrar ese mínimo global y así lograr la mejor aproximación del modelo. Debido a las propiedades de las funciones convexas, se garantiza que dicho mínimo local encontrado corresponde inevitablemente al mínimo global. La función de costo L del MSE es convexa porque los términos de error se encuentran elevados al cuadrado.

VII. DESCENSO DE GRADIENTE

Es un algoritmo de optimización iterativo utilizado para minimizar la función de pérdida (L). Su objetivo es encontrar los valores de los parámetros que hacen que el error del modelo sea lo más pequeño posible.

VII-A. Pasos del algoritmo

1. Inicializar los parámetros (w y b) con valores aleatorios.
2. Calcular el gradiente de la función de costo respecto a los parámetros.
3. Actualizar los parámetros en dirección opuesta al gradiente iterativamente.

VIII. DERIVADAS BÁSICAS

A continuación, se formalizan las reglas fundamentales de derivación utilizadas al calcular el gradiente, acompañadas de sus respectivos ejemplos:

VIII-A. Derivada de una constante

$$f(x) = c \implies f'(x) = 0 \quad (4)$$

Ejemplo: Si tenemos $f(x) = 8$, su derivada es $f'(x) = 0$.

VIII-B. Constante por función

$$f(x) = c \cdot g(x) \implies f'(x) = c \cdot g'(x) \quad (5)$$

Ejemplo: Si $f(x) = 5x^2$, sacamos la constante y derivamos x^2 , dando como resultado $f'(x) = 5(2x) = 10x$.

VIII-C. Función de grado n (Regla de la potencia)

$$f(x) = x^n \implies f'(x) = n \cdot x^{n-1} \quad (6)$$

Ejemplo: Para $f(x) = x^4$, bajamos el exponente y le restamos uno, obteniendo $f'(x) = 4x^3$.

VIII-D. Suma de funciones

$$f(x) = g(x) + h(x) \implies f'(x) = g'(x) + h'(x) \quad (7)$$

Ejemplo: Dada $f(x) = x^3 + 2x$, derivamos cada término por separado resultando en $f'(x) = 3x^2 + 2$.

VIII-E. Multiplicación de funciones (Regla del producto)

$$f(x) = g(x) \cdot h(x) \implies f'(x) = g'(x)h(x) + g(x)h'(x) \quad (8)$$

Ejemplo: Si $f(x) = (x^2)(e^x)$, aplicando la regla obtenemos $f'(x) = (2x)(e^x) + (x^2)(e^x)$.

VIII-F. Función más constante

$$f(x) = g(x) + c \implies f'(x) = g'(x) \quad (9)$$

Ejemplo: Para $f(x) = x^3 + 15$, la constante desaparece y queda $f'(x) = 3x^2$.

VIII-G. Derivadas multivariantes y parciales

Para una función que depende de múltiples variables $f(x, y, \dots)$, la derivada parcial respecto a x denota la tasa de cambio de la función al variar únicamente x (tratando las demás variables como constantes):

$$\frac{\partial}{\partial x} f(x, y) \quad (10)$$

Ejemplo: Dada la función $f(x, y) = 3x^2y + y^3$. Si calculamos la derivada parcial respecto a x , asumimos que y es constante, resultando en $\frac{\partial f}{\partial x} = 6xy$.

IX. CÁLCULO DE GRADIENTES Y ACTUALIZACIÓN

Para minimizar la función de costo L mediante el descenso de gradiente, es necesario calcular las derivadas parciales respecto a cada parámetro del modelo (w y b). Aplicando la regla de la cadena sobre la función MSE, obtenemos las siguientes expresiones:

IX-A. Cálculo de derivadas de L con respecto a w

La derivada parcial respecto al peso w nos indica la dirección y magnitud del ajuste necesario para este parámetro:

$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=1}^N \frac{\partial}{\partial w} ((wx_i + b) - y_i)^2 \quad (11)$$

Aplicando la regla de la cadena, el exponente baja a multiplicar y se multiplica por la derivada interna (que en este caso es x_i):

$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=1}^N 2(wx_i + b - y_i) \cdot x_i \quad (12)$$

Si definimos la predicción como $\hat{y}_i = wx_i + b$, la fórmula simplificada es:

$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=1}^N 2(\hat{y}_i - y_i)x_i \quad (13)$$

IX-B. Cálculo de derivadas de L con respecto a b

De manera similar, para el intercepto b , la derivada interna es simplemente 1:

$$\frac{\partial L}{\partial b} = \frac{1}{N} \sum_{i=1}^N 2(wx_i + b - y_i) \cdot 1 \quad (14)$$

Lo que resulta en:

$$\frac{\partial L}{\partial b} = \frac{1}{N} \sum_{i=1}^N 2(\hat{y}_i - y_i) \quad (15)$$

IX-C. Regla de actualización de parámetros

Una vez obtenidos los gradientes, los parámetros se actualizan simultáneamente en cada iteración. Se utiliza una constante α denominada *learning rate* (tasa de aprendizaje) para controlar el tamaño del paso hacia el mínimo:

$$w := w - \alpha \frac{\partial L}{\partial w} \quad (16)$$

$$b := b - \alpha \frac{\partial L}{\partial b} \quad (17)$$

Donde el símbolo $:=$ denota una asignación de valor, permitiendo que el modelo aprenda de forma iterativa reduciendo el error en cada paso.