

Apuntes de Clase — Semana 4

IC-6200: Inteligencia Artificial — 10 / Mar / 2026

Allan Bolaños Barrientos - 2024145458

Resumen—This class session reviewed the fundamentals of *K-Nearest Neighbors* (KNN) and introduced essential concepts in statistical modeling and linear regression. We discussed the geometric intuition behind KNN, along with its practical strengths and computational limitations. We then formalized the statistical-modeling view of a target variable as the sum of a systematic component and an error term. Building on this foundation, we studied linear regression, the *Mean Square Error* (MSE) loss function, convexity, and gradient descent as an optimization mechanism. Finally, we reviewed core differentiation rules and partial derivatives to explain how gradients are computed and used to learn model parameters.

Index Terms—K-Nearest Neighbors, statistical model, linear regression, MSE, MAE, convexity, gradient descent, partial derivatives

I. RESUMEN GENERAL DE LA SESIÓN

En clase se trabajaron dos bloques: (i) repaso de KNN y (ii) fundamentos de regresión lineal y optimización. La idea central fue pasar de un método *basado en instancias* (KNN) a un método *basado en parámetros* (modelo lineal), entendiendo cómo se define el error y cómo se minimiza mediante gradiente.

II. REPASO DE K-NEAREST NEIGHBORS (KNN)

KNN es un algoritmo supervisado para clasificación y regresión. Para un nuevo punto x^* , calcula su distancia a todas las muestras de entrenamiento, escoge los k vecinos más cercanos y decide por votación mayoritaria (clasificación) o promedio (regresión).

II-A. Distancia y lógica geométrica

La métrica más usada es la distancia euclidiana:

$$d(x_i, x_j) = \sqrt{\sum_{m=1}^D (x_{im} - x_{jm})^2} \quad (1)$$

El algoritmo funciona bien cuando “cercanía” en el espacio de características implica similitud semántica.

II-B. Selección del hiperparámetro k

- k pequeño: modelo flexible, baja bias y alta varianza (riesgo de sobreajuste).
- k grande: modelo más suave, mayor bias y menor varianza (riesgo de subajuste).

II-C. Ventajas y limitaciones

Ventajas: simple de implementar, no requiere entrenamiento explícito y captura fronteras locales complejas.

Limitaciones: predicción costosa, dependencia de escala de variables, necesidad de almacenar todo el dataset y degradación en alta dimensión.

III. MODELO ESTADÍSTICO Y REGRESIÓN LINEAL

Un modelo estadístico separa estructura y ruido:

$$Y = f(x) + \epsilon \quad (2)$$

En regresión lineal, se aproxima $f(x)$ con una función afín:

$$\hat{y} = f_{w,b}(x) = w^T x + b \quad (3)$$

Aquí w y b son parámetros aprendibles; ϵ recoge variabilidad no explicada.

III-A. Ejemplo visto en clase

Se mostró una relación lineal entre horas de estudio y calificación, con datos representativos como en la Tabla I.

Cuadro I
HORAS DE ESTUDIO VS. CALIFICACIÓN

Horas de estudio (x)	Calificación (y)
1	50
2	55
3	65
4	70
5	75

Una recta de referencia presentada fue:

$$y = 5x + 45 \quad (4)$$

La pendiente (5) indica cuánto sube la calificación por cada hora adicional; el intercepto (45) es la base del modelo.

IV. FUNCIÓN DE PÉRDIDA: MSE Y COMPARACIÓN CON MAE

Para evaluar el ajuste del modelo, se definió la pérdida promedio:

$$L = \frac{1}{N} \sum_{i=1}^N (f_{w,b}(x_i) - y_i)^2 \quad (5)$$

En clase se enfatizó:

- **Loss por ejemplo:** $(f_{w,b}(x_i) - y_i)^2$.
- **Cost function:** promedio de esa pérdida sobre todo el conjunto.
- **Objetivo:** minimizar L para ajustar w, b .

También se comparó MSE con MAE:

$$L_{MAE} = \frac{1}{N} \sum_{i=1}^N |f_{w,b}(x_i) - y_i| \quad (6)$$

MSE es suave y diferenciable en todo punto, lo que facilita gradiente descendente; MAE es menos sensible a outliers pero no es diferenciable en 0.




Figura 1. Comparación geométrica entre MSE y MAE.

V. CONVEXIDAD Y SU IMPORTANCIA

Se discutió que la pérdida cuadrática en regresión lineal induce una superficie convexa respecto a parámetros, por lo que el mínimo local coincide con el mínimo global. Esta propiedad da estabilidad al entrenamiento.

VI. DESCENSO DE GRADIENTE

La actualización de parámetros vista en diapositivas fue:

$$w \leftarrow w - \alpha \frac{\partial L}{\partial w} \quad (7)$$

$$b \leftarrow b - \alpha \frac{\partial L}{\partial b} \quad (8)$$

con α como hiperparámetro de aprendizaje (*learning rate*).

VI-A. Interpretación del learning rate

- α pequeño: pasos cortos y convergencia lenta.
- α grande: sobrepaso del mínimo y posible divergencia.
- α adecuado: descenso estable y rápido.




Figura 2. Efecto de la tasa de aprendizaje en el descenso de gradiente.

VI-B. Ejemplo intuitivo de actualización

Para una función simple $J(x) = x^2$, su gradiente es $\frac{dJ}{dx} = 2x$. Si $x = 1$, el gradiente vale 2 y una regla de actualización es:

$$x_{\text{nuevo}} = x_{\text{antiguo}} - \alpha(2x) \quad (9)$$

Se repite hasta aproximar un punto con gradiente cercano a cero.

VII. REPASO DE DERIVADAS Y DERIVADAS PARCIALES

Antes de optimizar, se repasaron reglas base de derivación:

- Constante: $f(x) = k \Rightarrow f'(x) = 0$.
- Identidad: $f(x) = x \Rightarrow f'(x) = 1$.
- Potencia: $\frac{d}{dx}(x^n) = nx^{n-1}$.
- Multiplicación (regla del producto): $\frac{d}{dx}[u(x)v(x)] = u'(x)v(x) + u(x)v'(x)$.
- División (regla del cociente): $\frac{d}{dx}\left[\frac{u(x)}{v(x)}\right] = \frac{u'(x)v(x) - u(x)v'(x)}{v(x)^2}$, con $v(x) \neq 0$.
- Regla de la cadena: si $y = f(g(x))$, entonces $\frac{dy}{dx} = f'(g(x))g'(x)$.

Para múltiples variables, se usan derivadas parciales: miden cómo cambia una función respecto a una variable, manteniendo las demás constantes.

Si $f(x_1, \dots, x_D)$ depende de varios parámetros, el gradiente se escribe como:

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_D} \right) \quad (10)$$

Ejemplo:

$$f(x, y) = 3x^2y + y^3, \quad \frac{\partial f}{\partial x} = 6xy, \quad \frac{\partial f}{\partial y} = 3x^2 + 3y^2 \quad (11)$$

Estas derivadas parciales forman el gradiente, que guía la dirección de actualización de parámetros en descenso de gradiente.

VIII. CONCLUSIONES

Los contenidos de la clase muestran el puente entre intuición geométrica (KNN), modelado matemático (regresión lineal) y optimización numérica (gradiente descendente). El mensaje central es que entrenar un modelo significa minimizar una función de error con herramientas de cálculo, cuidando la elección de hiperparámetros como k y α .

REFERENCIAS

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.
- [3] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.