

Apuntes Semana 4

Apuntes 12/Mar/2026

1st Fernando Sánchez Hidalgo - 2022218688

Tecnológico de Costa Rica

[IC-6200] Inteligencia Artificial

Abstract—This document summarizes key concepts from a lecture on machine learning and regression models in the Artificial Intelligence course at Tecnológico de Costa Rica. It reviews fundamental topics such as the K-Nearest Neighbor algorithm, statistical models, loss and cost functions, and the use of gradient descent for parameter optimization. The notes also explain training concepts including epochs and batches, as well as different gradient descent approaches: batch, stochastic, and mini-batch gradient descent. Additionally, the document discusses common issues in regression models, including data non-linearity, outliers, and multicollinearity, and presents several techniques to detect and mitigate these problems to improve model performance.

I. REPASO DE LA CLASE ANTERIOR

- K-Neares-Neighbor
 - Implementación fácil
 - Utilización en problemas de regresión y clasificación
 - No apto para datasets grandes
 - difícil de definir un K adecuado

- Modelo Estadístico

$$F_{w,b}(x) = w \cdot x + b \quad (1)$$

- Define la relación matemática entre los datos
- Ajusta los datos bajo una curva (función)
- Queremos optimizar w, b para el mejor ajuste

- Loss function

$$L = \frac{1}{N} \cdot \sum_{i=1}^n (f_{w,b}(x_i) - y_i)^2 \quad (2)$$

- Loss function: Medida de penalidad de errores
- Cost function: Promedio de loss function sobre todo el dataset
- El objetivo es minimizar L
- utiliza la formula de median square error

- Descenso de gradiente

$$x_{nuevo} = x_{viejo} - \alpha \cdot f'(x) \quad (3)$$

- Buscar la dirección de máxima pendiente en una curva y descender en esa dirección
- α : tamaño del paso (usualmente < 1)

- Repaso de derivadas

- Derivada de una constante:

$$f(x) = k$$

$$f'(x) = 0$$

- Derivada de una variable:

$$f(x) = x^n$$

$$f'(x) = n \cdot x^{n-1}$$

- Derivada de un producto entre constante y variable:

$$f(x) = k \cdot x^n$$

$$f'(x) = k \cdot (n \cdot x^{n-1})$$

- Regla de la suma/resta:

$$f(x) = x$$

$$g(x) = x$$

$$(f(x) \pm g(x))' = f'(x) \pm g'(x)$$

- Regla del producto:

$$f(x) = x$$

$$g(x) = x$$

$$(f(x) \cdot g(x))' = f'(x) \cdot g(x) + f(x) \cdot g'(x)$$

- Regla de la cadena:

$$f(x) = x$$

$$g(x) = x$$

$$(f(g(x)))' = f'(g(x)) \cdot g'(x)$$

- Derivadas parciales de loss function


$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=1}^N 2((w \cdot x_i + b) - y_i) \cdot x_i$$

$$\frac{\partial L}{\partial b} = \frac{1}{N} \sum_{i=1}^N 2((w \cdot x_i + b) - y_i)$$

II. ITERACIONES DE ENTRENAMIENTO

A. Epoch

Epoch o Época es un hiperparametro que representa una iteración de entrenamiento y optimización de parámetros. La cantidad definidas de épocas depende del modelo y datos a utilizar.




Idealmente, a medida que se realizan más épocas, la pérdida decrementa.

B. Batch

El batch es un subconjunto (lote) de todos los datos del dataset, esto es utilizado cuando la cantidad de datos es mucha para procesar todos al mismo tiempo o cuando se realizan calculos sobre formatos pesados (Ej: imágenes o videos). El hiperparámetro del batch representa cuantos samples de los datos se van a tomar en un batch.

Ej: Si tenemos 10 000 samples, podemos definir un batch de 1000, esto significa que la procesar 10 batches, se completa un epoch.

III. DESCENDENCIA DE GRADIENTE POR BATCHES



Fuente: GeeksForGeeks

A. Batch Gradient Descent

Este proceso calcula el error por cada sample que se realiza en el training, pero ajusta y optimiza el modelo unicamente cuando termina el epoch.

- + Más estable que otros métodos
- Requiere todo el dataset en memoria (poco útil en datasets grandes)
- Convergencia lenta

B. Stochastic Gradient Descent

Calcula, ajusta y optimiza el modelo por cada sample que se calcula.

- + Convergencia rápida
- + No requiere todo el dataset en memoria
- Gradiente inestable, cambios bruscos en el modelo
- Ineficiente, se realizan muchas operaciones por sample

C. Mini-Batch Gradient Descent

Optimiza el modelo al finalizar el batch de datos


- + Evita mínimos locales
- Computacionalmente eficiente
- Requiere hiperparámetro del tamaño de batch

IV. POTENCIALES PROBLEMAS EN MODELOS DE REGRESIÓN

A. No linealidad de los datos

Fuente: GeeksForGeeks

Siempre partimos del supuesto que el modelo es lineal, pero existen casos donde los datos no se pueden ajustar con un



modelo lineal, en estos casos, los errores sistemáticos por sample son muy grandes. Existen casos donde es posible agregar nuevos features al modelo para mejorar el ajuste.

Solución: Aumentar el grado de los polinomios del modelo


Ej:

Modelo inicial: $m_1 = \beta_0 + \beta_1 \cdot hp + \epsilon$

Modelo arreglado: $m_2 = \beta_0 + \beta_1 \cdot hp + \beta_2 \cdot hp^2 + \epsilon$

B. Outliers

Los datos outliers, son datos atípicos que no se comportan como el resto del dataset, estos modifican la función de ajuste incorrectamente.



Fuente: GeeksForGeeks

Soluciones:

- 1) Standardized residual: Se busca escalar el residuo sobre una desviación estándar global.

$$e_i = y_i - \hat{y}_i \quad (4)$$

$$SSE = \sum_{i=1}^n (e_i)^2 \quad (5)$$

$$\hat{\sigma} = \sqrt{\frac{SSE}{n-p}} \quad (6)$$

$$z_i = \frac{e_i}{\hat{\sigma}} \quad (7)$$

Donde:

y_i = resultado estimado

$\hat{y}_i$ = label del resultado

n = total de observaciones

p = números de parámetros estimados

$|z_i| > 2 \rightarrow$ posible outlier

$|z_i| > 3 \rightarrow$ muy probable outlier

2) Regla de rango intercuartilico

$$IQR = Q_3 - Q_1 \quad (8)$$

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR] \quad (9)$$

Donde:

valores $< Q_1 - 1.5 \cdot IQR$ son outliers inferiores

valores $> Q_3 + 1.5 \cdot IQR$ son outliers superiores

3) Winsorization: Reemplazar valores extremos por el valor en el percentil.

valores $< 5\% \rightarrow$ reemplazar por valor en percentil 5%

valores $> 95\% \rightarrow$ reemplazar por valor en percentil 95%

Ej:

Percentil 5% = \$500

Percentil 95% = \$15 000

Los valores menores a \$500 se reemplazan por \$500, valores mayores a \$15 000, son reemplazados por \$15 000

C. Colinealidad

La colinealidad es un caso donde dos o más variables independientes están altamente relacionadas, esto causa redundancia y dificulta visualizar como cada una de estas afecta el resultado final.

Formas de identificar colinealidad:

- 1) Variance Inflation Factor: Demuestra cuanto la varianza de un coeficiente de regresión incrementa por la correlación con otras variables independientes

$$VIF_i = \frac{1}{1 - R^2} \quad (10)$$

Donde R^2 es la proporción de varianza total de una variable

- 2) Gráfico de dispersión por pares: Realizar un gráfico de comparación entre las variables para identificar patrones de linealidad entre ellos

Soluciones:

- 1) Eliminar variables redundantes
- 2) Combinar variables en un solo feature
- 3) Regresiones de Ridge o Lasso
- 4) Utilizar más features y/o recolectar más datos

Fuente: GeeksForGeeks