

Apuntes Semana 4 [Jueves]

Curso: IC6200 Inteligencia Artificial

Clase del 12 de marzo de 2026

Jose David Chaves Mena - 2024072126

Tecnologico de Costa Rica
Escuela de Ingenieria en Computacion
Profesor: Steven Pacheco Portuguez
Fecha: 12 de marzo de 2026

Abstract

En este documento se presentan los conceptos fundamentales vistos en la semana 04, incluyendo un repaso de limitaciones del algoritmo K-Nearest Neighbors (KNN), introducción al aprendizaje estadístico, regresión lineal, funciones de costo y métodos de optimización como el descenso del gradiente. Además, se abordan problemas comunes como la no linealidad y la presencia de valores atípicos (outliers), junto con sus posibles soluciones.

1. Introducción (noticias y repaso)

Durante esta semana se discutieron avances recientes en inteligencia artificial, incluyendo incrementos en los costos de herramientas como GitHub Copilot y modelos avanzados. Posteriormente, se realizó un repaso del algoritmo KNN y se introdujeron modelos estadísticos como alternativa más robusta.

1.1. Limitaciones de KNN

El algoritmo K-Nearest Neighbors (KNN), aunque sencillo de implementar, presenta varias limitaciones:

- Dificultad para seleccionar un valor adecuado de K
- Ineficiencia en grandes volúmenes de datos
- No es un modelo de aprendizaje activo

NOTA.: KNN es considerado un modelo de *lazy learning*, ya que no requiere una fase explícita de entrenamiento, sino que compara directamente los datos.

1.2. Modelos Estadístico

Los modelos estadísticos buscan ajustar parámetros para representar relaciones entre variables, estos suelen estar descritos por.:

$$Y = f(X) + \varepsilon \quad (1)$$

Donde:

- X : Variables de entrada
- Y : Variable de salida
- $f(X)$: parte sistémica del fenómeno (corresponde al patrón encontrado que el modelo puede explicar).
- ε : error o variabilidad no explicada (diferencia entre el valor esperado y el valor real).

1.3. Regresión Lineal

Busca asociar y predecir los valores de cualquier Y_i dado un valor de X_i .




Figure 1: Datos de entrenamiento y línea de regresión

En este caso, se puede decir que Y_i es una variable dependiente y X_i la variable independiente.

Dado un problema que se pueda representar linealmente, se busca construir el siguiente modelo.:

$$f_{w,b}(x) = w \cdot x + b \quad (2)$$

Donde:

- x : Vector D-dimensional de entrada
- w : Vector D-dimensional de pesos
- b : Bias (es un numero real)

RECORDAR.: El producto punto se define como:

$$w \cdot x = \sum_{i=1}^D w_i x_i \quad (3)$$

A partir de esto, se busca encontrar los valores óptimos para los parámetros w y b que permitan que la función retorne las predicciones más acertadas.

1.4. Función de Costo

Permite cuantificar qué tan bien o mal se ajusta nuestro modelo a los datos de entrenamiento. Para evaluar el modelo se utiliza la función de pérdida.:

$$L = \frac{1}{N} \sum_{i=1}^N (f_{w,b}(x_i) - y_i)^2 \quad (4)$$

El objetivo es minimizar esta función ajustando los parámetros w y b .

1.5. Descenso del Gradiente

El descenso del gradiente es un método iterativo para minimizar la función de costo.

Para acercarnos al mínimo, nos movemos en la dirección en la que decrece el gradiente negativo, con un paso que usualmente es denominado α , el cual es un hiperparámetro (learning rate).

Derivadas parciales de la función de pérdida

$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=1}^N 2((w \cdot x_i + b) - y_i) x_i$$

$$\frac{\partial L}{\partial b} = \frac{1}{N} \sum_{i=1}^N 2((w \cdot x_i + b) - y_i)$$

Actualización de los parámetros

$$w = w - \alpha \frac{\partial L}{\partial w}$$

$$b = b - \alpha \frac{\partial L}{\partial b}$$

Donde.: α es la tasa de aprendizaje.

1.6. Ejemplo de descenso del gradiente




Figure 2: Convergencia hacia el mínimo

2. Epochs

Epoch: es un hiperparámetro que representa una iteración completa a través de todo el conjunto de datos de entrenamiento. Su objetivo es disminuir el error (loss) a través de cada iteración.





Figure 3: Disminución del error con las epochs

Idealmente, a medida que se realizan más epochs, el error disminuye. Sin embargo, usualmente existe un límite en la efectividad de cada iteración, por lo cual llega un punto en el que no se considera positivo seguir iterando.



3. Batch (lotes)


Esto suele utilizarse cuando la cantidad de datos es muy grande para procesar todos al mismo tiempo, o cuando se realizan cálculos sobre formatos pesados, como imágenes. Dentro del gradiente del batch suelen darse las siguientes situaciones.:

3.1. Tipos de Gradient Descent

A. Batch Gradient Descent: Este método calcula el error utilizando todo el conjunto de datos y actualiza los parámetros únicamente al finalizar cada *epoch*. Es más estable al representar mejor el gradiente global, pero requiere cargar todo el dataset en memoria y su convergencia es lenta en conjuntos de datos grandes.

B. Stochastic Gradient Descent: El *Stochastic Gradient Descent* actualiza los parámetros después de evaluar cada muestra individual. Esto permite una convergencia más rápida y reduce el uso de memoria, aunque introduce inestabilidad debido a la alta variabilidad del gradiente y puede generar cambios bruscos en el modelo.


C. Mini-Batch Gradient Descent: El *Mini-Batch Gradient Descent* actualiza el modelo utilizando pequeños subconjuntos de datos. Ofrece un equilibrio entre estabilidad y eficiencia computacional, reduciendo la variabilidad del gradiente, aunque requiere definir el tamaño del batch como hiperparámetro.



4. Problemas Comunes

4.1. No Linealidad

La no linealidad ocurre cuando la relación que existe entre las variables de un conjunto de datos no es lineal.



Hasta ahora, uno de los supuestos principales en regresión lineal ha sido que existe linealidad entre las variables predictoras y la variable de respuesta. Sin embargo, no siempre es el caso, y un ajuste lineal simple puede resultar insuficiente para capturar la tendencia real de los datos.

Soluciones propuestas.: Para manejar este problema, se puede extender el modelo lineal incorporando transformaciones polinómicas y agregando nuevas características (*features*) que mejoren la linealidad del problema.

Modelo inicial:

$$m_1 = \beta_0 + \beta_1 \cdot h$$

Modelo extendido:

$$m_2 = \beta_0 + \beta_1 \cdot h + \beta_2 \cdot h^2$$

En este caso, h^2 se convierte en un nuevo *feature*. Este proceso se conoce como *feature engineering*, que consiste básicamente en introducir nuevas características al modelo para mejorar su capacidad de ajuste y reducir el error.

4.2. Outliers

Los datos sobresalientes o *outliers* son datos que se comportan de manera atípica en comparación con el resto del conjunto de datos.




Figure 4: Presencia de valores atípicos

El problema de los outliers es que pueden influir desproporcionadamente en la pendiente de la recta de regresión y en la estimación de los parámetros del modelo. Para manejarlos, existen varias soluciones:

- **Residuos estandarizados (Standardized Residuals)**

- Permite poner todos los residuos en la misma escala para poder compararlos.
- Fórmula:

$$z_i = \frac{e_i}{\hat{\sigma}}, \quad \hat{\sigma} = \sqrt{\frac{SSE}{n-p}}$$

- Donde:
 - * n = total de observaciones
 - * $e_i = y_i - \hat{y}_i$ = residuo de la observación i
 - * p = número de parámetros estimados
- Aplicación práctica:
 - * $|z_i| > 2 \rightarrow$ posible outlier
 - * $|z_i| > 3 \rightarrow$ muy probable outlier (se recomienda excluir o analizar cuidadosamente)

- **Rango intercuartílico (Interquartile Range, IQR)**

- Mide la dispersión de los datos centrales.
- Fórmula del rango intercuartílico:

$$IQR = Q_3 - Q_1$$

- Regla para identificar outliers:

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$$

- Interpretación:
 - * Valores $< Q_1 - 1.5 \cdot IQR \rightarrow$ outliers inferiores
 - * Valores $> Q_3 + 1.5 \cdot IQR \rightarrow$ outliers superiores

- **Winsorización (Winsorization)**

- No elimina los valores extremos, sino que los reemplaza por los percentiles límite.
- Procedimiento:
 1. Elegir los percentiles de corte inferior y superior.
 2. Los valores menores al percentil inferior se redondean a ese valor; los valores mayores al percentil superior se redondean de manera análoga.
- Ventajas:
 - * Conserva el tamaño de la muestra.
 - * Reduce la influencia de valores extremos en el modelo.