

Semana 5

Kendell Garbanzo Calvo — 2022123716

Instituto Tecnológico de Costa Rica

IC-6200 Inteligencia Artificial

Apuntes 17 de marzo, 2026

I. REPASO DE LA CLASE ANTERIOR

I-A. Regresión Lineal

La regresión lineal modela la relación entre las variables de entrada y la variable objetivo mediante la expresión:

$$\hat{y} = \mathbf{w}x + b \quad (1)$$

donde $\mathbf{w}$ son los pesos y b el sesgo (*bias*). Ambos parámetros se actualizan durante el entrenamiento mediante algoritmos de optimización basados en gradiente.

I-B. Métodos de Descenso de Gradiente

I-B1. Batch Gradient Descent (BGD): Calcula el gradiente usando **todo el conjunto de datos** antes de actualizar los parámetros. Su convergencia es estable ya que el gradiente estimado es preciso; sin embargo, puede estabilizarse cerca del óptimo en lugar de alcanzarlo exactamente. Sus principales limitaciones son:

- Requiere cargar el dataset completo en memoria.
- Converge lentamente con datasets de gran tamaño.

I-B2. Stochastic Gradient Descent (SGD): Actualiza los pesos **después de cada muestra** del conjunto de entrenamiento. Si bien responde rápidamente a cada observación, su varianza alta genera trayectorias ruidosas. Además, resulta computacionalmente costoso para modelos de gran escala, dado el volumen de actualizaciones que se realizan.

I-B3. Mini-Batch Gradient Descent: Representa una combinación entre BGD y SGD: divide el dataset en **lotes** (*batches*) de tamaño fijo, calcula el error sobre cada lote y actualiza los parámetros antes de pasar al siguiente. Sus ventajas son:

- Evita mínimos locales con mayor robustez que BGD.
- Más eficiente computacionalmente que SGD puro.

Su costo adicional es la necesidad de definir el **tamaño del batch** como hiperparámetro extra.

I-C. Problemas Comunes en Regresión Lineal

I-C1. No Linealidad en la Relación Predictor–Respuesta: La regresión lineal asume que la relación entre los *features* x y la etiqueta y es lineal. Cuando esto no se cumple, se aplica **ingeniería de características** (*feature engineering*): se generan transformaciones polinómicas del predictor original:

$$x, x^2, x^3, \dots, x^d \quad (2)$$

permitiendo capturar relaciones no lineales sin abandonar el marco lineal en los parámetros.




Figura 1. Comparación de residuos con predictor lineal (izquierda) vs. predictor al cuadrado (derecha).

Como ejemplo ilustrativo, al modelar el **consumo de gasolina** en función de la potencia del motor, la comparación entre un modelo de grado 1, grado 2 y grado 5 muestra que el modelo de grado 2 obtiene el mejor ajuste, evitando tanto el *underfitting* del modelo lineal como el *overfitting* del modelo de grado 5.




Figura 2. Comparación de modelos de grado 1, 2 y 5 para el consumo de gasolina en función de la potencia del motor.

I-C2. Datos Atípicos (Outliers): Los outliers son observaciones con errores inusualmente grandes. Al calcular el promedio del error, estos datos reducen artificialmente la métrica sobre ellos mismos pero aumentan el error sobre el resto del dataset. Se tienen las siguientes técnicas de tratamiento:

I-C2a. Residuales Estandarizados: Los residuos crudos $e_i = y_i - \hat{y}_i$ se normalizan respecto a la desviación estándar del error:

$$z_i = \frac{e_i}{\hat{\sigma}}, \quad \hat{\sigma} = \sqrt{\frac{SSE}{n-p}} \quad (3)$$

donde n es el número total de observaciones y p el número de parámetros estimados en el modelo. Se considera outlier si $|z_i| > 2$ o $|z_i| > 3$.

I-C2b. Regla del Rango Intercuartílico (IQR): Se calculan el percentil 25 (Q_1) y el percentil 75 (Q_3):

$$IQR = Q_3 - Q_1 \quad (4)$$

Los datos fuera de $[Q_1 - 1,5 IQR, Q_3 + 1,5 IQR]$ se consideran outliers y son eliminados.

I-C2c. Winsorización: En lugar de eliminar los datos atípicos, se **reemplazan** por los valores de los percentiles límite (típicamente el 5 % y el 95 %). Esto preserva el tamaño del dataset mientras reduce el impacto de los extremos.

II. SESGO Y VARIANZA

Al trabajar con un conjunto de datos, usualmente no se entrena el modelo con todos los elementos disponibles. El dataset se divide en dos fases principales: **entrenamiento** y **prueba** (*testing*), con una partición típica de 80 %–20 %. En el conjunto de testing se reservan datos que el modelo no ha visto, permitiendo evaluar su comportamiento real.

Un modelo es considerado bueno cuando produce buenos resultados sobre el set de evaluación. Los posibles escenarios son:

- Buen desempeño en entrenamiento, mal desempeño en testing.
- Mal desempeño en entrenamiento y también en testing.
- Mal desempeño en entrenamiento, buen desempeño en testing (poco probable).

III. TRAINING SET

El training set se utiliza para ajustar los parámetros del modelo, permitiéndole encontrar patrones en los datos. Una vez entrenado, el modelo debería ser capaz de predecir correctamente resultados con datos nuevos.

Se debe evitar el **overfitting**, que ocurre cuando el modelo se ajusta en exceso a los datos de entrenamiento, aprendiendo no solo el patrón subyacente sino también el *ruido* (variaciones aleatorias e irregularidades propias del conjunto de entrenamiento). Como consecuencia, el modelo presenta un rendimiento alto sobre los datos de entrenamiento pero pierde capacidad de **generalización**, produciendo predicciones poco confiables ante datos nuevos no vistos durante el entrenamiento.

IV. TESTING SET

El testing set se usa exclusivamente para **evaluar** el modelo y nunca para entrenarlo; debe ser independiente del training set. Simula la aplicación de un examen al modelo. Sobre él se calculan métricas de rendimiento como *accuracy* y *loss*, siendo estas las métricas relevantes para determinar si un modelo es viable.

Objetivo: crear un modelo que generalice adecuadamente a todos los escenarios, medido de forma realista con datos que nunca ha visto, lo que hace posible una comparación objetiva.

IV-A. Caso de Overfitting

Se inicia el entrenamiento del modelo capturando métricas del training set: se obtiene buen *accuracy* y la función de *loss* disminuye. Tras varios días de entrenamiento, al ejecutar el testing set el resultado evidencia overfitting. Cabe recalcar que el tiempo de entrenamiento podría ser considerablemente mayor, lo que hace esta situación especialmente costosa.

V. VALIDATION SET

Conjunto de datos que sirve para valorar la capacidad de generalización del modelo con datos nunca vistos **durante el entrenamiento**. Los resultados del validation set permiten tomar decisiones sobre el proceso de entrenamiento y es esencial para el **ajuste de hiperparámetros**.

En cada iteración se ejecuta un mini-examen con datos del validation set, permitiendo detectar overfitting de forma temprana. Estos datos se obtienen partiendo una porción del training set original.

V-A. Técnicas de Subdivisión del Dataset

V-A1. Random Sampling: División completamente aleatoria del dataset. Útil cuando los datos están balanceados (ej. igual cantidad de ejemplos por clase). Si los datos no están balanceados, algunas clases podrían quedar subrepresentadas, afectando la capacidad predictiva del modelo.

V-A2. Stratified Sampling: Usado para datos desbalanceados. Asegura representación de todas las clases en cada subconjunto, manteniendo la misma distribución proporcional. Produce modelos más robustos.

V-A3. K-Fold Cross-Validation: Se utiliza cuando se dispone de poca data. Divide el dataset en K partes; en cada iteración se entrena con $K - 1$ partes y se valida con la parte restante, rotando los subconjuntos hasta cubrir todas las combinaciones posibles.

VI. POSIBLES ESCENARIOS

VI-A. Bajo error en training, bajo error en validation

Escenario ideal. El modelo evita el ruido y generaliza correctamente.





Figura 3. Escenario ideal: bajo error en training y validation.

VI-B. Bajo error en training, alto error en validation

Overfitting. El modelo no generaliza; presenta alta varianza entre los resultados de training y validation.



Mini-Batch Gradient Descent en al menos 10 ejecuciones con distintos hiperparámetros, reportando MSE y detectando overfitting. La entrega incluye un informe en $\text{\LaTeX}$ formato IEEE y un Jupyter Notebook, empacados en un .zip.

Figura 4. Overfitting: el error de validación diverge mientras el de entrenamiento sigue disminuyendo.

VI-C. Alto error en training, alto error en validation

Underfitting. El modelo no aprende de los datos; es demasiado simple y presenta alto sesgo (*bias*).




Figura 5. Underfitting: ambas curvas convergen en un valor de error elevado.

VII. BIAS-VARIANCE TRADEOFF

Se busca un modelo con **bajo sesgo** y **baja varianza**.

VII-A. Alto Sesgo (High Bias)

Indica underfitting: el modelo comete muchos errores en el training set, asume demasiado sobre los datos, no aprovecha todos los *features* disponibles y es excesivamente simple. Para reducirlo:

- Utilizar un modelo más complejo.
- Revisar que los features sean adecuados para el problema.

VII-B. Alta Varianza (High Variance)

Indica overfitting: el modelo se ajusta en exceso a los datos de entrenamiento, es sensible a variaciones y no generaliza. Suele ocurrir con datos de alta dimensionalidad y pocos ejemplos de entrenamiento. Para reducirla:

- Usar un modelo más simple.
- Reducir la dimensionalidad o la cantidad de features.
- Obtener más ejemplos de entrenamiento (no siempre posible).
- Aplicar técnicas de **regularización**.

VIII. TAREA

La tarea asignada consiste en implementar un modelo de regresión lineal desde cero usando únicamente NumPy y Pandas, aplicado al dataset *Student Performance Prediction* de Kaggle. Se deben comparar Batch Gradient Descent y