

# Inteligencia Artificial Semana 5

Julian Lopez Mata - 2022207831  
IC-6200 Inteligencia Artificial  
17 de Marzo de 2026

## I. RESUMEN CLASE JUEVES 12 DE MARZO

### I-A. Tipos de Gradient Descent

**I-A1. Batch Gradient Descent:** Corresponde al enfoque clásico de la regresión lineal. En este método, se consideran todos los errores del conjunto de datos y se realiza una optimización global al final del proceso. Presenta una convergencia estable y un gradiente consistente.

Desventajas:

- Debido a la estabilidad del gradiente, puede converger a parámetros no óptimos.
- Requiere que el dataset completo esté cargado en memoria.
- Su desempeño es lento cuando se trabaja con grandes volúmenes de datos.

**I-A2. Stochastic Gradient Descent:** Este método actualiza los parámetros del modelo por cada muestra individual, lo que lo hace especialmente útil en datasets de gran tamaño.

Desventajas:

- Presenta mayor complejidad computacional.
- Genera gradientes ruidosos, lo que puede afectar la estabilidad del entrenamiento.

**I-A3. Mini Batch Gradient Descent:** Se trata de un enfoque híbrido entre Batch y Stochastic Gradient Descent, el cual permite evitar mínimos locales y mejorar la robustez del modelo. Además, es más eficiente computacionalmente que el enfoque estocástico puro.

Desventaja:

- Introduce un hiperparámetro adicional: el tamaño del batch.

### I-B. Problemas Potenciales con Regresión Lineal

#### I-B1. No linealidad de la relación respuesta predictor:

En la regresión lineal se asume la existencia de una relación lineal entre las variables predictoras y la variable respuesta. Sin embargo, esta suposición no siempre se cumple.

- En estos casos, el modelo lineal no logra capturar adecuadamente la relación entre variables.
- Se generan errores sistemáticos en los residuos:

$$e_i = y_i - \hat{y}_i \quad (1)$$

donde  $y_i$  representa el valor real y  $\hat{y}_i$  la predicción del modelo.




Figura 1. Ejemplo de un modelo lineal aplicado a datos cuadráticos.

La solución ante el problema es emplear regresión polinómica, extendiendo el modelo lineal mediante la incorporación de transformaciones polinómicas del predictor.

**I-B2. Outliers:** Los outliers son datos atípicos que se desvían significativamente de la distribución general. Estos pueden afectar negativamente el ajuste del modelo, ya que este intentará minimizar el error asociado a dichos puntos, incrementando el error en el resto de los datos.




Figura 2. Impacto de los outliers en el modelo (línea punteada).

¿Cómo se tratan los outliers?

- **Standardized residuals:** Escalar el residuo mediante una desviación estándar global de los errores.
- **Regla del Rango Inter cuartílico (IQR):** Determinar los percentiles 25 y 75 para establecer un rango válido de datos.
- **Winsorización:** Sustituir valores extremos por percentiles límite (por ejemplo, 5 % y 95 %), en lugar de eliminarlos.

## II. SESGO Y VARIANZA

**II-1. Dataset:** Al trabajar con un conjunto de datos, es común dividirlo en dos subconjuntos: entrenamiento (train) y prueba (test). El conjunto de prueba se reserva para evaluar el desempeño del modelo con datos no vistos previamente.

Si el modelo presenta un buen rendimiento en el conjunto de prueba, se puede inferir que posee una adecuada capacidad de generalización.

**II-2. Training set:** Se utiliza para ajustar los parámetros del modelo a partir de las muestras disponibles. Durante este proceso, el modelo identifica patrones en los datos de entrada y salida, permitiéndole realizar predicciones sobre datos no observados previamente.

Un ajuste excesivo al conjunto de entrenamiento puede provocar *overfitting*, donde el modelo se especializa en exceso y pierde capacidad de generalización.

**II-3. Testing set:** Este conjunto se emplea exclusivamente para evaluar el modelo y no debe ser utilizado durante el entrenamiento. Debe mantenerse completamente independiente del conjunto de entrenamiento.

En esta fase se calculan métricas de desempeño como *accuracy* y *loss*, con el objetivo de evaluar la capacidad de generalización del modelo.

## III. VALIDATION SET

El validation set es un subconjunto de datos utilizado para evaluar la capacidad de generalización del modelo durante el entrenamiento, antes de la fase de testing.

En cada época, el modelo es evaluado mediante este conjunto, lo que permite ajustar hiperparámetros y tomar decisiones durante el proceso de entrenamiento.

### III-A. Técnicas para subdividir el Dataset

**III-A1. Random Sampling:** Consiste en dividir el dataset de manera aleatoria. Es adecuado cuando las clases están balanceadas. Sin embargo, en datasets desbalanceados, puede ocurrir que la clase minoritaria no esté correctamente representada.

**III-A2. Stratified Sampling:** Se utiliza en datasets desbalanceados. Garantiza que la distribución de clases se mantenga constante en cada subconjunto.

**III-A3. K-fold Cross-Validation:** Se emplea cuando la cantidad de datos es limitada. El dataset se divide en  $k$  subconjuntos, utilizando  $k - 1$  para entrenamiento y uno para validación. Este proceso se repite rotando los subconjuntos.



Figura 3. Ejemplo de K-fold Cross-Validation.

## IV. POSIBLES ESCENARIOS EN TRAINING Y TESTING

### IV-1. Bajo error en training, bajo error en testing:

- Representa el escenario ideal.
- El modelo evita ajustarse al ruido.
- Presenta una adecuada capacidad de generalización.




Figura 4. Caso ideal de entrenamiento y prueba.

### IV-2. Bajo error en training y alto error en testing:

- Indica overfitting.
- El modelo no logra generalizar adecuadamente.
- Presenta alta varianza.



Figura 5. Ejemplo de overfitting.

### IV-3. Alto error en training y alto error en testing:

- Corresponde a un caso de underfitting.
- El modelo no logra aprender de los datos.
- Es excesivamente simple.
- Presenta alto sesgo.




Figura 6. Ejemplo de underfitting.

## V. BIAS VARIANCE TRADEOFF

El objetivo es obtener un modelo que minimice tanto el sesgo como la varianza.

### V-1. *Alto Bias:*

- El modelo comete numerosos errores en el conjunto de entrenamiento (underfitting).
- Se basa en supuestos excesivamente simplificados.
- Corresponde a un modelo de baja complejidad.

#### ¿Cómo evitar un alto bias?

Incrementar la complejidad del modelo y utilizar variables (features) más representativas.

### V-2. *Alta Varianza:*

- El modelo se ajusta excesivamente al conjunto de entrenamiento (overfitting).
- No logra generalizar a nuevos datos.
- Es común en escenarios de alta dimensionalidad con pocos ejemplos.

#### ¿Cómo evitar una alta varianza?

Reducir la complejidad del modelo, disminuir la dimensionalidad o incrementar la cantidad de datos de entrenamiento.