

Apuntes Semana 5

*Apuntes del 19/03/2026

2nd José Jiménez
IC-6200 Inteligencia Artificial
Tecnológico de Costa Rica
Cartago, Costa Rica
josegab18@estudiantec.cr

I. REPASO

A. Formas de muestreo

Los ejemplos de muestras mas comunes que son el random, stratified y el k-fold cross-validation.

Con el **estratificado** se trata de mantener las proporciones de las clases que existan siempre y cuando sean desbalanceadas; si fuesen balanceadas, lo que sería un problema de clasificación con dos clases específicas, en donde el 50% de la muestra es para cada clase, lo ideal sería usar el muestreo **aleatorio** para usarlos en los sets de entrenamiento, validación y testeo.

Hacerlo con clases desbalanceadas, puede no ser lo mejor, ya que solamente podría representarse una clase en un grupo, por lo que el algoritmo daría datos erróneos en los resultados, entonces **lo mejor** es tratar las clases **desbalanceadas**.

Técnicas de **manejo de datos imbalanceados**:

- Hacer un corte de muestras de la clase mayoritaria.
- Muestreo extra.
- Generar datos sintéticos para generar muestras de la clase mayoritaria.

Es buena práctica usar el **k-fold cross-validation**, este divide los datos de entrenamiento en partes, los cuales se rotan, es decir, si uno se usó para validar luego se usará para entrenar, etc.

B. Entrenamiento del modelo

Dividir el data set en **80% entrenamiento** y **20% testeo** Datos que optimizarán los pesos(u's y v's asociadas a la función lineal) del modelo.

Modelos de aprendizaje supervisado con parámetros de entrenamiento, entrenados por medio del descenso de gradiente, se optimizan los parámetros en base a los datos de entrenamiento.

Datos de testeo sirven para hacerle como un "examen" con datos no usados, simulando datos productivos, esto para **evaluar la capacidad de generalizar** la solución con respecto a datos que no existen en el set de entrenamiento.

Overfitting: sobre ajuste que tiene el modelo o en el set de entrenamiento, es tanto el sobre ajuste que aprende el ruido(información incorrecta, relevante o aleatoria) de las muestras.

El ruido que contienen las muestras puede darse por **la medición de datos, condiciones a la hora de realizar las mediciones, etc**, siempre se alejan un poco de la realidad.

Si los datos contienen errores de algún tipo, en el entrenamiento el modelo se ajustará al error, por lo que el modelo termina perdiendo generalización.

Después de testear, se toman métricas para ver que tan bien sirve con datos nuevos. **Para evitar overfitting**, se usa el set de validación, que se ejecuta cada "x" tiempo que se defina.

Posibles escenarios:

- **Bajo error** en entrenamiento y **bajo error** en pruebas.
- Escenario ideal
- Modelo evita ruido de los datos
- Generaliza correctamente

Lo normal es que los sets de **entrenamiento y validación decrezcan constantemente**, generalmente el de validación tiene más error.




Fig. 1. Caso normal

- **Bajo error** en entrenamiento, **alto error** en validación.
- Overfitting
- No generaliza
- Alta varianza
- **Alto error** en entrenamiento y **alto error** en validación
- Underfitting(malo en todo)
- Modelo muy simple
- Alto sesgo

C. Compensación Bias-Varianza

- Si aumenta la varianza, el bias disminuye y viceversa.
- Ocupamos un intermedio tal que siga generalizando.



Fig. 2. Alto error en validación




Fig. 3. Alto error en ambos

Si el modelo tiene alto Bias:

- Comete muchos errores en el set de entrenamiento.
- Underfitting.
- El modelo asume mucho del set de entrenamiento.
- No usa todas las características del modelo.
- Modelo es simple.

Como evitar un alto Bias:

- Usar un modelo más complejo/no lineal.
- Cambiar de arquitectura, a una que se adapte mejor.
- Usar características del set de entrenamiento adecuados para el problema.

Si hay alta varianza:

- Hay Overfitting.
- No generaliza, es sensible a variaciones de los datos.
- Sucede con datos de alta dimensionalidad (muchas variables) y pocos ejemplos.

Como evitar una alta varianza:

- Usar un modelo más simple.
- Reducir dimensionalidad.
- Obtener más ejemplos para el training set.
- Aplicar técnicas de regularización.

II. REGRESIÓN LOGÍSTICA

- No es lo mismo que una regresión.
- Es un algoritmo de clasificación.
- Salida binaria.
- Predice la probabilidad de ocurrencia de un evento.
- Utiliza la distribución de Bernoulli.

A. Función Sigmoide

- Tiene comportamiento no lineal.
- Codominio de $[0, 1]$
- El valor de "x" puede ser cualquier número, incluido el valor de una composición de funciones.

$$f(x) = \frac{1}{1 + e^{-x}}$$




Fig. 4. Función Sigmoide

Para combinarla con la regresión lineal:

$$\sigma(f_{w,b}(x)) = \frac{1}{1 + e^{-(f_{w,b}(x))}}$$

Lo hacemos para:

- Método simple para mantener las relaciones entre variables y pesos.
- Obtener comportamiento no lineal con una función sencilla como el Sigmoide.
- Permite modelar problemas con mayor complejidad.

Clasificador

- Definir un umbral para el clasificador.
- $y \geq 0.5 = 1$
- $y < 0.5 = 0$
- Podemos cambiar el umbral dependiendo del problema.
- Moneda cargada.

Por lo tanto la regresión logística:

- El resultado es no lineal.
- Codominio $[0, 1]$
- Relación entre pesos y features se da por la regresión lineal.
- Es una función de activación (función con resultado no lineal).

Optimización

- Necesitamos optimizar los pesos "w" y "b" de la regresión logística.
- Necesitamos:

- Conseguir una función de pérdida que me sirva para probabilidades.
- Derivar la función de pérdida "L" con respecto a "w" y "b", para utilizar el descenso de gradiente.

La función de pérdida está dada por el modelo, el modelo está dado por el sigmoide:

- $\sigma(x) = \frac{1}{1+e^{-x}}$
- $\sigma'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \sigma(x) \cdot (1 - \sigma(x))$

Verosimilitud VS MSE

La verosimilitud es la probabilidad condicional que se obtiene de observar el conjunto de entrenamiento dado los parámetros de un modelo.

- No se usa MSE
- Se necesita una función de costo relacionada a probabilidades.

Máxima verosimilitud

Habrán un conjunto de parámetros específicos, que hacen que la distribución sea la óptima para los datos que tenemos.




Fig. 5. Verosimilitud máxima

- Para regresión lineal minimizar el **MSE**.
- Problemas de clasificación(regresión logística) usan la **verosimilitud**.
- Optimizar "w" y "b" para maximizar verosimilitud.