

Apuntes Semana 6 Clase 1 Inteligencia Artificial

1st Roberto José Garita Mata
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
robertogarita99@estudiantec.cr

Profesor: Steven Andrey Pacheco Portuquez
Curso: IC6200 Inteligencia Artificial
Fecha: Martes 24 de Marzo

Abstract—En este presente documento se van a presentar los apuntes de la clase del 24 de Marzo, correspondiente a la semana 6 del curso de Inteligencia Artificial, con el profesor Steven Pacheco. Se va a comenzar con las preguntas del Quiz 2, luego como es habitual con un pequeño repaso de la clase anterior (Jueves 19 de Marzo) sobre el tema de la Regresión Logística y seguidamente se continua propiamente ya con los apuntes del día correspondiente, Martes 19 de Marzo, sobre la Función de Costo-Regresión Logística.

I. QUIZ 2

1) Describa ¿que es overfitting y underfitting? 20 pts

Overfitting: Bajo error en training con alto error en testing, el modelo no es capaz de generalizar.

Underfitting: Alto error en training con alto error en testing, el modelo no aprende nada de los datos.

2) Anote la derivada de la función Sigmoide: 20 pts

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$
$$\sigma'(x) = \frac{1' \cdot (1 + e^{-x}) - (1 \cdot (1 + e^{-x})')}{(1 + e^{-x})^2}$$
$$\sigma'(x) = \frac{0 - 1 \cdot (1' + (e^{-x})')}{(1 + e^{-x})^2}$$
$$\sigma'(x) = \frac{-(0 - (-e^{-x}))}{(1 + e^{-x})^2}$$
$$\sigma'(x) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

3) ¿Describa las 3 técnicas para el tratamiento de datos atípicos? 30 pts

Random Sampling: Divide el dataset de forma aleatoria, funciona mejor cuando las clases están balanceadas, pero en datos desbalanceados puede dejar clases poco representadas.

Stratified Sampling: Se usa en datos desbalanceados, mantiene la proporción de cada clase en cada subconjunto, logrando una evaluación más confiable.

K-Fold / Cross-Validation: Divide los datos en K partes, entrena con K-1 y valida con la restante, repitiendo el proceso varias veces. Es útil cuando hay pocos datos.

4) Desarrolle la derivada parcial de L con respecto a W de: 30 pts

$$L = \frac{1}{N} \sum ((wx_i + b) - y_i)^2$$
$$\frac{1}{N} \sum_{i=1}^N 2((wx_i + b) - y_i) \cdot ((wx_i + b) - y_i)'$$
$$\frac{1}{N} \sum_{i=1}^N 2((wx_i + b) - y_i) \cdot x_i$$

II. REPASO DE LA CLASE ANTERIOR (JUEVES 19 DE MARZO)(REGRESIÓN LOGÍSTICA)

Regresión Logística != Regresión Lineal




Fig. 1. Regresión Lineal vs Regresión Silogística

- Es una clasificación binaria (0s o 1s)
- Predice la probabilidad de ocurrencia de un evento binario
- Lo hace mediante la distribución de Bernoulli:

$$P(X = k) = p^k \cdot (1 - p)^{1-k}$$

- Donde k es el valor que puede tomar (0 o 1) y p la probabilidad de que ocurra el evento
- Debemos aplicar este modelo pero con machine learning para que se pueda aprender solo de los datos. ¿Cómo logramos esto? Con la función Sigmoid

A. Sigmoid (Standar Logistic Function)

- Tiene un comportamiento no lineal
- Acotada entre 0 y 1
- Su función es:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- x puede ser cualquier número, incluso el resultado de otra función




Fig. 2. Función Sigmoid

B. Linealidad

- $\sigma(x) = \frac{1}{1 + e^{-x}}$

Resultado no lineal

- $f_{w,b}(x) = wx + b$

Resultado lineal

- $\sigma(f_{w,b}(x)) = \frac{1}{1 + e^{-(f_{w,b}(x))}}$

- ¿Por qué queremos hacerlo así?
- Calcular una función lineal es sumamente simple (computacionalmente)
- Es un método simple para mantener la relación entre las variables y los pesos
- Obtener un comportamiento no lineal con una función sencilla como lo es la Sigmoid
- Permite modelar problemas con una complejidad mayor

C. Clasificador

- Hay que definir un umbral, que por lo general es 0.5
- Si $y \geq 0.5 = 1$ pertenece a la clase 1
- Si $y < 0.5 = 0$ pertenece a la clase 0
- De igual manera el umbral puede cambiar, dependiendo de la situación

D. ¿Cómo se ve mi modelo de Regresión Logística?

- Su función es:

$$\sigma(f_{w,b}(x)) = \frac{1}{1 + e^{-(f_{w,b}(x))}}$$

- Su resultado es no lineal
- Acotación entre 0 y 1
- La relación de los features y pesos se da por la regresión lineal
- Probabilidad de que un evento ocurra




Fig. 3. Arquitectura a nivel gráfico de Regresión Logística




Fig. 4. Función de Activación (Función Sigmoid)

E. Optimización

- Para optimizar nuestro modelo se necesita optimizar los pesos w y b de la regresión logística
- Dado por la función: $f_{w,b}(x) = \frac{1}{1 + e^{-(f_{w,b}(x))}}$

F. Derivada Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\sigma'(x) = \frac{1' \cdot (1 + e^{-x}) - (1 \cdot (1 + e^{-x})')}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{0 - 1 \cdot (1' + (e^{-x})')}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{-(0 - (-e^{-x}))}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

Podemos observar que es medio fea de utilizar entonces vamos a usar un truco para que quede un poco mejor.

$$\sigma'(x) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{e^{-x} + 1 - 1}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{e^{-x} + 1}{(1 + e^{-x})^2} - \frac{1}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{1}{(1 + e^{-x})} - \frac{1}{(1 + e^{-x})^2}$$

$$\sigma'(x) = \frac{1}{(1 + e^{-x})} \cdot \left(1 - \frac{1}{(1 + e^{-x})}\right) \quad \text{Factor común}$$

$$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$$

G. Verosimilitud vs MSE

- NO usamos MSE
- Necesitamos una función de costo relacionada a probabilidades
- Verosimilitud es la probabilidad condicional que se obtiene de observar mi conjunto de entrenamiento, o sea mis datos dados los parámetros de un modelo:

$$L(\theta|X) = P(X|\theta)$$

- Probabilidad de observar todos los datos:

$$L(\theta|X) = P(x_1, x_2, \dots, x_n|\theta) = P(x_1|\theta) \cdot P(x_2|\theta) \cdots P(x_n|\theta)$$




Fig. 5. Afectación de la varianza de los datos




Fig. 6. Máxima Verosimilitud

H. MSE vs Maximize Likelihood

- En regresión lineal minimizamos el MSE
- En su lugar, vamos a maximizar la verosimilitud
- Optimizamos los parámetros w y b , para obtener la máxima verosimilitud

III. FUNCIÓN DE COSTO - REGRESIÓN LOGÍSTICA

- La decisión sobre un evento sea la más probable posible
- Maximizar la verosimilitud de todo el training set
- Con los parámetros w y b , calculamos la probabilidad de cada observación

$$L = \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{(1-y_i)}, \quad i = 1 \dots N$$

1) Caso $y_i = 1$

$$\begin{aligned} & \bullet f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i} \\ & \bullet = f_{w,b}(x_i)^1 (1 - f_{w,b}(x_i))^0 \\ & \bullet = f_{w,b}(x_i)^1 \end{aligned}$$

2) Caso $y_i = 1$ - Ejemplo de la Calabaza no es naranja

$$\begin{aligned} & \bullet wx + b = 1.458 \\ & \bullet f_{w,b}(x_i) = \sigma(wx_i + b) = \sigma(1.458) = 0.81 \\ & \bullet = f_{w,b}(x_i)^1 (1 - f_{w,b}(x_i))^0 \\ & \bullet = f_{w,b}(x_i)^1 = \sigma(1.458) \\ & \bullet = 0.81 \end{aligned}$$

La probabilidad de x_i no sea naranja es 0.81

3) Caso $y_i = 0$

$$\begin{aligned} & \bullet \cancel{f_{w,b}(x_i)^{y_i}} (1 - f_{w,b}(x_i))^{1-y_i} \\ & \bullet = \cancel{f_{w,b}(x_i)^0} (1 - f_{w,b}(x_i))^1 \\ & \bullet = (1 - f_{w,b}(x_i))^1 \end{aligned}$$

4) Caso $y_i = 0$ - Ejemplo de la Calabaza no es naranja

$$\begin{aligned} & \bullet wx + b = -1.32 \\ & \bullet f_{w,b}(x_i) = \sigma(wx_i + b) = \sigma(-1.32) = 0.21 \end{aligned}$$

- $= f_{w,b}(x_i)^0 (1 - f_{w,b}(x_i))^{1-0}$
- $= (1 - f_{w,b}(x_i))^1 = (1 - \sigma(-1.32))$
- $= (1 - 0.21) = 0.79$

La probabilidad de x_i sea naranja es 0.79




Fig. 7. Ejemplo de la Calabaza no es naranja, cuando $y_i = 0$ y $y_i = 1$

A. Derivada - Función de Costo

$$L = \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{(1-y_i)}, \quad i = 1 \dots N$$

- Para calcular la verosimilitud se necesita encontrar la probabilidad de observar cada sample
- La derivada de una multiplicación es compleja
- Tenemos que buscar una equivalencia que no tengamos que multiplicar
- Para poder hacer esto, tenemos que aplicar logaritmo

1) Logaritmo:

- $\ln(a^n) = n \cdot \ln(a)$
- $\ln(a \cdot b) = \ln(a) + \ln(b)$
- $\ln(a^n \cdot b^n) = n \cdot \ln(a) + n \cdot \ln(b)$
- Estrictamente creciente

2) Aplicamos logaritmo a la verosimilitud:

- $$L = \prod f_{w,b}(x_i)^{y_i} \cdot (1 - f_{w,b}(x_i))^{(1-y_i)}$$
- $$\ln(L) = \sum \ln(f_{w,b}(x_i)^{y_i}) + \ln((1 - f_{w,b}(x_i))^{(1-y_i)})$$

- $$\ln(L) = \sum y_i \cdot \ln(f_{w,b}(x_i)) + (1-y_i) \cdot \ln(1 - f_{w,b}(x_i))$$
- Es más fácil de computar (NaN)
- Es una función mas sencilla de derivar
- Se llama Log-Likelihood
- Me quita errores al momento de estar computando las multiplicaciones de probabilidades

3) Para minimizar maximizando:

- En regresión lineal encontramos un algoritmo para minimizar el MSE
- Imaginemos que tenemos todo el código y solo queremos cambiar la función
- Se puede invertir la función multiplicándola por -1
-

$$L = \frac{1}{N} \sum y_i \cdot \ln(f_{w,b}(x_i)) + (1-y_i) \cdot \ln(1 - f_{w,b}(x_i))$$




Fig. 8. Antes de darle vuelta

- $$L = -\frac{1}{N} \sum y_i \cdot \ln(f_{w,b}(x_i)) + (1-y_i) \cdot \ln(1 - f_{w,b}(x_i))$$




Fig. 9. Después de darle vuelta

- Después de invertir la función, ya se puede minimizar y aplicar el algoritmo de descenso de gradiente
- Lo ideal es acercarse al donde loss es 0, porque si se tiene un loss negativo, se estaría haciendo algo mal en los cálculos

4) Actualizamos los parámetros w y b :

Se necesita actualizar los parámetros w y b porque son los que nos permiten cambiar los resultados de las probabilidades que vamos a obtener

- Para actualizar el parámetro w : $\frac{\partial L}{\partial w}$
- Para actualizar el parámetro b : $\frac{\partial L}{\partial b}$

5) Calculando las derivadas por medio de la composición de funciones:

- Función de costo derivada:

$$L_i = -(y_i \cdot \ln(f_{w,b}(x_i)) + (1 - y_i) \cdot \ln(1 - f_{w,b}(x_i)))$$

- Modelo compuesto por 2 funciones:

$$f_{w,b}(x) = a(z(x))$$

- Función Sigmoid:

$$a(x) = \frac{1}{1 + e^{-x}}$$

- Regresión lineal:

$$z(x) = wx + b$$

- $L_i = -(y_i \cdot \ln(a(z(x))) + (1 - y_i) \cdot \ln(1 - a(z(x))))$

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$

$$\frac{\partial L}{\partial b} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial b}$$

Primero se calcula la derivada parcial de L con respecto a la función Sigmoid.

- $L = -[y_i \cdot \ln(a(z(x))) + (1 - y_i) \cdot \ln(1 - a(z(x)))]$

$$\frac{\partial L}{\partial a} = - \left[\left(y_i \cdot \frac{1}{a(x)} \cdot a(x)' \right) + \left((1 - y_i) \cdot \frac{1}{1 - a(x)} \cdot (1 - a(x))' \right) \right]$$

$$\frac{\partial L}{\partial a} = - \left[\left(\frac{y_i}{a(x)} \cdot 1 \right) + \left(\frac{(1 - y_i)}{1 - a(x)} \cdot -1 \right) \right]$$

$$\frac{\partial L}{\partial a} = - \left[\left(\frac{y_i}{a(x)} \right) - \left(\frac{(1 - y_i)}{1 - a(x)} \right) \right]$$

$$\frac{\partial L}{\partial a} = - \frac{y_i}{a(x)} + \frac{(1 - y_i)}{1 - a(x)}$$

Luego calculamos la derivada parcial de la función Sigmoid con respecto a z .

$$a(x) = \sigma(x) = \frac{1}{1 + e^{-x}}$$

$$a(z(x)) = \frac{1}{1 + e^{-z(x)}}$$

$$\frac{\partial a}{\partial z} = \sigma(z(x)) \cdot (1 - \sigma(z(x)))$$

Por último calculamos la derivada parcial de cada uno de los parámetros con respecto a la regresión lineal.

$$z(x) = wx + b$$

$$\frac{\partial z}{\partial w} = x$$

$$\frac{\partial z}{\partial b} = 1$$

Luego de haber calculado todo por separado se hacen las multiplicaciones correspondientes.

Primero la derivada parcial de L con respecto a z .

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} = - \frac{y_i}{a(z(x))} + \frac{1 - y_i}{(1 - a(z(x)))}$$

$$a(z(x)) \cdot (1 - a(z(x)))$$

$$\frac{\partial L}{\partial z} = \frac{-y_i + a(z(x)) \cdot y_i + a(z(x)) - a(z(x)) \cdot y_i}{a(z(x)) - a(z(x))^2}$$

$$[a(z(x)) - a(z(x))^2]$$

$$\frac{\partial L}{\partial z} = \frac{-y_i + a(z(x)) \cdot y_i + a(z(x)) - a(z(x)) \cdot y_i}{a(z(x)) - a(z(x))^2}$$

$$[a(z(x)) - a(z(x))^2]$$

$$\frac{\partial L}{\partial z} = \frac{-y_i + a(z(x))}{a(z(x)) - a(z(x))^2} \cdot [a(z(x)) - a(z(x))^2]$$

$$\frac{\partial L}{\partial z} = a(z(x)) - y_i$$

Segundo la derivada parcial de L con respecto a w y b

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial w} = (a(z(x)) - y_i) \cdot x$$

$$\frac{\partial L}{\partial b} = \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial b} = (a(z(x)) - y_i) \cdot 1$$

- Recordar que $a(z(x)) = \text{Mi modelo!!}$

Actualizamos parámetros

$$f_{w,b}(x) = a(z(x))$$

$$a(x) = \frac{1}{1 + e^{-x}}$$

$$z(x) = wx + b$$