

Apuntes de Clase - Regresión Logística

IC6200 — Inteligencia Artificial

David Blanco Láscarez 2020053806

Escuela de Ingeniería en Computación

Tecnológico de Costa Rica

24 de marzo de 2026

I. RESPUESTAS QUIZ 2

I-A. *Overfitting y underfitting*

Overfitting ocurre cuando un modelo aprende demasiado bien los datos de entrenamiento, incluyendo ruido y particularidades específicas del dataset. Como consecuencia, el error en entrenamiento es muy bajo, pero el modelo generaliza mal y comete muchos errores en validación o prueba.

Underfitting ocurre cuando el modelo es demasiado simple o está mal entrenado, por lo que ni siquiera logra capturar los patrones básicos de los datos. En este caso tanto el error de entrenamiento como el de validación son altos, indicando que el modelo no tiene capacidad suficiente o que no se entrenó adecuadamente (pocas épocas, mala tasa de aprendizaje, etc.).

I-B. *Derivada de la función sigmoide*

La función sigmoide estándar se define como:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

Su derivada es:

$$\sigma'(x) = \sigma(x) (1 - \sigma(x)) \quad (2)$$

Esta forma es muy conveniente porque permite expresar la derivada solo en función del valor ya calculado de $\sigma(x)$, lo que simplifica las implementaciones de backpropagation.

I-C. *Técnicas para tratamiento de datos atípicos*

Existen varias técnicas para tratar *outliers* (datos atípicos). Tres ejemplos comunes son:

1. **Residuos Estandarizados:** Se normaliza el residuo respecto a la desviación estándar global: $|z| > 2$ es un posible outlier y $|z| > 3$ es un muy probable outlier (eliminar o analizar).
2. **Winsorización:** en lugar de eliminar, recortar los valores extremos a un límite máximo y mínimo razonable (por ejemplo, reemplazar valores por encima de $Q3 + 1,5 \cdot IQR$ por ese umbral).
3. **Regla del IQR:** Outliers son valores fuera del rango $Q1 - 1,5 \cdot IQR$, $Q3 + 1,5 \cdot IQR$

La elección de la técnica depende del contexto del problema, del tamaño del dataset y de si los outliers representan errores de medición o casos válidos pero poco frecuentes.

I-D. *Derivada parcial de L respecto a w*

Sea la función de costo de regresión lineal:

$$L = \frac{1}{N} \sum_{i=1}^N ((wx_i + b) - y_i)^2 \quad (3)$$

La derivada parcial de L con respecto a w se obtiene aplicando regla de la cadena:

$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=1}^N 2((wx_i + b) - y_i) \cdot x_i \quad (4)$$

$$= \frac{2}{N} \sum_{i=1}^N (wx_i + b - y_i) x_i \quad (5)$$

Esta expresión es la que se utiliza en descenso de gradiente para actualizar el peso w en regresión lineal.

II. REPASO: REGRESIÓN LINEAL VS LOGÍSTICA

La regresión lineal produce una salida continua no acotada, lo cual la hace adecuada para problemas de predicción numérica. Su función de predicción es:

$$f_{w,b}(x) = w^T x + b \quad (6)$$

Sin embargo, para problemas de **clasificación binaria** se necesita una salida acotada entre 0 y 1 que pueda interpretarse como una probabilidad. La regresión logística resuelve esto combinando una función lineal con una función sigmoide no lineal:

$$f_{w,b}(x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (7)$$

La principal ventaja de esta combinación es que los datos internamente siguen siendo productos punto (computacionalmente simples), y la sigmoide se encarga de transformar el resultado al rango $[0, 1]$.

III. FUNCIÓN SIGMOIDE

La función sigmoide estándar (*Standard Logistic Function*) se define como:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (8)$$

Sus propiedades más relevantes son:

- Salida acotada en el intervalo $(0, 1)$
- Estrictamente creciente
- No lineal, lo que permite resolver problemas no lineales tanto en ML como en DL
- Su derivada tiene una forma muy conveniente:

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)) \quad (9)$$

Se utiliza un **umbral de decisión** (típicamente 0.5) para convertir la probabilidad de salida en una clase binaria: si $f_{w,b}(x) \geq 0,5$ se predice clase 1, de lo contrario clase 0.

IV. DISTRIBUCIÓN DE BERNOULLI Y VEROSIMILITUD

La regresión logística se fundamenta en la distribución de Bernoulli. Para una variable binaria $k \in \{0, 1\}$ con probabilidad p :

$$P(k) = p^k(1 - p)^{1-k} \quad (10)$$

En nuestro modelo, $p = f_{w,b}(x)$. Para cada muestra x_i con etiqueta y_i :

$$P(x_i) = f_{w,b}(x_i)^{y_i} \cdot (1 - f_{w,b}(x_i))^{1-y_i} \quad (11)$$

Esto unifica los dos casos posibles en una sola expresión:

- **Caso $y_i = 1$:** la expresión se reduce a $f_{w,b}(x_i)$
- **Caso $y_i = 0$:** la expresión se reduce a $1 - f_{w,b}(x_i)$

La **verosimilitud** (*likelihood*) del conjunto de entrenamiento completo es el producto de todas las probabilidades individuales:

$$\mathcal{L}(w, b) = \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i} \quad (12)$$

El objetivo de la optimización es **maximizar** esta verosimilitud, es decir, encontrar los parámetros w y b que hacen más probable observar los datos de entrenamiento.

Nota: no se utiliza MSE en regresión logística porque no está diseñado para probabilidades y produce superficies de error no convexas.

V. LOG-VEROSIMILITUD

Calcular la derivada de una multiplicación de N términos es computacionalmente complejo y propenso a errores numéricos (underflow por multiplicar muchos valores pequeños $\rightarrow$ NaN). La solución es aplicar logaritmo natural, que es una función estrictamente creciente, por lo que **maximizar la verosimilitud es equivalente a maximizar el logaritmo de la verosimilitud**:

$$\begin{aligned} \ln \mathcal{L} &= \ln \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i} \\ &= \sum_{i=1}^N [y_i \ln f_{w,b}(x_i) + (1 - y_i) \ln(1 - f_{w,b}(x_i))] \end{aligned} \quad (13)$$

Las propiedades del logaritmo que hacen esto posible son:

$$\ln(a^n) = n \ln a$$

$$\ln(ab) = \ln a + \ln b$$

$$\ln(a^n b^n) = n \ln a + n \ln b$$

VI. FUNCIÓN DE COSTO: BINARY CROSS-ENTROPY

Para usar descenso de gradiente necesitamos **minimizar**, no maximizar. Se cambia el signo de la log-verosimilitud y se promedia sobre N :

$$\mathcal{L}(w, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \ln f_{w,b}(x_i) + (1 - y_i) \ln(1 - f_{w,b}(x_i))] \quad (14)$$

Esta función se conoce como **Binary Cross-Entropy** (BCE) y calcula el promedio del error entre las predicciones y las etiquetas reales sobre todas las muestras.

VII. DERIVADAS Y DESCENSO DE GRADIENTE

Para actualizar los parámetros se necesitan las derivadas parciales de $\mathcal{L}$ respecto a w y b . Definiendo la composición de funciones:

$$z(x) = w^T x + b \quad (15)$$

$$a(z) = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (16)$$

Se aplica la regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial w} = \frac{\partial \mathcal{L}}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w} \quad (17)$$

Calculando cada término por separado:

$$\frac{\partial \mathcal{L}}{\partial a} = -\frac{y_i}{a(z_x)} + \frac{1 - y_i}{1 - a(z_x)} \quad (18)$$

$$\frac{\partial a}{\partial z} = a(z_x)(1 - a(z_x)) \quad (\text{ver Ec. 9}) \quad (19)$$

$$\frac{\partial z}{\partial w} = x, \quad \frac{\partial z}{\partial b} = 1 \quad (20)$$

Combinando, el gradiente final simplificado resulta:

$$\frac{\partial \mathcal{L}}{\partial w} = (a(z_x) - y_i) \cdot x \quad (21)$$

$$\frac{\partial \mathcal{L}}{\partial b} = a(z_x) - y_i \quad (22)$$

Donde $a(z_x) = f_{w,b}(x)$ es la predicción actual del modelo. La regla de actualización de pesos es:

$$w \leftarrow w - \alpha \cdot \frac{\partial \mathcal{L}}{\partial w} \quad (23)$$

$$b \leftarrow b - \alpha \cdot \frac{\partial \mathcal{L}}{\partial b} \quad (24)$$

VIII. RESUMEN DEL MODELO

El modelo de regresión logística final queda definido por la composición:

$$f_{w,b}(x) = \sigma(z(x)) = \frac{1}{1 + e^{-(wx+b)}} \quad (25)$$

- **Entrada:** vector de características x
- **Parámetros:** pesos w y sesgo b
- **Función de costo:** Binary Cross-Entropy (BCE)
- **Optimización:** descenso de gradiente con gradientes de las Ecs. (21) y (22)
- **Salida:** probabilidad $\hat{y} \in (0, 1)$, clasificada con umbral 0.5