

Semana 6 Clase 2 Inteligencia Artificial

*Resumen de la clase impartida el día jueves 26 de marzo

Emmanuel José Matamoros Jiménez
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
emmajose1703@estudiantec.cr

Profesor: Steven Andrey Pacheco Portuquez
Curso: IC6200 Inteligencia Artificial

Abstract—Este documento presenta un análisis de las principales métricas utilizadas en la evaluación de modelos de clasificación, especialmente en el contexto de la regresión logística. Se abordan conceptos fundamentales como la matriz de confusión, accuracy, precisión, recall y F1-Score, destacando sus ventajas, limitaciones y aplicaciones según el tipo de problema.

I. REPASO DE LA CLASE DEL MARTES 24

En esta sesión se analizó la formulación de la función de costo para la regresión logística, con el objetivo de modelar probabilidades y tomar decisiones basadas en la máxima verosimilitud.

A. Máxima verosimilitud

El objetivo principal es maximizar la probabilidad de observar el conjunto de datos de entrenamiento dado el modelo. Para ello, se busca maximizar la probabilidad de observar todo el conjunto de entrenamiento.

Asumiendo que las observaciones son independientes, la función de verosimilitud se define como:

$$L = \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i}$$

donde $f_{w,b}(x_i)$ representa la probabilidad predicha por el modelo.

Dependiendo del valor de y_i , la expresión se simplifica:

- Si $y_i = 1$: $f_{w,b}(x_i)$
- Si $y_i = 0$: $1 - f_{w,b}(x_i)$

Esto permite interpretar directamente la probabilidad de que una observación pertenezca a una clase.




Fig. 1. Máxima verosimilitud

B. Transformación logarítmica

Trabajar con productos de probabilidades es complejo, especialmente al derivar. Por ello, se aplica el logaritmo natural, aprovechando sus propiedades:

- $\ln(a^n) = n \ln(a)$
- $\ln(a \cdot b) = \ln(a) + \ln(b)$

Aplicando logaritmo a la verosimilitud:

$$\log L = \sum_{i=1}^N [y_i \ln(f_{w,b}(x_i)) + (1 - y_i) \ln(1 - f_{w,b}(x_i))]$$

Esta expresión se conoce como **log-likelihood**, y es más estable numéricamente y más sencilla de derivar.

Para poder minimizar, se define la función de costo (entropía cruzada o *cross-entropy*) como la negativa:

$$J = -\frac{1}{N} \sum_{i=1}^N [y_i \ln(f_{w,b}(x_i)) + (1 - y_i) \ln(1 - f_{w,b}(x_i))]$$

C. Modelo como composición de funciones

El modelo logístico puede expresarse como la composición de dos funciones:

$$f_{w,b}(x) = a(z(x))$$

donde:

$$z(x) = wx + b$$

$$a(z) = \frac{1}{1 + e^{-z}}$$

La función $a(z)$ corresponde a la función sigmoide, la cual convierte una salida lineal en una probabilidad.

D. Derivación de la función de costo

Para optimizar el modelo, se calculan las derivadas parciales de la función de pérdida. Para una observación individual:

$$L_i = -(y_i \ln(a(z(x_i))) + (1 - y_i) \ln(1 - a(z(x_i))))$$

Aplicando la regla de la cadena:

$$\frac{\partial L_i}{\partial w} = \frac{\partial L_i}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$

$$\frac{\partial L_i}{\partial b} = \frac{\partial L_i}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial b}$$

Se derivan cada una de las partes:

- Derivada de la sigmoide:

$$\frac{\partial a}{\partial z} = a(z)(1 - a(z))$$

- Derivadas de la función lineal:

$$\frac{\partial z}{\partial w} = x, \quad \frac{\partial z}{\partial b} = 1$$

Al simplificar todas las expresiones, se obtiene un resultado clave:

$$\frac{\partial L_i}{\partial z} = a(z(x_i)) - y_i$$

Por lo tanto:

$$\frac{\partial L_i}{\partial w} = (a(z(x_i)) - y_i) \cdot x_i$$

$$\frac{\partial L_i}{\partial b} = (a(z(x_i)) - y_i)$$

Esto muestra que el error del modelo corresponde a la diferencia entre la predicción probabilística y el valor real, lo cual guía la actualización de los parámetros durante el entrenamiento.

E. Actualización de parámetros

Los parámetros w y b se actualizan mediante descenso por gradiente:

$$w := w - \alpha \frac{1}{N} \sum_{i=1}^N (a(z(x_i)) - y_i) x_i$$

$$b := b - \alpha \frac{1}{N} \sum_{i=1}^N (a(z(x_i)) - y_i)$$

donde α es la tasa de aprendizaje.

Este proceso se repite iterativamente hasta minimizar la función de costo, permitiendo que el modelo mejore sus predicciones.

II. MÉTRICAS

Una vez entrenado un modelo, surge la necesidad de evaluarlo adecuadamente. Es posible que distintos algoritmos presenten valores similares en la función de costo, pero esto no garantiza que su desempeño sea equivalente en la práctica. Por ello, se requieren métricas que permitan comparar modelos de manera objetiva y fundamentar la toma de decisiones.

A. ¿Qué es una métrica?

Las métricas son medidas cuantitativas utilizadas para evaluar el rendimiento de un modelo predictivo. Estas permiten analizar qué tan bien se comporta un modelo frente a datos reales y constituyen la forma más objetiva de comparación entre diferentes enfoques.

Además, las métricas funcionan como un mecanismo de validación, permitiendo identificar situaciones en las que el modelo no se comporta conforme a lo esperado, aun cuando la función de costo sugiera un buen desempeño.

B. Matriz de confusión

En problemas de clasificación binaria, donde existen dos clases posibles (positiva: 1, negativa: 0), se utiliza la matriz de confusión como herramienta fundamental de análisis.

Target class	P	N
Predicted class		
P	TP	FP (Type I)
N	FN (Type II)	TN

Fig. 2. Matriz de confusión

Esta matriz permite comparar las predicciones del modelo con los valores reales, clasificando los resultados en cuatro categorías:

- **Verdadero Positivo (TP):** El modelo predice la clase positiva y efectivamente es positiva.
- **Verdadero Negativo (TN):** El modelo predice la clase negativa y efectivamente es negativa.
- **Falso Positivo (FP):** El modelo predice la clase positiva cuando en realidad es negativa (Error Tipo I).
- **Falso Negativo (FN):** El modelo predice la clase negativa cuando en realidad es positiva (Error Tipo II).

Esta clasificación permite analizar de manera más detallada el comportamiento del modelo, especialmente en contextos donde los distintos tipos de error tienen diferentes implicaciones.

C. Accuracy

La **accuracy** (exactitud) es una de las métricas más básicas y ampliamente utilizadas. Mide la proporción de predicciones correctas realizadas por el modelo respecto al total de observaciones.

Se define como:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Esta métrica considera tanto los aciertos como los errores del modelo. En un escenario ideal, donde no existen errores ($FP = 0$ y $FN = 0$), la accuracy sería igual a 1.




Fig. 3. Representación de Accuracy

La accuracy es especialmente útil cuando las clases están balanceadas y los distintos tipos de error tienen la misma importancia. Sin embargo, presenta limitaciones importantes:

- No distingue entre tipos de error (FP y FN).
- Puede ser engañosa en datasets desbalanceados.
- No refleja adecuadamente el desempeño en clases minoritarias.

D. Precision y Recall

Para complementar el análisis, se introducen métricas que permiten evaluar el modelo desde distintas perspectivas:

- **Precisión (Precision):** Indica qué proporción de las predicciones positivas fueron correctas.

$$Precision = \frac{TP}{TP + FP}$$




Fig. 4. Representación de Precision

- **Recall (Sensibilidad):** Indica qué proporción de los positivos reales fueron correctamente identificados.

$$Recall = \frac{TP}{TP + FN}$$




Fig. 5. Representación de Recall

Estas métricas son fundamentales en problemas donde los errores tienen diferentes costos, como en detección de enfermedades o fraudes.

E. F1-Score

El **F1-Score** es una métrica que combina precisión y recall en un solo valor, utilizando la media armónica:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Esta métrica es útil cuando se busca un equilibrio entre precisión y recall, especialmente en datasets desbalanceados.

F. Caso de estudio

Se analiza un problema de clasificación binaria en el contexto médico, donde se desea detectar la presencia de cáncer en pacientes.

- Total de pacientes: 1000
- Pacientes con cáncer (clase positiva): 30
- Pacientes sin cáncer (clase negativa): 970

Supongamos que el modelo produce los siguientes resultados:

- Verdaderos Positivos (TP): 25
- Falsos Negativos (FN): 5
- Verdaderos Negativos (TN): 950
- Falsos Positivos (FP): 20

Matriz de confusión:

	Predicción Positiva	Predicción Negativa
Real Positivo	$TP = 25$	$FN = 5$
Real Negativo	$FP = 20$	$TN = 950$

Cálculo de métricas: Accuracy:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{25 + 950}{1000} = 0.975$$

Precisión (Precision):

$$Precision = \frac{TP}{TP + FP} = \frac{25}{25 + 20} = 0.55$$

Recall (Sensibilidad):

$$Recall = \frac{TP}{TP + FN} = \frac{25}{25 + 5} \approx 0.833$$

F1-Score:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = 2 \cdot \frac{0.55 \cdot 0.833}{0.55 + 0.833} \approx 0.66$$

Análisis: Aunque la accuracy del modelo es alta (97.5%), esta métrica resulta engañosa debido al desbalance de clases. La mayoría de los pacientes no tienen cáncer, por lo que el modelo puede acertar muchas veces simplemente prediciendo la clase negativa.

Sin embargo, al analizar métricas más específicas:

- La precisión (55%) indica que solo la mitad de los pacientes diagnosticados como positivos realmente tienen cáncer.
- El recall (83%) muestra que el modelo logra detectar una parte importante de los casos reales, pero aún pierde pacientes (FN).
- El F1-Score (66%) refleja un desempeño moderado al equilibrar precisión y recall.

En un contexto médico, el recall suele ser más importante que la precisión, ya que es preferible detectar más casos positivos aunque se cometan algunos falsos positivos.

G. ROC y AUC

La curva ROC (*Receiver Operating Characteristic*) es una herramienta que permite evaluar el desempeño de un modelo de clasificación para distintos umbrales de decisión.

Esta curva representa la relación entre:

- **Tasa de Verdaderos Positivos (TPR o Recall)**

$$TPR = \frac{TP}{TP + FN}$$

- **Tasa de Falsos Positivos (FPR)**

$$FPR = \frac{FP}{FP + TN}$$




Fig. 6. Representación gráfica de la curva ROC

La curva ROC se construye variando el umbral de clasificación del modelo (sobre sus probabilidades de salida) y graficando el TPR frente al FPR.

Por otro lado, el AUC (*Area Under the Curve*) mide el área bajo la curva ROC y resume el desempeño del modelo en un único valor:

- $AUC = 1$: Modelo perfecto
- $AUC = 0.5$: Modelo equivalente al azar
- $0.5 < AUC < 1$: Modelo con capacidad predictiva

El AUC es especialmente útil para comparar modelos, ya que no depende de un único umbral de decisión y permite evaluar la capacidad general de discriminación entre clases.




Fig. 7. Comparación ROC y AUC

En conclusión, la curva ROC y el AUC proporcionan una visión más completa del rendimiento del modelo, especialmente en escenarios con clases desbalanceadas.

III. TAREA 02: IMPLEMENTACIÓN DE REGRESIÓN LOGÍSTICA - PYTORCH

Antes de finalizar la clase el profesor dejó una tarea que se debe entregar el día 9 de abril. La tarea consiste en la implementación y análisis de un modelo de regresión logística aplicado a un problema de clasificación binaria, cuyo objetivo es determinar si la calidad de un vino es clasificada como *BUENA* o *MALA*. Para ello, se utiliza PyTorch como herramienta principal para la construcción, entrenamiento y optimización del modelo.

El desarrollo de la tarea inicia con la obtención del conjunto de datos y la realización de un análisis exploratorio (EDA), incluyendo visualizaciones como histogramas, boxplots, diagramas de dispersión y matrices de correlación. A partir de este análisis, se deben seleccionar un máximo de seis características relevantes, justificando matemáticamente dicha selección. Además, se requiere dividir el dataset en conjuntos de entrenamiento, validación y prueba, utilizando una técnica adecuada como *stratified sampling*.

Posteriormente, se implementa el modelo de regresión logística en PyTorch, realizando múltiples entrenamientos (al menos diez) con diferentes configuraciones de hiperparámetros, tales como tasa de aprendizaje, número de épocas y tamaño de batch. Durante este proceso, se debe analizar el comportamiento de la función de pérdida para identificar posibles casos de *overfitting*.

La evaluación del modelo se realiza mediante diversas métricas, incluyendo accuracy, precisión, recall, F1-Score y AUC, comparando los resultados obtenidos en cada uno de los entrenamientos. A partir de este análisis, se selecciona el modelo con mejor desempeño, el cual debe ser validado utilizando el conjunto de prueba.

Finalmente, se deben presentar los resultados del modelo seleccionado mediante una matriz de confusión y un análisis detallado de las métricas obtenidas. La entrega incluye un informe formal en formato IEEE desarrollado en $\text{\LaTeX}$, acompañado de un notebook con la implementación completa del modelo.