

Resumen de: Semana 6 Clase 2 Inteligencia Artificial

Victor Aymerich
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica

Abstract—Este documento describe los principios fundamentales de la regresión logística y las principales medidas utilizadas para evaluar modelos de clasificación. Se analizan conceptos como la función de verosimilitud, la entropía cruzada y el descenso de gradiente, además de métricas clave como accuracy, precision, recall, F1-score y AUC. También se presenta un ejemplo aplicado para evidenciar las limitaciones de ciertas métricas en escenarios con datos desbalanceados.

Index Terms—Regresión Logística, Clasificación, Métricas, Accuracy, Precision, Recall, F1-Score, AUC




Fig. 1: Máxima verosimilitud

I. INTRODUCCIÓN

Los modelos de clasificación son ampliamente utilizados en problemas donde se requiere asignar una categoría a una observación. Dentro de estos, la regresión logística es uno de los enfoques más importantes debido a su interpretabilidad y eficiencia.

Este trabajo repasa cómo este modelo transforma una combinación lineal de variables en probabilidades y cómo se optimiza mediante técnicas matemáticas. Además, se estudian diferentes métricas que permiten evaluar su desempeño de manera adecuada.

II. FUNDAMENTOS TEÓRICOS

A. Máxima Verosimilitud

El objetivo del modelo es encontrar los parámetros que maximizan la probabilidad de observar los datos disponibles. Asumiendo que las observaciones son independientes, la función de verosimilitud se define como:

$$L = \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i} \quad (1)$$

donde $f_{w,b}(x_i)$ representa la probabilidad predicha por el modelo. Dependiendo del valor de y_i , la expresión se simplifica: si $y_i = 1$, contribuye $f_{w,b}(x_i)$; si $y_i = 0$, contribuye $1 - f_{w,b}(x_i)$.

B. Transformación Logarítmica

Trabajar con productos de probabilidades es numéricamente inestable y difícil de derivar. Por ello, se aplica logaritmo natural, aprovechando que $\ln(a \cdot b) = \ln(a) + \ln(b)$, convirtiendo productos en sumas:

$$\log L = \sum_{i=1}^N [y_i \ln(f_{w,b}(x_i)) + (1 - y_i) \ln(1 - f_{w,b}(x_i))] \quad (2)$$

Esta expresión se conoce como *log-likelihood*. Para poder minimizar, se define la función de costo (entropía cruzada o *cross-entropy*) como su negativa:

$$J = -\frac{1}{N} \sum_{i=1}^N [y_i \ln(f_{w,b}(x_i)) + (1 - y_i) \ln(1 - f_{w,b}(x_i))] \quad (3)$$

C. Modelo como Composición de Funciones

El modelo logístico puede expresarse como la composición de dos funciones: $f_{w,b}(x) = a(z(x))$, donde:

$$z(x) = wx + b \quad a(z) = \frac{1}{1 + e^{-z}} \quad (4)$$

La función $a(z)$ corresponde a la **función sigmoide**, que transforma una salida lineal en una probabilidad entre 0 y 1.

D. Derivación de la Función de Costo

Para optimizar el modelo se calculan las derivadas parciales de la pérdida mediante la regla de la cadena:

$$\frac{\partial L_i}{\partial w} = \frac{\partial L_i}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w} \quad (5)$$

Usando que la derivada de la sigmoide es $\frac{\partial a}{\partial z} = a(z)(1 - a(z))$, y que $\frac{\partial z}{\partial w} = x$, $\frac{\partial z}{\partial b} = 1$, se simplifica a un resultado clave:

$$\frac{\partial L_i}{\partial w} = (a(z(x_i)) - y_i) \cdot x_i \quad \frac{\partial L_i}{\partial b} = a(z(x_i)) - y_i \quad (6)$$

Esto muestra que el gradiente es simplemente el error entre la predicción probabilística y el valor real.

E. Actualización de Parámetros

Los parámetros w y b se actualizan iterativamente mediante descenso por gradiente:

$$w := w - \alpha \frac{1}{N} \sum_{i=1}^N (a(z(x_i)) - y_i) x_i \quad (7)$$

$$b := b - \alpha \frac{1}{N} \sum_{i=1}^N (a(z(x_i)) - y_i) \quad (8)$$

donde α es la tasa de aprendizaje. Este proceso se repite hasta minimizar la función de costo.

III. MÉTRICAS DE EVALUACIÓN

Una vez entrenado un modelo, es necesario evaluarlo con métricas cuantitativas. Distintos algoritmos pueden presentar valores similares en la función de costo sin tener el mismo desempeño práctico, por lo que las métricas permiten una comparación objetiva.

A. Matriz de Confusión

En clasificación binaria, la matriz de confusión compara las predicciones del modelo con los valores reales, clasificando los resultados en cuatro categorías:

- **Verdadero Positivo (TP):** predicción positiva correcta.
- **Verdadero Negativo (TN):** predicción negativa correcta.
- **Falso Positivo (FP):** predicción positiva incorrecta (Error Tipo I).
- **Falso Negativo (FN):** predicción negativa incorrecta (Error Tipo II).




Fig. 2: Matriz de confusión

B. Accuracy

La exactitud mide el porcentaje total de predicciones correctas:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (9)$$

Aunque es intuitiva, puede ser engañosa cuando las clases no están equilibradas, ya que no distingue entre tipos de error ni refleja el desempeño en clases minoritarias.

C. Precision y Recall

Estas métricas ofrecen una visión más detallada del comportamiento del modelo:

$$Precision = \frac{TP}{TP + FP} \quad Recall = \frac{TP}{TP + FN} \quad (10)$$

La **precision** indica qué proporción de las predicciones positivas fueron correctas, mientras que el **recall** indica qué proporción de los positivos reales fueron detectados.




Fig. 3: Diagrama de Precision y Recall

D. F1-Score

Combina precision y recall en un solo valor mediante la media armónica:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (11)$$

Es especialmente útil en datasets desbalanceados donde se busca equilibrio entre ambas métricas.

E. Curva ROC y AUC

La curva ROC (*Receiver Operating Characteristic*) evalúa el desempeño del modelo para distintos umbrales de decisión, graficando la Tasa de Verdaderos Positivos (TPR) frente a la Tasa de Falsos Positivos (FPR):

$$TPR = \frac{TP}{TP + FN} \quad FPR = \frac{FP}{FP + TN} \quad (12)$$

El AUC (*Area Under the Curve*) resume el rendimiento en un único valor: AUC = 1 indica un clasificador perfecto, AUC = 0.5 equivale al azar, y $0.5 < AUC < 1$ indica capacidad predictiva real. Es especialmente útil para comparar modelos sin depender de un umbral fijo.




Fig. 4: Curva ROC y AUC

IV. CASO DE ESTUDIO

Se analiza un problema médico de clasificación binaria para detectar cáncer en pacientes, con datos desbalanceados: 1000 pacientes en total, 30 con cáncer (clase positiva) y 970 sin cáncer (clase negativa). El modelo produce los siguientes resultados: TP = 25, FN = 5, TN = 950, FP = 20.

TABLE I: Matriz de confusión del caso de estudio

	Pred. Positiva	Pred. Negativa
Real Positivo	TP = 25	FN = 5
Real Negativo	FP = 20	TN = 950

Cálculo de métricas:

$$Accuracy = \frac{25 + 950}{1000} = 0.975 \quad (13)$$

$$Precision = \frac{25}{25 + 20} \approx 0.55 \quad Recall = \frac{25}{25 + 5} \approx 0.833 \quad (14)$$

$$F1 = 2 \cdot \frac{0.55 \cdot 0.833}{0.55 + 0.833} \approx 0.66 \quad (15)$$

Aunque la accuracy es alta (97.5%), resulta engañosa: el modelo puede acertar simplemente prediciendo siempre la clase negativa. La precision del 55% revela que solo la mitad de los diagnósticos positivos son correctos, y el recall del 83.3% indica que aún se pierden 5 pacientes con cáncer. En contextos médicos, el recall suele priorizarse sobre la precision.

V. DISCUSIÓN

Los resultados muestran que no es suficiente evaluar un modelo con una sola métrica. En escenarios reales, es necesario considerar varias medidas dependiendo del contexto del problema.

Por ejemplo, en aplicaciones médicas, es preferible maximizar el recall para evitar omitir casos importantes, aun a costa de incrementar los falsos positivos.

VI. CONCLUSIONES

- La regresión logística permite modelar probabilidades de forma efectiva mediante la composición de una función lineal y la sigmoide.
- La entropía cruzada es clave para entrenar el modelo y se deriva directamente de la máxima verosimilitud.
- Accuracy por sí sola no siempre refleja el desempeño real, especialmente en datasets desbalanceados.
- Precision, recall y F1-score ofrecen un análisis más completo al considerar los distintos tipos de error.
- El AUC es una métrica robusta para comparar modelos independientemente del umbral de decisión.