

Apuntes Clase 1 Semana 7

Jose Maria Vindas Ortiz
2022209471

Escuela de Ingeniería en Computadores
Instituto Tecnológico de Costa Rica

Profesor: Steven Pacheco Portuquez
Curso: IC6200 Inteligencia Artificial
Fecha: 7 de abril de 2026

Abstract—En esta lección se inició con el tema de redes neuronales, pero enfocándose primeramente en el preprocesamiento de datos, el cual es necesario para que este tipo de modelos funcione correctamente. Se explicaron los problemas de los datos y cómo solucionarlos con diferentes técnicas.

I. INTRODUCCIÓN

Antes de iniciar con el tema de redes neuronales, es necesario aprender sobre el preprocesamiento de datos, ya que este tipo de modelos es sensible a los datos, específicamente a la diferencia entre escalas.

Por ejemplo, si se analizan los ingresos y la cantidad de carros que una persona tiene, mientras que los ingresos pueden estar en rangos de miles o incluso millones, la cantidad de carros, con mucha suerte, apenas alcanza el rango de decenas.

Esto puede generar overfitting, ya que el modelo se ajusta más al valor más grande. Debido al uso de derivadas para ajustar el modelo, estas tienden a favorecer valores mayores por sus cambios más notorios.

II. PROBLEMAS

Muchas veces no se tendrán valores perfectos para su uso. Principalmente, se presentan los siguientes problemas:

- Incompletitud
- Inexactitud o ruido
- Inconsistencia

A. Incompletitud

Consiste en valores faltantes en atributos importantes. Sucede debido a diferentes razones:

- Atributos de interés no siempre están disponibles.
- No se incluyen porque no se consideraron importantes en el momento de la selección.
- Datos relevantes no se registran por malentendidos o fallos del equipo.
- Los valores faltantes en atributos pueden necesitar ser inferidos.

B. Inexactitud o ruido

Consiste en errores y valores atípicos en las transacciones. Sucede debido a diferentes razones:

- Instrumentos de recolección de datos defectuosos.
- Errores humanos o computacionales en la entrada de datos.
- Usuarios que ingresan valores falsos para ocultar los reales, por ejemplo, poner "1 de enero" como fecha de cumpleaños para ocultar la real, también conocidos como "datos faltantes disfrazados".

C. Inconsistencia

Consiste en discrepancias en los códigos de departamentos o categorías.

Sucede debido a diferentes razones:

- Diferencias en convenciones de nombres o códigos usados para clasificar elementos.
- Conflictos entre bases de datos o sistemas que manejan el mismo tipo de información.
- Errores al integrar datos de múltiples fuentes heterogéneas.
- Actualizaciones parciales o incorrectas que dejan registros contradictorios.

III. SOLUCIÓN

Para resolver este tipo de problemas, existen tareas principales en el procesamiento de datos:

- Data Cleaning
- Data Integration
- Data Reduction
- Data Transformation
- Data Discretization

IV. DATA CLEANING

Consiste en la eliminación de ruido, corrección de inconsistencias y tratamiento de valores faltantes.

A. Datos faltantes (Missing Values)

En caso de valores faltantes, se tienen varias opciones para solucionarlo:

- Ignorar tuplas con valores faltantes (es riesgoso si la pérdida de datos es significativa, ya que puede generar underfitting).
- Completar manualmente los valores faltantes (es costoso y poco práctico en grandes datasets).
- Usar un valor global constante, como un tipo de "default" (por ejemplo, "Desconocido" o " $-\infty$ ").
- Rellenar con la media (normal), mediana o moda.

– **Nota:** Para este caso, es importante realizarlo por clases. Por ejemplo, en un banco pueden existir dos clases de clientes: clientes de bajo riesgo con ingresos altos y clientes de alto riesgo con ingresos bajos. Si se rellenan valores faltantes de manera general, puede ocurrir que se reemplacen con valores que no corresponden a su clase.

- Inferir valores mediante otros modelos estadísticos o de Machine Learning (ML), por ejemplo: regresión, k-NN o árboles de decisión.

B. Datos ruidosos (Noisy Data)

En caso de datos ruidosos, se tienen varias opciones para solucionarlo:

- Binning
 - Consiste en agrupar valores en intervalos (bins).
 - Se reemplazan por la media, mediana o el valor más cercano del intervalo.
 - Ejemplo: Salarios: [2950, 3000, 3020, 8000].
 - Cualquier valor entre 2900 y 3100 se cambiará por su media, en este caso 2990. El valor 8000 se identifica como un outlier.




Fig. 1. Ejemplo: Técnica de Binning

- Regresión
 - Consiste en ajustar una función matemática a los datos para suavizar el ruido.
 - Puede ser lineal o no lineal.
 - Ejemplo: Ventas mensuales con fuertes fluctuaciones.
 - Se utiliza una regresión lineal para capturar la tendencia general; cualquier valor que se desvie demasiado se considera ruido.




Fig. 2. Ejemplo: Técnica de regresion

- Series Temporales
 - Aplicar técnicas de filtrado para suavizar fluctuaciones.
 - Por ejemplo, la media móvil, que calcula el promedio durante un número específico de periodos. Es utilizada para identificar la tendencia y reducir el ruido o picos.

- Ejemplo: Datos diarios de temperatura con mucho ruido.
- Se calcula la media móvil en días usando la siguiente fórmula:

$$MA(t) = \frac{1}{t} \sum_{i=0}^{t-1} x_{t-i}$$

- Donde x_t es el valor en el día t .
- Se obtiene una curva suavizada que refleja la tendencia real.

V. DATA INTEGRATION

Consiste en combinar datos de múltiples fuentes heterogéneas en un repositorio coherente. Por ejemplo, se pueden tener bases de datos con datos faltantes que se complementan entre sí, por lo que pueden integrarse.

Sin embargo, existe el problema de que, muchas veces, la misma información puede estar registrada varias veces o con valores distintos. Esto genera inconvenientes, ya que los datos duplicados o contradictorios reducen la calidad de la integración.

Para solucionar esto, es necesario aplicar reglas de deduplicación y estandarización de formatos. Además, se pueden utilizar técnicas de correlación para datos numéricos con el fin de analizar la relación entre variables, como las siguientes:

- X^2 (Chi-cuadrado)
- Coeficiente de correlación de Pearson
- Correlación de rangos de Spearman

A. Prueba de asociación X^2 para datos nominales

Es una prueba estadística utilizada para medir la asociación entre variables categóricas.

Se parte de una hipótesis de independencia:

$$H_0 : P(A_i \wedge B_j) = P(A_i)P(B_j)$$

Donde H_0 establece que las variables son independientes (no existe asociación). Se busca aceptar o rechazar esta hipótesis mediante el siguiente criterio:

Las variables se consideran independientes si se cumple la siguiente desigualdad:

$$X^2_{calculado} \leq X^2_{a,df}$$

Para calcular X^2 se utiliza la siguiente fórmula:

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde:

- O_{ij} : es la frecuencia observada en la celda (i,j).
- E_{ij} : es la frecuencia esperada en la celda (i,j).
- r,c: numero de filas y columnas en la tabla de contingencia.

Para calcular la frecuencia esperada de una celda se usa la siguiente formula:

$$E_{i,j} = \frac{(\text{Total Fila } i)(\text{Total Columna } j)}{\text{Total General}}$$

El valor teórico de X^2 se obtiene de la tabla de la distribución Chi-cuadrado, utilizando:

- Nivel de significancia $\alpha = 0.05$ (Que es la probabilidad de rechazar erróneamente H_0).
- Grados de libertad: $df = (Filas - 1)(Columnas - 1)$ (Que es la complejidad de los datos)

TABLA 3-Distribución Chi Cuadrado χ^2

P = Probabilidad de encontrar un valor mayor o igual que el chi cuadrado tabulado, v = Grados de Libertad

v/p	0,001	0,0025	0,005	0,01	0,025	0,05	0,1	0,15	0,2	0,25	0,3
1	10,8274	9,1404	7,8794	6,6349	5,0239	3,8415	2,7055	2,0722	1,6424	1,3233	1,0742
2	13,8150	11,9827	10,5965	9,2104	7,3778	5,9915	4,6052	3,7942	3,2189	2,7726	2,4079
3	16,2660	14,3202	12,8381	11,3449	9,3484	7,8147	6,2514	5,3170	4,6416	4,1083	3,6649

Fig. 3. Tabla de distribución Chi Cuadrada

Una vez obtenidos ambos valores, se comparan:

$$X^2_{calculado} \leq X^2_{a,df}$$

Esta prueba se puede utilizar para:

1. Comparar Feature y Label
 - Si no se cumple la desigualdad, hay asociación (se rechaza H_0):
 - El feature aporta información útil para predecir el label.
 - Puede seleccionarse como variable relevante.
 - Si se cumple la desigualdad, no hay asociación (no se rechaza H_0):
 - El feature no aporta información predictiva.
 - Puede descartarse para simplificar el modelo.
2. Comparar Feature y Feature
 - Si no se cumple la desigualdad, hay asociación (se rechaza H_0):
 - Los features están correlacionados (redundancia).
 - Puede ser necesario eliminar o transformar uno de ellos.
 - Si se cumple la desigualdad, no hay asociación (no se rechaza H_0):
 - Los features aportan información independiente.
 - Es beneficioso, ya que el modelo recibe señales complementarias.

Ejemplo de clase:

Se desea analizar si existe asociación entre el tipo de libro (ficción / no ficción) y el género (hombres / mujeres).

	male	female	Total
fiction	250	200	450
no-fiction	50	1000	1050
Total	300	1200	1500

Se calcula la frecuencia esperada de cada celda:

$$E_{i,j} = \frac{(\text{Total Fila } i)(\text{Total Columna } j)}{\text{Total General}}$$

	male	female	Total
fiction	250 (90)	200 (360)	450
no-fiction	50 (210)	1000 (840)	1050
Total	300	1200	1500

Se calcula X^2 :

$$X^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

$$X^2_{total} = 507,937$$

Se obtiene $X^2_{a,df}$, usando $a = 0,05$ y Grados de Libertad $= (r-1)(c-1) = (2-1)(2-1) = 1$ de la tabla de distribución Chi Cuadrada, obteniendo $X^2_{0,95,1} \approx 3,841$

Comparamos:

$$X^2_{calculado} \leq X^2_{a,df}$$

$$507,937 \leq 3,841$$

No se cumple la desigualdad, se rechaza H_0 (independencia)
Conclusion: Existe asociación entre género y tipo de libro.

B. Pearson Correlation Coefficient

Mide la fuerza y dirección de la relación lineal entre dos variables.

Sus valores están en el rango $[-1, 1]$. Si las variables están altamente relacionadas, el valor se aproxima a los extremos (-1 o 1); mientras que, si no presentan relación, el valor se acerca a 0 .

Esta técnica es sensible a outliers, requiere una distribución aproximadamente normal de valores continuos y solo es adecuada para relaciones lineales.




Fig. 4. Pearson Correlation Coefficient

C. Spearman Rank Correlation

Mide la fuerza y dirección de la asociación monótona entre dos variables, basándose en los rangos de los datos.

Permite detectar relaciones monótonas que no necesariamente son lineales.

Es menos sensible a outliers, no requiere que los datos sean continuos y funciona tanto para relaciones lineales como no lineales. Por esta razón, en muchos casos se prefiere sobre el coeficiente de Pearson.




Fig. 5. Spearman Rank Correlation

VI. DATA REDUCTION

Consiste en reducir el volumen de datos mientras se conserva la información esencial para el análisis, mediante selección de atributos, reducción de dimensionalidad o discretización.

Esto se realiza debido a:

- Mayor eficiencia computacional.
- Reducción de costos de almacenamiento.
- Simplificación de los modelos y mejora en su interpretabilidad.

Una técnica importante es Dimensionality Reduction, que consiste en reducir el número de atributos manteniendo la mayor cantidad de información posible. Algunos ejemplos son PCA y autoencoders.

- PCA (Principal Component Analysis): Técnica de reducción que transforma múltiples variables correlacionadas en un menor número de variables no correlacionadas (componentes principales), conservando la mayor parte de la variabilidad.




Fig. 6. Técnica PCA, Copia de dibujo profesor

- Autoencoders: Técnica de reducción que transforma datos a un vector con solo información contextual, usado por ejemplo, en ChatGPT.




Fig. 7. Técnica Autoencoders

VII. DATA TRANSFORMATION

Consiste en convertir los datos a un formato más adecuado para el análisis. Algunos ejemplos son:

- Normalización y estandarización.
- Agregación de atributos.
- Generación de nuevas variables.
- Transformaciones matemáticas (logarítmica, raíz cuadrada, entre otras).

VIII. DATA DISCRETIZATION

Consiste en reducir el número de valores posibles de un atributo continuo, dividiéndolo en intervalos o categorías. Algunos ejemplos son:

- Binning (uniforme o basado en frecuencia).
- Jerarquías de conceptos (edad → joven, adulto, mayor).

IX. PROBLEMÁTICA: DATOS SIN NORMALIZAR

Como se explicó al principio, los atributos pueden estar en escalas muy diferentes; por ejemplo, salarios en miles o millones y cantidad de carros en unidades o, con suerte, decenas.

Esto provoca que:

- Los algoritmos basados en distancia (KNN, K-means) se vean dominados por la variable con mayor escala.
- En métodos de descenso de gradiente, los pasos de actualización sean desbalanceados y la convergencia se ralentice.

Por lo tanto, es necesario escalar los atributos para ponerlos en igualdad de condiciones.

Para ello, existen principalmente los siguientes métodos de Data Transformation:

A. Normalizacion

- Min-Max Normalization: Se reescala a un rango de [0,1] o [-1,1], donde el nuevo valor se obtiene de la siguiente fórmula, donde x' es el nuevo valor y x el antiguo valor.

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- Z-score (Estandarización): Transforma a media 0 y desviación estándar 1, con la siguiente fórmula.

$$z = \frac{x - \mu}{\sigma}$$




Fig. 8. Comparación de datos, técnicas de Normalización

- Como se observa en la figura 8, se mantiene la distribución, solo afecta la escala.

Además, existe el siguiente método importante dentro de Data Discretization:

B. Binning

Consiste en dividir un atributo continuo en intervalos (bins) y asignar cada valor a uno de ellos.

Esto permite reducir el número de valores distintos y simplificar la representación de los datos.

Los métodos principales son:

- Equal-width binning: Cada intervalo tiene el mismo tamaño.
- Equal-frequency binning: Cada intervalo contiene aproximadamente la misma cantidad de registros.