

Apuntes Semana 7

Apuntes 07/Abr/2026

1st Fernando Sánchez Hidalgo - 2022218688

Tecnológico de Costa Rica
[IC-6200] Inteligencia Artificial

Abstract—This document provides a comprehensive overview of data preprocessing techniques and foundational machine learning concepts discussed during the seventh week of the IC-6200 Artificial Intelligence course. It details methods for addressing data quality issues such as incompleteness, inaccuracy, and inconsistency through cleaning processes like tuple ignoring, manual entry, and various imputation strategies including mean, median, and mode replacement. The text explores data integration and correlation analysis using the Chi-square (χ^2) hypothesis test for nominal data, as well as Pearson and Spearman rank correlation coefficients for measuring feature relationships. Furthermore, it covers essential data transformation techniques like Min-Max normalization and Z-score standardization, alongside discretization methods and k-fold cross-validation. Finally, the document reviews performance metrics—specifically accuracy, precision, recall, and F1-score—and provides a mathematical derivation of log-likelihood for model optimization.

I. ANUNCIOS GENERALES

- Las clases de la semana 9 serán asincrónicas (21 y 23 de Abril)
- Se agregaron dos lecturas nuevas, sus contenidos pueden aparecer en futuros quizzes
 - Artificial Neural Networks
 - Neural networks and Deep Learning

II. QUIZ 3

A. Enunciado del quiz

- 1) Describa 2 técnicas de cada una para evitar un alto sesgo y una alta varianza (20pts)
- 2) Describa k-fold Cross Validation (20pts)
- 3) Describa las fórmulas para calcular Accuracy, Recall, Precision y F1-Score (30pts) (Puntos extra)
- 4) Dada la función de likelihood, desarrolle la log-likelihood en 3 pasos (30pts)

$$L = \prod f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{(1-y_i)}, i = 1 \dots N$$

B. Respuestas del Quiz

- 1)
 - Sesgo
 - Utilizar un modelo más complejo
 - Agregar dimensionalidad al dataset
 - Varianza
 - Simplificar el modelo
 - Eliminar outliers
- 2) Se separa el dataset total en K secciones de igual tamaño, donde se utiliza $K - 1$ secciones para entrenamiento y la última sección para validación, repitiendo el proceso

hasta que todas las secciones se han utilizado para validación una vez.

3)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 - Score = \frac{2 \cdot precision \cdot recall}{precision + recall}$$

Donde:

TP = Positivos reales

TN = Negativos reales

FP = Positivos falsos

FN = Negativos falsos

4)

$$\ln(L) = \sum \ln(f(x_i)^{y_i} \cdot (1 - f(x_i))^{(1-y_i)})$$

$$\ln(L) = \sum \ln(f(x_i))^{y_i} + \ln(1 - f(x_i))^{(1-y_i)}$$

$$\ln(L) = \sum y_i \cdot \ln(f(x_i)) + (1 - y_i) \cdot \ln(1 - f(x_i))$$

III. PREPROCESAMIENTO DE DATOS

Al utilizar datos reales se pueden encontrar una infinita cantidad de problemas, los cuales dificultan el entrenamiento adecuado de un modelo, algunos problemas que podemos encontrar son:

- Incompletitud: Datos faltantes
- Inexactitud: Errors o outliers
- Inconsistencia: Discrepancia en categorías

Estos problemas pueden ser causa de:

- Instrumentos defectuosos
- Errores humanos o de computadora
- Valores falsos en datos obligatorios (datos faltantes disfrazados)
- Respecto a valores incompletos
 - No siempre están disponibles
 - No se consideran importantes en selección

- Datos relevantes no se registran (malentendidos o fallos)
- valores clave faltantes puede necesitar ser inferidos
- Respecto a inconsistencias de datos
 - Convenciones diferentes
 - Problemas de integración entre diferentes fuentes de datos

IV. PASOS PARA EL PREPROCESAMIENTO DE DATOS

A. Data cleaning

La limpieza de datos trata de ajustar la información para maximizar la eficiencia del modelo a entrenar. Algunas de las técnicas a aplicar son:

- Ignorar tuplas (Se pierde información)
- Completar celdas manualmente
- Asignar un valor constante global (desconocido, $-\infty$)
- Rellenar con la media, mediana o moda (todo el dataset o por clases)
- Entrenar otro modelo para aproximar valores
- Ajustar datos para suavizar el ruido
- filtrado de datos (Ejemplo de media móvil para series temporales)

Binning: Agrupar datos por intervalos para suavizar el ruido, usualmente se realiza un reemplazo de los valores por:

- Media del bin
- Mediana del bin
- borde más cercano

B. Data integration

Al unir varias fuentes de datos (BDs), es probable que varios datos se encuentren duplicados. Existen múltiples técnicas para definir datos duplicados o altamente correlacionados.

Pruebas de hipótesis χ^2 : Calcula si 2 datos son independientes, utilizados en datos nominales.

Se acepta H_0 cuando: $\chi^2_{calculado} \leq \chi^2_{\alpha, df}$

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \quad (1)$$

Donde:

O_{ij} : Frecuencia observada en (i,j)

E_{ij} : Frecuencia esperada en (i,j)

df: $filas - 1 \cdot columnas - 1$ r: Número de filas

c: Número de columnas

Interpretación:

- Feature vs label
 - Aceptar H_0 (Son independientes): El feature aporta información útil.
 - Rechazar H_0 (No hay asociación): El feature NO aporta información útil.
- Feature vs Feature
 - Aceptar H_0 (Son independientes): Los features tienen muy poca correlación.

- Rechazar H_0 (Son dependientes): Los features tienen alta correlación (redundantes).

Ejemplo:

	Male	Female	Total
Fiction	250	200	450
Non-Fiction	50	1000	1050
Total	300	1200	1500

$$E_{ij} = \frac{(Total\ fila\ i) \cdot (Total\ fila\ j)}{Total\ general} \quad (2)$$

Cálculo de valores esperados:

	Male	Female	Total
Fiction	250 (90)	200 (360)	450
Non-Fiction	50 (210)	1000 (840)	1050
Total	300	1200	1500

- $Male\ fiction = \frac{(250-90)^2}{90} = 284.444$
- $Male\ nonfiction = \frac{(50-210)^2}{210} = 121.905$
- $Female\ fiction = \frac{(200-360)^2}{360} = 71.111$
- $Female\ nonfiction = \frac{(1000-840)^2}{840} = 30.476$

$$\chi^2_{calculado} = 284.444 + 121.905 + 71.111 + 30.476 = 507.936$$

$$df = 2 - 1 \cdot 2 - 1 = 1$$

$$\chi^2_{\alpha=0.05, df=1} = 3.841$$

$$507.936 > 3.841$$

Rechazamos H_0 : Existe una asociación entre genero y tipo de libro

Correlación de Pearson: Define fuerza y dirección de una relación final.

- Requiere que los datos sigan una distribución normal
- Sensible a outliers




Fig. 1. Ejemplos de correlación de Pearson

Fuente: GeeksForGeeks

Spearman Rank Correlation: Mide correlación similar a la correlación de Pearson, pero no requiere los datos normalizados. Fuente: Laerd statistics




Fig. 2. Ejemplos de correlación de Spearman

C. Data reduction

Reducción de la cantidad de tuplas o features que contiene para simplificar y/o mejorar eficiencia del modelo.

- Dimensionality reduction: Reducir el número de features sin perder información esencial. (PCA o Autoencoders)

D. Data transformation

Existen casos donde los features se encuentran en diferentes escalas (unidades, centenas, millones de centenas, etc.), causando que cada algunos feature afecten más al modelo que otros. Una solución a esto es normalizar los datos para que contengan la misma información, pero a una sola escala.

- Min-Max normalization: Reescala los datos a un rango $[0,1]$ o $[-1,1]$

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- Z-score (Standardization): Escala los datos alrededor de una media (μ) = 0 y desviación estándar (σ) = 1

$$Z = \frac{x - \mu}{\sigma}$$

E. Data discretization

La discretización se basa en transformar datos continuos (espacio de números reales) a datos discretos (espacio de números naturales)

- Redondear
- Truncar decimales
- Binning
 - Equal-width binning: Todos los bins son de igual rango, dividiendo el dataset en n secciones.
 - Equal-frequency binning: Cada bin contiene aproximadamente la misma cantidad de datos.