

Apuntes Semana 7 Clase 1

Curso de Inteligencia Artificial

Nahomi Bolaños Valverde
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica

Abstract—En el presente documento se presentan los apuntes correspondientes a la clase del 7 de abril, perteneciente a la semana 7 del curso de Inteligencia Artificial, impartido por el profesor Steven Pacheco. Durante esta sesión se realizó el Quiz 3 y se revisaron sus respuestas. Posteriormente, se continuó con la materia nueva, dando inicio al estudio del preprocesamiento de datos, abordando su importancia, los problemas comunes en los conjuntos de datos reales y las principales técnicas utilizadas para su tratamiento antes de aplicar algoritmos de aprendizaje automático.

I. RESPUESTAS DEL QUIZ

A. Técnicas para evitar alto sesgo y alta varianza

En el desarrollo de modelos de aprendizaje automático es fundamental manejar adecuadamente el sesgo y la varianza, ya que ambos afectan la capacidad de generalización del modelo.

1) *Alta varianza*: La alta varianza ocurre cuando un modelo se ajusta demasiado a los datos de entrenamiento, capturando incluso el ruido presente en ellos.

- Reducir la complejidad del modelo.
- Reducir la dimensionalidad del conjunto de datos.

2) *Alto sesgo*: El alto sesgo se presenta cuando el modelo es demasiado simple y no logra capturar las relaciones subyacentes del problema.

- Aumentar la complejidad del modelo si este es muy simple.
- Revisar que los *features* seleccionados tengan capacidad de predicción.

B. K-Fold Cross Validation (KCV)

El método de validación cruzada K-Fold divide el conjunto de datos en k partes. En cada iteración, se utilizan $k-1$ partes para el entrenamiento y la parte restante para la validación. Este proceso se repite rotando la partición utilizada para validación, permitiendo obtener una estimación más robusta del desempeño del modelo.

C. Métricas de Evaluación

Las métricas de evaluación permiten medir el desempeño de los modelos de clasificación de forma cuantitativa.

1) *Accuracy*:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

2) *Recall*:

$$\text{Recall} = \frac{TP}{TP + FN}$$

3) *Precision*:

$$\text{Precision} = \frac{TP}{TP + FP}$$

4) *F1-Score*:

$$F1\text{-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

D. Desarrollo de la log-verosimilitud

En modelos como la regresión logística, la función de verosimilitud se define como:

$$\mathcal{L} = \prod_{i=1}^N f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i}$$

Aplicando el logaritmo natural se obtiene:

$$\ln(\mathcal{L}) = \sum_{i=1}^N \ln(f_{w,b}(x_i)^{y_i} (1 - f_{w,b}(x_i))^{1-y_i})$$

$$\ln(\mathcal{L}) = \sum_{i=1}^N [y_i \ln(f_{w,b}(x_i)) + (1 - y_i) \ln(1 - f_{w,b}(x_i))]$$

Este desarrollo facilita la optimización de la función de costo.

E. Notas Importantes

Se indicó que durante la semana que inicia el lunes 20 no se tendrán clases presenciales y que la modalidad será probablemente asincrónica.

II. MATERIA NUEVA: PREPROCESAMIENTO DE DATOS

A. Algoritmo de Redes Neuronales

Las redes neuronales son sensibles a datos que pertenecen a diferentes escalas. Por ejemplo, en un problema de clasificación que incluye salarios y precios de carros, donde los valores pueden estar en unidades, miles o millones, el algoritmo tiende a enfocarse principalmente en la escala más alta. Para evitar este problema, se normalizan o estandarizan los datos antes del entrenamiento.

B. Técnicas de Preprocesamiento de Datos

La mayoría de los conjuntos de datos reales requieren algún tipo de preprocesamiento antes de aplicar técnicas de minería de datos o aprendizaje automático.

1) Problemas encontrados:

- **Incompletitud:** datos incompletos, valores faltantes y *features* vacíos.
- **Inexactitud o ruido:** errores y valores atípicos en las transacciones.
- **Inconsistencia:** discrepancias en códigos de departamentos o categorías.

2) ¿Por qué los datos pueden ser inexactos?:

- Instrumentos de recolección de datos defectuosos.
- Errores humanos o computacionales.
- Ingreso de valores falsos para campos obligatorios, conocidos como datos faltantes disfrazados.

3) ¿Por qué los datos pueden ser incompletos?:

- Atributos de interés no considerados importantes en la etapa de diseño.
- Fallos de equipo o malentendidos durante el registro.
- Valores faltantes en atributos clave que deben ser inferidos.

4) ¿Por qué los datos pueden ser inconsistentes?:

- Conflictos entre bases de datos.
- Diferencias en convenciones de nombres.
- Migraciones de sistemas con actualizaciones parciales.

C. ¿Cómo se resuelve?:

- **Cleaning:** eliminación de ruido y tratamiento de valores faltantes.
- **Integration:** combinación de múltiples *features* en un repositorio.
- **Reduction:** reducción del volumen de datos.
- **Transformation:** normalización y estandarización.
- **Discretization:** conversión de atributos continuos a categóricos.




Fig. 1. Principales técnicas de preprocesamiento de datos

III. DATA CLEANING

El objetivo del proceso de limpieza de datos es mejorar la calidad de la información sin perder datos relevantes.

A. Tratamiento de valores faltantes

- Ignorar tuplas con valores faltantes.
- Completar los datos manualmente.
- Usar valores constantes.
- Imputar media, mediana o moda (preferiblemente por clase).
- Inferir valores mediante modelos estadísticos o de Machine Learning.

B. Datos ruidosos

1) *Binning*: Los valores se reemplazan por la media, mediana o el borde más cercano del bin.

2) *Regresión*: Consiste en ajustar una función matemática, ya sea lineal o no lineal, para suavizar el ruido presente en los datos.

3) Series temporales:

$$MA_7(t) = \frac{1}{7} \sum_{i=0}^6 x_{t-i}$$

Este método permite obtener una curva suavizada que refleja la tendencia real.

IV. DATA INTEGRATION

La integración de datos aborda casos donde la misma información se encuentra duplicada o representada por varios *features*.

A. Prueba de asociación χ^2

$$H_0 : P(A_i \cap B_j) = P(A_i)P(B_j)$$

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

B. Asociación entre variables

1) Feature vs Label:

- Si se rechaza H_0 , el feature es relevante.
- Si no se rechaza H_0 , el feature puede descartarse.

2) Feature vs Feature:

- Asociación indica redundancia.
- No asociación indica información complementaria.

C. Datos numéricos continuos

1) *Coefficiente de correlación de Pearson*: Mide la fuerza y dirección de una relación lineal, con valores en $[-1, 1]$, es sensible a *outliers* y asume normalidad.

2) *Coefficiente de Spearman*: Se basa en rangos, detecta relaciones monótonas y es menos sensible a valores atípicos.

V. DATA REDUCTION

El objetivo de la reducción de datos es disminuir el volumen del conjunto manteniendo la mayor cantidad de información posible. Entre las técnicas más utilizadas se encuentra la reducción de dimensionalidad mediante PCA y autoencoders.

VI. DATA TRANSFORMATION

A. Normalization

1) Min-Max Normalization:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

2) Z-score:

$$z = \frac{x - \mu}{\sigma}$$

VII. DATA DISCRETIZATION

La discretización consiste en dividir un atributo continuo en intervalos o bins, permitiendo una mayor interpretabilidad y compatibilidad con ciertos algoritmos.

VIII. CONCLUSIONES

El preprocesamiento de datos es una etapa fundamental en el desarrollo de modelos de Inteligencia Artificial. Un tratamiento adecuado de los datos permite mejorar el desempeño, la estabilidad y la capacidad de generalización de los modelos, convirtiéndose en un paso imprescindible dentro del flujo de Machine Learning.