

Apuntes Semana 7 Clase 2

Fabricio Mena Mejía
Instituto Tecnológico de Costa Rica
IC-6200 Inteligencia Artificial
fabriciomena11@estudiantec.cr

Abstract—En este presente documento se van a presentar los apuntes de la clase del 9 de Abril, correspondiente a la semana 7 del curso de Inteligencia Artificial, con el profesor Steven Pacheco. Se va a comenzar con la noticia importante de la semana relacionada al tema de la inteligencia artificial, luego como es habitual con un pequeño repaso de la clase anterior (Martes 7 de Abril) sobre el tema de la preprocesamiento de datos y seguidamente se continua propiamente ya con los apuntes del día correspondiente, Jueves 9 de Abril, sobre la introducción a redes neuronales (MNIST, arquitectura, codificación one-hot).

I. NOTICIA SEMANAL: MYTHOS ANTHROPIC

Anthropic presentó un avance denominado *Mythos* y un proyecto asociado llamado *Glasswing*, reportado por la compañía como capaz de identificar vulnerabilidades en software a gran escala. Entre los hitos citados figura la detección de una falla que llevaba "27 años" sin corregirse. Los autores del anuncio destacan pruebas internas y colaboraciones con varias empresas para gestionar la divulgación responsable. Por su capacidad y riesgo potencial, Anthropic ha mantenido el modelo restringido y ha discutido medidas de despliegue controlado. Además, se comenta el modelo comercial y el posible esquema de acceso basado en pago por uso.

Fuente: Anthropic (2026) [1].

Al final se hizo la reflexión de que el salto que se dio desde febrero en gpt 3.1 hasta el día de hoy es inmenso, no habíamos avanzado tanto en tan poco tiempo.

II. REPASO

Este repaso sintetiza los conceptos más relevantes vistos en la clase anterior relacionados con preprocesamiento y análisis estadístico.

A. Técnicas de preprocesamiento de datos

La mayoría de los conjuntos de datos reales requieren algún tipo de preprocesamiento antes de aplicar técnicas de minería de datos o aprendizaje automático.

Problemas comunes encontrados:

- **Incompletitud:** datos incompletos, valores faltantes y features vacíos.
- **Inexactitud o ruido:** errores y valores atípicos en las transacciones.
- **Inconsistencia:** discrepancias en códigos de departamentos o categorías.

¿Cómo se resuelve?

- **Cleaning:** eliminación de ruido y tratamiento de valores faltantes (imputación, eliminación, etc.).

- **Integration:** combinación de múltiples fuentes y features en un repositorio unificado.
- **Reduction:** reducción del volumen de datos (muestreo, agregación, selección de características).
- **Transformation:** normalización y estandarización de atributos para homogeneizar escalas.
- **Discretization:** conversión de atributos continuos a categóricos cuando convenga.

B. Prueba de asociación (chi-cuadrado)

Para variables nominales se emplea la prueba de independencia chi-cuadrado:

$$\chi^2 = \sum_i^r \sum_j^c \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}},$$

donde O_i son frecuencias observadas y E_i las esperadas. Los grados de libertad son $(r - 1)(c - 1)$ para una tabla $r \times c$.

C. Series temporales

En problemas con dependencia temporal es crucial evaluar estacionariedad.

$$MA_7(t) = \frac{1}{7} \sum_{i=0}^6 x_{t-i}$$

D. Correlaciones y reducción de dimensionalidad

Antes de usar Pearson verifique normalidad; en su defecto prefiera Spearman. Para multicolinealidad descarte variables altamente correlacionadas y considere PCA o selección de características cuando la dimensionalidad complica el problema.

III. MATERIA NUEVA: REDES NEURONALES

Hasta el momento hemos tratado de establecer un mecanismo de combinación lineal entre los features y pesos. Después lo hicimos más robusto, así que ese mismo algoritmo sirve también para resolver temas más complejos, clasificación logística y obtenemos a la función sigmoide a la cual se le aplicaba una relación lineal. El siguiente nivel son redes neuronales.

IV. CLASIFICACIÓN DE MNIST

MNIST es un dataset clásico de 60,000 imágenes de entrenamiento y 10,000 de prueba, cada una de 28×28 píxeles en escala de grises.

El flujo típico de trabajo incluye:




Fig. 1. Imagen del dataset de MNIST.

A. Regresión Logística

Con la regresión logística vimos que solo se nos permite identificar si algo es o no, por ejemplo, si la figura 1 es un 5 o no, pero ¿cómo podemos identificar cual es el número de la imagen?




Fig. 2. Imagen del dataset de MNIST convertida a matriz con valores.

Podríamos asumir que cada uno de los pixeles es información importante, y les asignamos un valor, y con base en esos valores tomaremos la decision de si es un 5 o no; para este caso obtendremos un valor total de 784 features.

B. Transformación de la imagen (Flatten)

La operación de *flatten* transforma la matriz 28×28 en un vector de 784 componentes que se usa como entrada de una capa densa fig3.

Ahora para cada uno de esos valores del vector x podemos asignar un peso w e ir trabajando con eso $f_{w,b}(x) = wx + b$. Al final tendremos 784 perillas que ajustar para que nuestro modelo pueda decidir si es un 5 o no. Pero lo que se solicita no es hacer una clasificación binaria, si no una multinomial.

C. Regresión Logística Multinomial

El ejemplo brindado para poder resolver este caso, es supones que tenemos a 10 personas, y cada una de estas está




Fig. 3. Transformación de matriz a vector.

capacitada para poder identificar 1 solo número del 1 al 10, lo que va a pasar al momento de identificar el número mostrado es que solo 1 de las personas va a devolver un 1 que sería la salida cuando se identificó que si es su número esperado y los demás van a devolver 0, indicando que no es el número que ellos pueden detectar. Para lograr esto podemos entrenar varios modelos especializados en identificar 1 solo número.

D. One-hot vector

La etiqueta y se codifica como un vector one-hot de longitud K con un 1 en la posición de la clase verdadera; en la posición que encienda es la clase identificada fig4.




Fig. 4. One-hot vector.

Esto permite que se extrapole a otros problemas de clasificación, por ejemplo a animales o colores.

E. Dense layer / Fully connected

Ahora, que pasa si se tiene más de 1 pixel? Se hace exactamente lo mismo, a cada uno de estos pixeles que serían los features de entrada se les asigna cada uno de los features del dense layer fig5.




Fig. 5. Dense Layer.

F. Conversión entre vector y matriz

En lugar de calcular cada regresión lineal de forma vectorial cambiamos los vectores por matrices para hacer 1 sola operación y no N, donde N es el tamaño de la capa siguiente. Usando de nuevo conceptos de álgebra lineal $y = x_{vector} \cdot w_{vector} + b$ fig6




Fig. 6. Vector por entrada.

G. Matriz de pesos W

La matriz de pesos se representa de la siguiente forma:

$w_{0,0}$	$w_{0,1}$	$w_{0,2}$	...	$w_{0,n-2}$	$w_{0,n-1}$	$w_{0,n}$
$w_{1,0}$	$w_{1,1}$	$w_{1,2}$	...	$w_{1,n-2}$	$w_{1,n-1}$	$w_{1,n}$
...	...	...	...	...	...	...
$w_{j,0}$	$w_{j,1}$	$w_{j,2}$	...	$w_{j,n-2}$	$w_{j,n-1}$	$w_{j,n}$

Fig. 7. Matriz de pesos.

Donde:

- j = El tamaño de la siguiente capa
- n = El tamaño de features

Para el caso de una imagen de MNIST la matriz de pesos tiene una capa de entrada de 784 y una capa de salida de 10, esta se vería de la siguiente forma:

$w_{0,0}$	$w_{0,1}$	$w_{0,2}$	...	$w_{0,784}$
$w_{1,0}$	$w_{1,1}$	$w_{1,2}$	...	$w_{1,784}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$w_{10,0}$	$w_{10,1}$	$w_{10,2}$	...	$w_{10,784}$

Así tenemos un vector de tamaño 10 para representar el bias, y haciendo el cálculo se tienen 7840 pesos que ajustar

con el descenso del gradiente y cada uno debe de ser ajustado para que el modelo funcione correctamente. Al final el modelo tiene la siguiente forma:




Fig. 8. Red neuronal de 1 capa para MNIST.

REFERENCES

- [1] Anthropic, "Mythos preview", 2026. [Online]. Available: <https://red.anthropic.com/2026/mythos-preview/>