

Apuntes Semana 7 Clase 2

Darío Espinoza Aguilar
Instituto Tecnológico de Costa Rica
Inteligencia Artificial
darioespinoza477@estudiantec.cr

Resumen—El presente documento recoge los apuntes correspondientes a la sesión del 9 de abril, perteneciente a la semana 7 del curso de Inteligencia Artificial. La clase inicia con la noticia relevante de la semana en el ámbito de la inteligencia artificial, continúa con un breve repaso de la clase del martes 7 de abril sobre preprocesamiento de datos, y finaliza con el contenido nuevo visto el jueves 9 de abril, enfocado en la introducción a redes neuronales.

I. NOTICIA SEMANAL: MYTHOS DE ANTHROPIC

Anthropic dio a conocer un avance denominado *Mythos* junto con un proyecto relacionado llamado *Glasswing*, descrito por la compañía como un sistema capaz de detectar vulnerabilidades en software a gran escala. Entre los logros destacados se menciona el hallazgo de una falla que permanecía sin solución desde hacía 27 años. La empresa resaltó resultados de pruebas internas y colaboraciones con distintas organizaciones para gestionar la divulgación de manera responsable. Dada su capacidad y el riesgo potencial que representa, Anthropic ha mantenido el modelo bajo restricciones de acceso y ha evaluado esquemas de despliegue controlado. Además, se discutió su modelo comercial, que contempla un posible esquema de pago por uso.

Fuente: Anthropic (2026) [1].

Como reflexión final, se señaló que el avance experimentado desde febrero, con Gemini 3.1, hasta la fecha actual ha sido extraordinario, pues rara vez se observa un progreso tan acelerado en un periodo tan corto.

II. REPASO

A continuación se sintetizan los conceptos más relevantes abordados en la sesión anterior, referentes al preprocesamiento y el análisis estadístico de datos.

II-A. Técnicas de Preprocesamiento de Datos

La mayoría de los conjuntos de datos del mundo real requieren algún tipo de tratamiento previo antes de aplicar algoritmos de minería de datos o aprendizaje automático.

Entre los problemas más frecuentes se encuentran:

- **Incompletitud:** presencia de registros incompletos, valores ausentes o atributos vacíos.
- **Inexactitud o ruido:** errores y valores atípicos dentro de las transacciones.
- **Inconsistencia:** discrepancias en códigos de categorías o departamentos.

Las estrategias habituales para abordar estos problemas son:

- **Limpieza (Cleaning):** eliminación del ruido y manejo de valores faltantes mediante imputación, eliminación, entre otros.
- **Integración (Integration):** unificación de múltiples fuentes y atributos en un repositorio centralizado.
- **Reducción (Reduction):** disminución del volumen de datos a través de muestreo, agregación o selección de características.
- **Transformación (Transformation):** normalización y estandarización de atributos para homogeneizar sus escalas.
- **Discretización (Discretization):** conversión de atributos continuos en categóricos cuando resulta conveniente.

II-B. Prueba de Asociación (Chi-Cuadrado)

Para variables nominales se utiliza la prueba de independencia chi-cuadrado:

$$\chi^2 = \sum_i^r \sum_j^c \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}} \quad (1)$$

donde $O_{i,j}$ representa las frecuencias observadas y $E_{i,j}$ las esperadas. Los grados de libertad corresponden a $(r-1)(c-1)$ para una tabla de $r \times c$.

II-C. Series Temporales

En problemas con dependencia temporal es fundamental evaluar la estacionariedad de la serie. Una medida común es la media móvil de orden 7:

$$MA_7(t) = \frac{1}{7} \sum_{i=0}^6 x_{t-i} \quad (2)$$

II-D. Correlaciones y Reducción de Dimensionalidad

Antes de aplicar la correlación de Pearson es necesario verificar la normalidad de los datos; de lo contrario, se recomienda emplear la correlación de Spearman. Ante la presencia de multicolinealidad, conviene descartar las variables altamente correlacionadas y considerar técnicas como PCA o selección de características cuando la alta dimensionalidad complica el modelado.

III. MATERIA NUEVA: REDES NEURONALES

Hasta el momento, el enfoque ha consistido en establecer combinaciones lineales entre los atributos de entrada y los pesos del modelo. Dicho esquema se fue refinando para dar soporte a tareas más complejas, como la clasificación logística, donde se introduce la función sigmoide aplicada sobre una

relación lineal. El paso siguiente en esta evolución natural son las redes neuronales.

IV. CLASIFICACIÓN CON MNIST

MNIST es un conjunto de datos clásico compuesto por 60,000 imágenes de entrenamiento y 10,000 de prueba, cada una de 28×28 píxeles en escala de grises.




Figura 1. Imagen del dataset de MNIST.

IV-A. Regresión Logística

Con la regresión logística únicamente es posible determinar si una imagen pertenece o no a una clase determinada; por ejemplo, si el dígito mostrado es un 5 o no. Sin embargo, este enfoque no permite distinguir directamente cuál de los diez dígitos posibles aparece en la imagen.

Assumiendo que cada píxel constituye información relevante, se le asigna un valor numérico y, con base en ellos, se toma la decisión de clasificación. Para el caso de MNIST, esto produce un total de 784 atributos de entrada.

IV-B. Transformación de la Imagen (Flatten)

La operación de *flatten* convierte la matriz 28×28 en un vector de 784 elementos, el cual se emplea como entrada de una capa densa, como se ilustra en la Fig. 3.

A cada componente x del vector resultante se le asigna un peso w , de modo que la función del modelo adopta la forma $f_{w,b}(x) = wx + b$. En consecuencia, se tienen 784 parámetros ajustables para que el modelo pueda realizar la clasificación deseada. No obstante, el objetivo no es una clasificación binaria, sino multinomial.




Figura 2. Imagen del dataset de MNIST convertida a matriz con valores.




Figura 3. Transformación de matriz a vector.

IV-C. Regresión Logística Multinomial

Para abordar la clasificación multinomial se propone la siguiente analogía: supóngase que se cuenta con 10 personas, cada una entrenada para reconocer únicamente un dígito del 0 al 9. Al presentarles una imagen, solo la persona correspondiente al dígito correcto devuelve un 1, mientras que las demás devuelven 0. Esto equivale a entrenar un modelo especializado por cada clase posible.

IV-D. Vector One-Hot

La etiqueta y se representa como un vector *one-hot* de longitud K , donde la posición activa (con valor 1) indica la clase verdadera; las demás posiciones permanecen en 0, como se muestra en la Fig. ??.

Esta representación es generalizable a otras tareas de clasificación, como el reconocimiento de animales o la identificación de colores.

IV-E. Capa Densa (Dense Layer / Fully Connected)

Cuando la entrada cuenta con más de un píxel, el procedimiento se extiende de manera natural: a cada uno de los atributos de entrada se le conecta con cada nodo de la capa densa, como se aprecia en la Fig. ??.

IV-F. Conversión entre Vector y Matriz

En lugar de calcular cada regresión lineal de forma individual, es posible reemplazar los vectores por matrices y realizar una única operación, en lugar de N operaciones separadas (donde N es el tamaño de la capa siguiente). Retomando conceptos de álgebra lineal:

$$\hat{y} = x_{vector} \cdot w_{vector} + b \quad (3)$$

IV-G. Matriz de Pesos W

La matriz de pesos tiene la siguiente estructura general, donde j denota el tamaño de la capa siguiente y n el número de atributos:

$w_{0,0}$	$w_{0,1}$	$w_{0,2}$	...	$w_{0,n-2}$	$w_{0,n-1}$	$w_{0,n}$
$w_{1,0}$	$w_{1,1}$	$w_{1,2}$	...	$w_{1,n-2}$	$w_{1,n-1}$	$w_{1,n}$
...	...	...	...	...	...	...
$w_{j,0}$	$w_{j,1}$	$w_{j,2}$	...	$w_{j,n-2}$	$w_{j,n-1}$	$w_{j,n}$

Figura 4. Matriz de pesos.

Para el caso de MNIST, la capa de entrada tiene 784 nodos y la capa de salida 10, de modo que la matriz de pesos adopta la siguiente forma:

$$\begin{pmatrix} w_{0,0} & w_{0,1} & w_{0,2} & \cdots & w_{0,784} \\ w_{1,0} & w_{1,1} & w_{1,2} & \cdots & w_{1,784} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_{10,0} & w_{10,1} & w_{10,2} & \cdots & w_{10,784} \end{pmatrix}$$

Adicionalmente, se requiere un vector de sesgo (*bias*) de tamaño 10. En total, el modelo cuenta con 7,840 pesos que deben ajustarse mediante descenso del gradiente para que el modelo opere correctamente.

La arquitectura resultante del modelo se ilustra en la Fig. 5.

REFERENCIAS

- [1] Anthropic, “Mythos preview”, 2026. [En línea]. Disponible en: <https://red.anthropic.com/2026/mythos-preview/>




Figura 5. Red neuronal de 1 capa para MNIST.