

Apuntes de Clase

IC-6200 Inteligencia Artificial

Kevin Jiménez Molinares
Instituto Tecnológico de Costa Rica
Profesor: Steven Pacheco Portugués
Fecha: 14 de abril de 2026

I. QUIZ IV

I-A. Anote la fórmula y explique la diferencia entre normalización y estandarización.

- **Normalización (Min-Max):** Reescala los datos originales a un intervalo específico, generalmente $[0, 1]$.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (1)$$

- **Estandarización (Z-score):** Ajusta los datos para que tengan una media (μ) de 0 y una desviación estándar (σ) de 1.

$$x' = \frac{x - \mu}{\sigma} \quad (2)$$

I-B. ¿Cuál prueba debo utilizar para probar la independencia de dos variables en caso de que sean categóricas y cuál en caso de que sean numéricas no normales?

- **Variables Categóricas:** Se utiliza la prueba de **chi-cuadrado**.
- **Variables Numéricas no normales:** Se emplea la **correlación de Spearman**.

I-C. Anote la fórmula para calcular el F1-score.

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

I-D. Describa en qué consiste el Data Cleaning y Data Reduction.

- **Data Cleaning:** es un proceso de limpieza de datos corrigiendo inconsistencias.
- **Data Reduction:** es un proceso que simplifica el conjunto de datos.

I-E. Mencione 2 funciones de activación distintas a la función sigmoide que pueden ser usadas en redes neuronales.

- **ReLU:** $\text{ReLU}(x) = \max(0, x)$.
- **Tangente hiperbólica:** $\tanh(x)$, con rango en $[-1, 1]$.

II. CORRECCIONES Y OBSERVACIONES DE LAS TAREAS

- El informe debe seguir el formato IEEE con una introducción que incluya referencias a artículos publicados y una metodología detallada paso a paso.
- Las imágenes deben estar numeradas, bien referenciadas en el texto y acompañadas de una explicación fundamentada.

- Los resultados de las pruebas es obligatorio incluirlos en el informe.
- Se debe evitar a toda costa incluir bloques de código pegado en el informe, para eso está el colab el informe es para presentar resultados.

Es importante tener en cuenta estas correcciones en los informes para las tareas sin incluir la 1 y 2 y ahorita principalmente para el proyecto.

III. REDES NEURONALES

III-A. Evolución de los Modelos

Todo inicia con la **regresión lineal**, definida por la función:

$$f_{w,b}(x) = wx + b \quad (4)$$

Para problemas de clasificación, evolucionamos hacia la **regresión logística**. En este modelo, se toma la salida de la combinación lineal y se le aplica una **función sigmoide** $\sigma(z)$, la cual transforma cualquier valor real en una probabilidad dentro del rango $[0, 1]$:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \implies P(y = 1|x) = \sigma(wx + b) \quad (5)$$

El dataset MNIST consiste en imágenes de dígitos escritos a mano de aproximadamente 60,000 imágenes de entrenamiento, los valores de los píxeles se normalizan comúnmente al rango $[0, 1]$. El objetivo es clasificar el dígito entre 10 clases posibles: $\{0, \dots, 9\}$, una imagen de 28×28 píxeles entonces al aplanar la matriz de la imagen, se obtiene un vector de entrada de 784 características entonces para manejar las 10 categorías, las etiquetas se convierten a una codificación en un vector de dimensión 10 lleno de ceros, excepto en el índice de la clase correcta, donde se coloca un 1.

Este enfoque permite ejecutar múltiples regresiones logísticas simultáneamente (una neurona de salida por cada clase). El modelo predice correctamente si el índice del bit más alto en la salida coincide con la posición del '1' en el vector *one-hot* de la etiqueta real.

Tener miles de regresiones implica calibrar miles de pesos; realizar multiplicaciones elemento por elemento resulta computacionalmente ineficiente pero aplicando conceptos de álgebra lineal se puede corregir.

- **Matrices de Pesos (W):** Agrupamos los pesos de todas las conexiones en una matriz compacta.

- **Dimensiones:** Si el modelo recibe n características (*features*) y debe calcular m salidas (o neuronas en la siguiente capa), la matriz W tendrá dimensiones $m \times n$.
 - En el caso de **MNIST** ($n = 784, m = 10$), el último elemento de la matriz corresponde al peso de la décima neurona para la característica 784
- **Fórmula Matricial:** El procesamiento simultáneo se define mediante una transformación afín seguida de una función de activación ϕ :

$$Z = XW^T + b \quad (6)$$

Esto permite procesar no solo muestras individuales, sino también **mini-lotes** (*mini-batches*) donde cada fila de la matriz X representa una instancia de datos distinta.

III-B. Ejemplo

Supongamos un vector de entrada $x = [3, 4, 5, 6]$. Para una capa con dos neuronas, los parámetros serían:

1. **Neurona 1:** $W_1 = [3, 2, 4, 5]$, $b_1 = 2$.
2. **Neurona 2:** $W_2 = [4, 3, 2, 1]$, $b_2 = 3$.

Desarrollo escalar:

$$\begin{aligned} n_1 &= (3 \cdot 3) + (4 \cdot 2) + (5 \cdot 4) + (6 \cdot 5) + 2 = 67 + 2 = 69 \\ n_2 &= (3 \cdot 4) + (4 \cdot 3) + (5 \cdot 2) + (6 \cdot 1) + 3 = 40 + 3 = 43 \end{aligned}$$

Representación matricial:

$$\begin{bmatrix} 3 & 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} 3 & 4 \\ 2 & 3 \\ 4 & 2 \\ 5 & 1 \end{bmatrix} + \begin{bmatrix} 2 & 3 \end{bmatrix} = \begin{bmatrix} 69 & 43 \end{bmatrix} \quad (7)$$

Al estructurarlo matricialmente, obtenemos el vector de salida $y = (69, 43)$ de forma directa y eficiente.

IV. MATERIA NUEVA

La clasificación binaria— desde la perspectiva de una red neuronal a diferencia de un modelo lineal simple, la red genera una salida en el rango $[0, 1]$. Tras aplicar una **función sigmoide**, este valor se interpreta como la probabilidad de que el dato pertenezca a la clase positiva ($y = 1$).

Y sigue la estructura:

- **Entrada de datos:** Recepción de atributos $(x_1, x_2, \dots, x_n)$, como píxeles o variables numéricas.
- **Procesamiento en paralelo:** Los datos se distribuyen en una **capa oculta**. Por ejemplo, diez neuronas ejecutando regresiones logísticas simultáneamente.
- **Integración final:** Las activaciones de la capa oculta se combinan en una neurona de salida final, la cual determina la etiqueta binaria.

Ventaja estratégica: La neurona final no analiza los datos crudos, sino un vector de activaciones procesado. La capa oculta funciona como un *extractor de características* que traduce la entrada original a un espacio de representación más sencillo de clasificar.

Un concepto crítico es que la relación entre la entrada y la salida deja de ser lineal. Al encadenar múltiples capas, cada

una con su propia **función de activación**, introducimos no linealidades

Sin estas funciones, cualquier red neuronal, sin importar su profundidad colapsaría matemáticamente en una simple regresión lineal. La composición de capas permite aprender patrones curvos y fronteras de decisión complejas.

La organización de una red neuronal se divide en tres bloques fundamentales:

1. **Capa de Entrada:** Punto de acceso de la información.
2. **Capas Ocultas o intermedias:** El motor del aprendizaje. Incrementar el número de capas (n) aumenta la *capacidad de representación* del modelo para entender problemas complejos.
3. **Capa de Salida:** Su dimensión depende del problema. Una neurona para clasificación binaria o k neuronas para clasificación multiclase.

Hiperparámetros: El número de capas y la cantidad de neuronas por capa son decisiones de diseño. No existe una configuración única; se optimizan según el rendimiento en el problema específico.

El éxito del *Deep Learning* se sustenta en dos pilares matemáticos:

- **Composición de transformaciones:** El encadenamiento sucesivo de matrices de pesos $(W_0, W_1, \dots, W_n)$. Cada capa aplica una transformación afín sobre la salida de la anterior.
- **Optimización por Gradiente:** Para que el modelo aprenda, todas las funciones deben ser **diferenciables**. Esto permite el uso del *Descenso del Gradiente* para ajustar los pesos y minimizar la función de pérdida.

Gracias al entrenamiento automático mediante gradientes, estas arquitecturas resuelven retos en visión por computadora, procesamiento de lenguaje natural y reconocimiento de voz que antes resultaban impensable.

V. AVISOS

- El martes y viernes de la siguiente semana son asíncronos.
- Para el jueves se recomienda leer el proyecto