

Resumen de: Redes Neuronales Convolucionales – Arquitecturas y Explicabilidad

Victor Aymerich
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica

Abstract—Este documento resume los conceptos fundamentales de las redes neuronales convolucionales (CNN) vistos en clase. Se describen las capas de convolución multicanal, la operación de *pooling*, y la capa completamente conectada (*fully connected*) que forma el clasificador final. Además, se comparan distintas arquitecturas históricas – LeNet, AlexNet, ZFNet, GoogLeNet, VGG16, ResNet y DenseNet – destacando las motivaciones de cada evolución arquitectónica. Finalmente, se revisan técnicas para mejorar la explicabilidad de las CNN, como visualización de activaciones, mapas de calor y proyecciones de embeddings.

Index Terms—Redes Convolucionales, CNN, Max Pooling, Arquitecturas Deep Learning, AlexNet, ResNet, Explicabilidad

I. INTRODUCCIÓN

Las redes neuronales convolucionales (CNN) constituyen el enfoque dominante para el procesamiento y clasificación de imágenes. A diferencia de las redes densas tradicionales, las CNN explotan la estructura espacial de las imágenes mediante filtros (*kernels*) compartidos, reduciendo drásticamente la cantidad de parámetros entrenables.

El flujo general de una CNN comprende tres etapas: (1) extracción de características mediante capas convolucionales y de activación, (2) reducción de dimensionalidad mediante capas de *pooling*, y (3) clasificación mediante una red completamente conectada (*fully connected*) que recibe el vector de características comprimido.

II. CAPAS CONVOLUCIONALES CON IMÁGENES MULTICANAL

A. Imágenes multicanal

Una imagen en color de dimensiones $224 \times 224 \times 3$ posee tres canales (R, G, B). El kernel de convolución debe tener la misma profundidad que la imagen de entrada. Por lo tanto, para una entrada de profundidad C , el kernel tiene forma $k \times k \times C$, y la operación de convolución produce un único mapa de activación (*feature map*).

Para obtener N mapas de activación distintos se aprenden N kernels independientes, resultando en un volumen de salida de dimensiones:

$$W_{\text{sal}} = \frac{W_{\text{ent}} - k + 2p}{s} + 1 \quad (1)$$

donde W_{ent} es el ancho/alto de entrada, k el tamaño del kernel, p el *padding* y s el *stride*.

B. Principio de pesos compartidos

Un mismo filtro se desplaza por toda la imagen asumiendo que la característica que detecta (línea horizontal, borde, color) es igualmente válida en cualquier posición espacial (x, y) . Esto reduce el número de parámetros de forma exponencial frente a una capa densa equivalente.




Fig. 1: Convolución sobre imagen multicanal de 3 canales con dos kernels, produciendo dos *feature maps*.

III. CAPA DE POOLING

A. Max Pooling

La capa de *pooling* reduce el ancho y el alto de los mapas de activación sin modificar la profundidad. La configuración más común es **Max Pooling** con kernel 2×2 y stride 2, lo que divide cada dimensión espacial a la mitad:

$$W_{\text{sal}} = \frac{W_{\text{ent}} - k_p}{s_p} + 1 \quad (2)$$

donde k_p es el tamaño del kernel de *pooling* y s_p el stride.

La operación selecciona el valor máximo dentro de cada ventana, preservando la activación más fuerte (mayor información). La profundidad se mantiene exactamente igual: todos los *feature maps* son reducidos de forma independiente.




Fig. 2: Max Pooling 2×2 con stride 2 sobre una imagen 4×4 . La imagen resultante es 2×2 .

B. Alternativas al Max Pooling

- **Average Pooling:** calcula el promedio de la ventana. Fue popular antes de que estudios demostraran la superioridad del Max Pooling.
- **L2 Pooling:** utiliza la norma L2 de los valores de la ventana.

La capa de *pooling* **no posee parámetros entrenables**; es una transformación fija.

IV. CAPA COMPLETAMENTE CONECTADA Y VECTOR DE EMBEDDINGS

Al finalizar el bloque convolucional, el volumen resultante (p.ej. $7 \times 7 \times 1024$) se aplana (*flatten*) para formar un vector unidimensional. Este vector condensa la información semántica de toda la imagen y se entrega como entrada a una o más capas densas que realizan la clasificación final.




Fig. 3: Flujo completo de una CNN: extracción de características → vector de embeddings → clasificador.

Existe un *trade-off* en el tamaño del vector:

- Vectores más grandes ⇒ mayor capacidad representativa, pero más parámetros en la capa densa.
- Vectores más pequeños ⇒ modelo más ligero, pero menor capacidad de discriminación.

V. KERNELS PEQUEÑOS VS. KERNELS GRANDES

Una técnica clave en el diseño moderno de CNN es preferir múltiples convoluciones con kernels pequeños (3×3) sobre una sola convolución con kernel grande. La Tabla I compara ambas opciones para un campo receptivo efectivo de 7×7 :

TABLE I: Comparación de parámetros: kernel 7×7 vs. tres capas 3×3

Configuración	Parámetros	No linealidades
1 capa, kernel 7×7	$49C^2$	1 (lineal)
3 capas, kernel 3×3	$27C^2$	3 (ReLU cada capa)

Las ventajas de los kernels pequeños son:

- 1) **Menos parámetros:** $27C^2 < 49C^2$.
- 2) **Más no-linealidades:** se aplica ReLU después de cada convolución, aumentando la expresividad del modelo.

VI. ARQUITECTURAS CLÁSICAS DE CNN

A. LeNet (1998)

Primera arquitectura CNN exitosa, diseñada para imágenes de 32×32 . Utiliza dos bloques de convolución + *subsampling* seguidos de capas densas. Produce 6 y 16 *feature maps* respectivamente.




Fig. 4: Arquitectura LeNet-5: entrada $32 \times 32 \rightarrow \text{conv} \rightarrow \text{pool} \rightarrow \text{conv} \rightarrow \text{pool} \rightarrow \text{FC}$.

B. AlexNet (2012)

Arquitectura que marcó el inicio del auge del *deep learning*. Sus características principales son:

- Entrada: $227 \times 227 \times 3$.
- Primera capa: kernel 11×11 , stride 4, 96 *feature maps* → salida $55 \times 55 \times 96$.
- Entrenamiento distribuido en dos GPUs (48 kernels por GPU).
- Introdujo el uso masivo de ReLU y *Dropout*.

C. ZFNet (2013)

Misma idea que AlexNet pero con kernels más pequeños en las primeras capas (de 11×11 a 7×7), lo que reduce parámetros y mejora resultados. Demuestra que pequeños ajustes arquitectónicos justifican una publicación científica.

D. GoogLeNet / Inception (2014)

Reduce los parámetros de ~ 60 M (AlexNet) a ~ 4 M mediante el **módulo Inception**. En lugar de elegir un tamaño de kernel, aplica en paralelo convoluciones 1×1 , 3×3 , 5×5 y Max Pooling 3×3 , concatenando todos los *feature maps* resultantes:




Fig. 5: Módulo Inception: concatenación de convoluciones 1×1 , 3×3 , 5×5 y Max Pooling.

Al final de la red se aplica **Average Pooling** global sobre los mapas 7×7 , produciendo un vector de 1024 elementos, seguido de un clasificador con *Dropout*.

E. VGG16 y VGG19

Redes muy profundas (16 y 19 capas respectivamente) basadas únicamente en convoluciones 3×3 apiladas, seguidas de Max Pooling. Obtienen alta precisión a costa de un mayor número de parámetros.

F. ResNet – Conexiones Residuales

Para redes muy profundas (>30 capas) el gradiente puede degradarse durante la retropropagación (*vanishing gradient*). ResNet introduce las **conexiones residuales** (o *skip connections*): la salida de un bloque de convoluciones se suma con su entrada antes de continuar:

$$y = \mathcal{F}(x, \{W_i\}) + x \quad (3)$$

donde $\mathcal{F}$ representa las transformaciones convolucionales del bloque.




Fig. 6: Bloque residual de ResNet: la entrada x se suma a la salida del bloque convolucional.

G. DenseNet

Lleva las conexiones residuales al extremo: cada capa recibe como entrada la concatenación de los mapas de activación de **todas las capas anteriores**. Esto maximiza la reutilización de características y reduce aún más el número de parámetros necesarios.

La Tabla II resume las principales arquitecturas.

TABLE II: Comparación de arquitecturas CNN

Arquitectura	Año	Capas	Parámetros aprox.
LeNet-5	1998	7	~60 K
AlexNet	2012	8	~60 M
ZFNet	2013	8	~58 M
GoogLeNet	2014	22	~4 M
VGG16	2014	16	~138 M
ResNet-34	2015	34	~21 M
DenseNet	2016	var.	~8 M

VII. REGLAS DE DISEÑO NO ESCRITAS

La comunidad de *deep learning* ha consolidado ciertas prácticas comunes:

- El tamaño de la imagen de entrada debe ser divisible entre 2 para facilitar los cálculos de *pooling* (ej. 32, 64, 224).
- Preferir kernels pequeños: 3×3 con *padding* 1 o 5×5 con *padding* 2, para preservar las dimensiones espaciales.

- Usar **Max Pooling** 2×2 con stride 2 como capa estándar de reducción.
- Aplicar la función de activación **ReLU** después de cada convolución.
- Dejar la responsabilidad de reducir dimensiones a la capa de *pooling*, no a la convolución.

VIII. EXPLICABILIDAD EN CNN

Las CNN tienen poca explicabilidad intrínseca: no es directo determinar *por qué* la red tomó una decisión. Existen varias técnicas para intentar interpretarlas:

A. Visualización de activaciones y filtros

Se inspeccionan los pesos aprendidos por los kernels de la primera capa, donde los filtros suelen especializarse en detectar colores, bordes y líneas diagonales. En capas profundas esta visualización pierde sentido semántico para el humano, aunque es más significativa para la red.

B. Proyección de embeddings

El vector de características de salida (embedding) se proyecta a 2D mediante técnicas como PCA o t-SNE. Datos semánticamente similares quedan agrupados en el plano, lo que permite verificar si la red ha aprendido representaciones coherentes.




Fig. 7: Proyección t-SNE de embeddings de 4096 dimensiones. Objetos con características similares (p.ej. pájaros y aviones) aparecen agrupados.

C. Oclusión de regiones

Se coloca un parche sobre distintas regiones de la imagen y se observa cómo cambian las activaciones. Si al cubrir una zona clave (p.ej. la cara del animal) la activación cae, esa zona es determinante para la decisión del modelo.

D. Mapas de calor (Grad-CAM)

Los mapas de activación de las últimas capas convolucionales se combinan para producir un mapa de calor que indica qué región de la imagen contribuyó más a la predicción. Lo ideal es que el mapa se concentre sobre el objeto de interés.




Fig. 8: Mapa de calor superpuesto sobre la imagen original: las zonas rojas indican mayor contribución a la decisión del clasificador.

IX. CONCLUSIONES

- Las CNN reducen drásticamente los parámetros respecto a capas densas gracias al mecanismo de **pesos compartidos**.
- El **Max Pooling** es la técnica estándar de reducción espacial; no posee parámetros entrenables.
- Kernels pequeños apilados (3×3) son preferibles a kernels grandes: menos parámetros y mayor no-linealidad.
- La evolución AlexNet $\rightarrow$ VGG $\rightarrow$ GoogLeNet $\rightarrow$ ResNet $\rightarrow$ DenseNet muestra una búsqueda continua de redes más profundas y eficientes.
- Las **conexiones residuales** (ResNet) solucionan el problema del *vanishing gradient* en redes muy profundas.
- La **explicabilidad** sigue siendo un reto abierto; herramientas como Grad-CAM y t-SNE ofrecen aproximaciones parciales.