

Apunte Semana 11 Clase I Inteligencia Artificial

Fabrizio Picado Alvarado
2022104933
Escuela de Ingeniería en Computación
Tecnológico de Costa Rica
Profesor: Steven Pacheco Portuquez
Curso: IC6200 Inteligencia Artificial
Fecha: 05 de mayo de 2026

I. INTRODUCCIÓN

Las Redes Neuronales Convolucionales (*Convolutional Neural Networks*, CNN) fueron diseñadas principalmente para procesar información visual, permitiendo analizar imágenes de manera automática mediante el aprendizaje de patrones y características relevantes.

El funcionamiento de una CNN se basa en múltiples capas que trabajan de manera jerárquica para transformar una imagen de entrada en representaciones abstractas útiles para clasificación o reconocimiento.




Figura 1. Arquitectura básica de una CNN

II. FUNCIONAMIENTO BÁSICO DE LAS CNN

II-A. Imágenes como entrada de la red

Una CNN recibe una imagen como entrada. Matemáticamente, una imagen se representa mediante una matriz de píxeles donde cada posición contiene información numérica relacionada con intensidad o color.

En imágenes en escala de grises, cada píxel posee un único valor numérico. Por otro lado, las imágenes a color normalmente utilizan tres canales: rojo (*Red*), verde (*Green*) y azul (*Blue*), conocidos como RGB. Debido a esto, una imagen a color puede representarse mediante tres matrices superpuestas.

Las dimensiones de entrada son importantes porque la red procesa imágenes con tamaños específicos. Cada imagen contiene información espacial que será utilizada posteriormente para detectar patrones visuales.

II-B. Convolución

La convolución es una de las operaciones fundamentales dentro de las CNN. Consiste en aplicar pequeños filtros o

kernels sobre regiones específicas de la imagen para detectar patrones locales.




Figura 2. Proceso de convolución mediante un kernel recorriendo una imagen

Los filtros son matrices pequeñas que se desplazan sobre toda la imagen realizando multiplicaciones y sumas entre sus valores y los píxeles correspondientes. El resultado de esta operación genera nuevos valores que forman un mapa de activación o *feature map*.

Durante la convolución, el filtro se desplaza utilizando un parámetro denominado *stride*, el cual determina cuántos píxeles avanza el filtro en cada movimiento.

Por ejemplo:

- Algunos filtros detectan bordes horizontales.
- Otros detectan bordes verticales.
- Algunos detectan texturas.
- Otros identifican patrones específicos.

II-C. Dimensiones y filtros convolucionales

En una CNN, cada filtro posee pesos que son aprendidos durante el entrenamiento. Estos pesos permiten detectar patrones específicos dentro de la imagen.

Por ejemplo, en AlexNet se utiliza una imagen de entrada de dimensiones $227 \times 227 \times 3$, donde el valor 3 representa los canales RGB.

La primera capa convolucional utiliza 96 filtros de tamaño $11 \times 11 \times 3$. Cada filtro procesa simultáneamente los tres canales de la imagen de entrada.

Como resultado de aplicar la convolución se obtiene un volumen de salida de dimensiones $55 \times 55 \times 96$, donde 96 corresponde a la cantidad de *feature maps* generados.

II-D. Filtros y extracción de características

Los filtros son elementos fundamentales dentro de las CNN porque permiten aprender características automáticamente a partir de los datos.

Las imágenes también muestran el concepto de extracción jerárquica de información. Esto significa que las primeras capas aprenden patrones básicos y las capas posteriores combinan esos patrones simples para formar representaciones más complejas.

III. CAPAS DE UNA CNN

III-A. Capas convolucionales

La función principal de estas capas es aplicar múltiples filtros sobre la imagen o sobre los mapas de activación generados previamente. Cada filtro produce un *feature map* diferente.

Cada uno de estos mapas resalta diferentes características visuales importantes para la red.

La combinación de todos los *feature maps* permite construir representaciones mucho más completas de la imagen original.

Mientras más capas convolucionales existan, mayor será la capacidad de aprender características complejas y abstractas.

III-B. Stacks de convoluciones pequeñas

En arquitecturas modernas se prefieren múltiples convoluciones pequeñas en lugar de una sola convolución grande.

Por ejemplo, un stack de tres convoluciones 3×3 permite obtener un campo receptivo equivalente a una convolución 7×7 .

La primera convolución observa una región 3×3 de la imagen original. La segunda convolución, al conectarse con la salida anterior, logra observar un área efectiva de 5×5 . Finalmente, la tercera convolución permite observar un área total de 7×7 .

Aunque el resultado espacial es similar al de una convolución única 7×7 , el uso de stacks pequeños presenta ventajas importantes. Entre las principales se encuentran:

- menor cantidad de parámetros,
- reducción del costo computacional,
- incorporación de múltiples funciones no lineales ReLU,
- generación de características más expresivas.

Suponiendo que los volúmenes poseen C canales, una convolución 7×7 requiere:

$$(7 \times 7 \times C) \times C = 49C^2$$

parámetros.

Por otro lado, un stack de tres convoluciones 3×3 requiere:

$$3 \times (3 \times 3 \times C) \times C = 27C^2$$

parámetros, lo que representa una reducción significativa.

III-C. Buenas prácticas en capas convolucionales

En CNN modernas existen varias recomendaciones comunes para el diseño de capas convolucionales.

Generalmente se utilizan campos receptivos pequeños de 3×3 o, como máximo, 5×5 .

Además, normalmente se utiliza:

- *stride* igual a 1,
- *padding* de ceros para conservar dimensiones espaciales.

Por ejemplo:

- para filtros 3×3 se utiliza $P = 1$,
- para filtros 5×5 se utiliza $P = 2$.

Esto permite mantener el tamaño espacial de los mapas de activación mientras se extraen características.

III-D. Funciones de activación

Las funciones de activación permiten introducir no linealidad dentro de la red neuronal. Una de las más utilizadas en CNN es ReLU.

La función ReLU transforma todos los valores negativos en cero y mantiene los valores positivos sin cambios.




Figura 3. Función de activación ReLU

Normalmente, la función de activación se aplica inmediatamente después de una convolución.

III-E. Pooling

El *pooling* es una operación utilizada para reducir las dimensiones espaciales de los mapas de activación, disminuyendo la cantidad de información procesada por la red.

Generalmente, el *pooling* se aplica después de una capa convolucional y de la función de activación.




Figura 4. Ejemplo de operación *max pooling* 2x2

En *max pooling*:

- se toma una región pequeña del mapa de activación,
- se selecciona el valor máximo,
- ese valor representa toda la región.

Este proceso permite conservar las características más importantes mientras se reducen dimensiones.

Entre las principales ventajas del *pooling* se encuentran:

- reducción de carga computacional,
- menor cantidad de parámetros,
- disminución del riesgo de *overfitting*,
- mayor robustez ante pequeñas variaciones de la imagen.

III-F. Capas Fully Connected

Las capas *fully connected* aparecen en la etapa final de una CNN. Estas capas funcionan de manera similar a una red neuronal tradicional y utilizan las características extraídas previamente para realizar la clasificación final.

Las capas convolucionales extraen información relevante, el *pooling* reduce dimensiones y finalmente las capas *fully connected* utilizan toda esa información para determinar la clase correspondiente.

Por ejemplo, la red puede clasificar si la imagen corresponde a:

- un número,
- un animal,
- una persona,
- un objeto específico.

IV. APRENDIZAJE DE CARACTERÍSTICAS

IV-A. Activaciones en capas iniciales

Las primeras capas de una CNN trabajan con información visual simple y de bajo nivel.

Estas capas detectan:

- bordes,
- líneas,
- texturas,
- colores básicos,
- contrastes.

Estas características básicas sirven como base para el aprendizaje de patrones más complejos en capas posteriores.

IV-B. Activaciones en capas profundas

A medida que aumenta la profundidad de la red, las representaciones aprendidas se vuelven más abstractas y complejas.

Las capas profundas pueden reconocer formas completas o más complejas.

Esto ocurre porque las capas profundas combinan la información aprendida por las capas anteriores.

IV-C. Embeddings y representación de características

Las CNN transforman progresivamente las imágenes en representaciones vectoriales denominadas *embeddings*.

Estos vectores contienen información abstracta y permiten representar imágenes mediante características numéricas aprendidas automáticamente.

El objetivo es que imágenes similares produzcan *embeddings* cercanos, mientras que imágenes diferentes generen representaciones separadas.

Estas representaciones pueden visualizarse utilizando técnicas de reducción de dimensionalidad como t-SNE (*t-Distributed Stochastic Neighbor Embedding*).

t-SNE permite transformar *embeddings* de alta dimensión a espacios de menor dimensión conservando relaciones de distancia entre muestras similares.




Figura 5. Representación de embeddings y separación de características en espacios vectoriales.

IV-D. Visualización de características aprendidas

La visualización de activaciones y filtros permite comprender mejor el funcionamiento interno de una CNN.

Estas visualizaciones ayudan a:

- interpretar el comportamiento del modelo,
- identificar patrones importantes,
- analizar errores,
- mejorar arquitecturas.




Figura 6. Visualización de activaciones mediante *heatmaps*

VI-B. Profundidad de la red

Las redes más profundas poseen mayor capacidad para aprender representaciones complejas.

Comparación entre red superficial y profunda:

Mientras más capas existan:

- mayor capacidad de aprendizaje,
- mayor complejidad de patrones reconocidos,
- mejor desempeño en tareas visuales.

Sin embargo, las redes profundas también requieren mayor capacidad computacional y tiempos de entrenamiento más elevados.

VII. VENTAJAS DE LAS CNN

Las CNN presentan múltiples ventajas dentro del área de visión por computadora.

- Detección automática de características sin intervención manual.
- Excelente desempeño en tareas de visión por computadora.
- Capacidad para aprender patrones complejos.
- Reducción de necesidad de ingeniería manual de características.
- Mayor capacidad de generalización.
- Adaptabilidad a múltiples tareas visuales.

VIII. LIMITACIONES Y PROBLEMAS DE LAS CNN

Uno de los principales problemas es la explicabilidad del modelo. En muchos casos las redes neuronales funcionan como una “caja negra”, dificultando entender exactamente cómo toman decisiones.

Además, los features aprendidos no siempre son fácilmente interpretables

- [10] Ultralytics, “t-Distributed Stochastic Neighbor Embedding (t-SNE),” Ultralytics Glossary. [Online]. Available: <https://www.ultralytics.com/glossary/t-distributed-stochastic-neighbor-embedding-t-sne>. [Accessed: 08-May-2026].

REFERENCIAS

- [1] 3Blue1Brown, “But what is a neural network?,” YouTube, 2017. [Online]. Available: <https://www.youtube.com/watch?v=pj9-rr1wDhM&t=1s>
- [2] StatQuest with Josh Starmer, “Convolutional Neural Networks (CNNs) explained,” YouTube, 2021. [Online]. Available: <https://www.youtube.com/watch?v=6MmGNZsA5nI>
- [3] Google Developers, “Funciones de activación,” *Machine Learning Crash Course*. [Online]. Available: https://developers.google.com/translate/goog/machine-learning/crash-course/neural-networks/activation-functions?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc
- [4] A. Jain, “Deep Learning Architecture – AlexNet,” Medium, 2024. [Online]. Available: <https://medium.com/@abhishekjainindore24/deep-learning-architecture-2-alexnet-8018f7640161>
- [5] I. Azeem, “A Brief Overview of ZFNet Architecture,” Medium, 2023. [Online]. Available: <https://medium.com/@ibtedaazeem/a-brief-overview-of-zfnet-architecture-c56aa015d20f>
- [6] S. B., “GoogLeNet: A Deep Dive into Google’s Neural Network Technology,” Medium, 2024. [Online]. Available: <https://medium.com/@siddheshb008/googlenet-a-deep-dive-into-googles-neural-network-technology-f588d1b49e55>
- [7] Ultralytics, “Residual Networks (ResNet),” Ultralytics Glossary. [Online]. Available: <https://www.ultralytics.com/es/glossary/residual-networks-resnet>
- [8] D. H. Karar, “VGG16: The Timeless Deep Learning Architecture That Redefined Image Classification,” Medium, 2024. [Online]. Available: <https://medium.com/@deepvisionkararhaider/vgg16-the-timeless-deep-learning-architecture-that-redefined-image-classification-fd4d3088fb8e>
- [9] DataCamp, “What Are Vector Embeddings?,” DataCamp Blog, 2024. [Online]. Available: <https://www.datacamp.com/blog/vector-embedding>