

Fundamentos, Arquitectura y Estado del Arte de los Modelos de Lenguaje Grandes (LLMs) y RAG

1^{er} Nahomi Bolaños Valverde
Ingeniería en Computación
Tecnológico de Costa Rica
Cartago, Costa Rica
nbolanos@estudiantec.cr

Resumen—Este documento presenta una síntesis exhaustiva sobre el funcionamiento de los Modelos Fundacionales y los Modelos de Lenguaje Grandes (LLMs). Se aborda la transición técnica hacia arquitecturas modulares, el estado del arte con modelos multimodales recientes y los fundamentos del procesamiento de lenguaje natural, incluyendo la tokenización y el mapeo en espacios vectoriales mediante embeddings. Asimismo, se analizan las métricas matemáticas para el cálculo de similitud semántica y se detallan las limitaciones inherentes de los LLMs. Finalmente, se expone la arquitectura de Generación Aumentada por Recuperación (RAG) como la solución de ingeniería estándar para mitigar las alucinaciones y el conocimiento estático en aplicaciones de Inteligencia Artificial.

Index Terms—Modelos de Lenguaje Grandes (LLM), Tokenización, Espacio Vectorial, Similitud del Coseno, Generación Aumentada por Recuperación (RAG), Modelos Fundacionales.

I. INTRODUCCIÓN Y DISCUSIÓN TÉCNICA

La industria de la Inteligencia Artificial (IA) ha experimentado un cambio de paradigma significativo. Se ha pasado de entrenar modelos propios desde cero (Machine Learning tradicional) a la utilización de **Modelos Fundacionales** (Foundational Models), los cuales son pre-entrenados con cantidades masivas de datos. Este avance ha dado lugar a nuevos roles profesionales, tales como los *AI Engineers* y *Prompt Engineers*, cuyo objetivo es integrar grandes modelos (GPT-4, Claude, Gemini) en aplicaciones empresariales específicas.

I-A. Mejores Prácticas y Herramientas

Durante las sesiones de desarrollo, se establecieron lineamientos técnicos críticos:

- **Modularidad del Código:** Se recomienda la transición desde el uso exclusivo de *Jupyter Notebooks* hacia *scripts* modulares en formato `.py`.
- **Gestión de Configuraciones:** Se reportaron fallas de compatibilidad al usar decoradores (`@`) de la librería **Hydra** en entornos interactivos (Notebooks). La solución óptima es modularizar los componentes de **PyTorch Lightning** en archivos `.py` para una correcta ejecución.
- **Arquitectura de Autoencoders:** Se validó la adaptación de un Autoencoder basado en Perceptrón Multicapa a Redes Neuronales Convolucionales (CNN), destacando la importancia de mantener un *espacio latente* continuo.

Documento basado en los apuntes de clase del 21 de mayo

II. ESTADO DEL ARTE Y NOTICIAS TECNOLÓGICAS

El panorama actual de la IA generativa evoluciona rápidamente, destacando los siguientes hitos recientes:

II-A. Lanzamientos de Google y OpenAI

- **Google I/O y AI Overviews:** Transición hacia una era de *agentes de IA autónomos*. La IA generativa responderá directamente a las búsquedas, lo que plantea retos para el modelo de negocio SEO tradicional. Se anunciaron iteraciones como *Gemini 3.5 Flash* (optimizado en latencia) y *Gemini Omni/Spark*.
- **OpenAI GPT-4o (".omni"):** Presentación de un modelo verdaderamente multimodal nativo (texto, audio y visión). Elimina la necesidad de encadenar modelos (ej. Speech-to-Text + LLM), logrando baja latencia y percepción de emociones en tiempo real.

II-B. Incidentes de Ciberseguridad

El despliegue de estas tecnologías no está exento de riesgos. Se reportaron incidentes críticos como la eliminación masiva de datos estructurados por parte de la plataforma *Claude (Anthropic)* sin consentimiento explícito, y una vulnerabilidad en *GitHub* donde atacantes usaron extensiones maliciosas para extraer código fuente de repositorios privados.

III. FUNDAMENTOS DE LOS LLMs

En su núcleo, un LLM es un modelo estadístico diseñado para predecir el siguiente *token* basándose en el contexto previo. Su versatilidad les permite procesar texto, código, imágenes y audio mediante redes neuronales complejas compuestas por *Inputs*, *Pesos (Weights)*, *Nodos Ocultos* y *Outputs*.

III-A. Capacidades Emergentes

Gracias a la arquitectura *Transformers* y el entrenamiento masivo, los LLMs desarrollan habilidades no programadas explícitamente:

- **Comprensión Contextual:** Entienden el significado según las oraciones adyacentes.
- **Razonamiento:** Resolución de problemas lógicos.
- **In-context Learning:** Adaptación de comportamiento mediante ejemplos en el *prompt*.

IV. PROCESAMIENTO DE TEXTO: TOKENIZACIÓN

Los modelos de IA requieren representaciones matemáticas. La **tokenización** es el proceso de dividir el texto en unidades (tokens) y asignarles un identificador numérico (ID).

Cuadro I
TIPOS COMUNES DE TOKENIZACIÓN

Enfoque	Característica/Ventaja
Palabra	Simple, pero genera vocabularios ineficientes y gigantes.
Carácter	Evita palabras desconocidas, pero pierde el contexto en secuencias largas.
Sub-palabra (BPE)	Estándar actual (Byte-Pair Encoding). Divide palabras en raíces/prefijos. Equilibrio ideal.

V. EMBEDDINGS Y ESPACIOS VECTORIALES

Un simple ID numérico no captura el significado. Los **embeddings** son representaciones vectoriales densas que traducen las palabras a un **espacio vectorial** multidimensional (ej. 512, 1024 dimensiones).

V-A. Mapeo Conceptual y Aritmética

En este espacio, palabras con significados similares se ubican en puntos cercanos (relaciones semánticas). Al estar en un plano matemático, la IA puede realizar operaciones aritméticas con conceptos:

$$Vector(Rey) - Vector(Hombre) + Vector(Mujer) = Vector(Reina) \quad (1)$$

V-B. Métricas de Similitud

Para calcular matemáticamente la cercanía entre conceptos, se utilizan principalmente dos métricas:

1) **Distancia Euclidiana:** Mide la separación en línea recta entre dos puntos.

$$d(\mathbf{a}, \mathbf{b}) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2} \quad (2)$$

2) **Similitud del Coseno:** Mide el ángulo entre dos vectores. Es la métrica preferida en Procesamiento de Lenguaje Natural (NLP) porque evalúa la dirección (significado temático) sin verse afectada por la magnitud (frecuencia o longitud del texto).

$$\text{sim}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \quad (3)$$

VI. LIMITACIONES DE LOS LLMs

A pesar de sus capacidades, los modelos presentan fallas críticas que limitan su uso directo en entornos corporativos:

- **Conocimiento Estático:** Tienen una "fecha de corte" de entrenamiento y no conocen eventos recientes.
- **Alucinaciones:** Inventan respuestas falsas con un tono convincente cuando desconocen la información, ya que su objetivo es solo predecir la siguiente palabra.
- **Amnesia (Stateless):** Las APIs no tienen memoria intrínseca. Olvidan la conversación a menos que se reenvíe el contexto completo (*Context Window*).

VII. ARQUITECTURA RAG (RETRIEVAL-AUGMENTED GENERATION)

Para solucionar las alucinaciones y el conocimiento estático, se implementa la arquitectura **RAG**. Esta técnica conecta el LLM con un buscador externo para inyectar conocimiento privado o actualizado. Se divide en tres fases principales:

VII-A. Fase 1: Ingesta e Indexación (Pre-producción)

- Se recopilan documentos privados (PDFs, bases de datos).
- Chunking:** El texto se divide en fragmentos pequeños (200-500 tokens), utilizando solapamiento (*overlap*) para no cortar ideas.
- Cada *chunk* se pasa por un modelo de embeddings para vectorizarlo.
- Indexación:** Se guardan en una Base de Datos Vectorial (*Vector DB* como Pinecone, Qdrant, ChromaDB) junto con su *metadata*.

VII-B. Fase 2: Recuperación (Retrieval)

Cuando el usuario realiza una consulta, la pregunta se convierte en un embedding. El sistema realiza una búsqueda semántica utilizando la **Similitud del Coseno** en la base de datos vectorial para extraer los *Top-K* chunks más relevantes.

VII-C. Fase 3: Generación (Aumentación)

Se construye un *Prompt* dinámico estructurado que restringe al modelo: *"Eres un asistente experto. Usa únicamente el siguiente contexto para responder. Contexto: [Chunks recuperados]. Pregunta: [Pregunta del usuario]"*.

El LLM recibe este prompt y genera una respuesta precisa, informada y basada puramente en la evidencia real encontrada en los datos de la empresa.

VIII. CONCLUSIÓN

Los Modelos de Lenguaje Grandes representan un avance monumental en la IA, logrando capacidades emergentes gracias a la tokenización avanzada (BPE) y el mapeo en espacios vectoriales de alta dimensionalidad. Sin embargo, para aplicaciones empresariales fiables, el uso aislado de LLMs es insuficiente debido a las alucinaciones y su naturaleza estática. La integración de la arquitectura RAG, apoyada en bases de datos vectoriales y métricas como la similitud del coseno, se consolida como el ecosistema definitivo para dotar a la IA de precisión, memoria y contexto actualizado.